

FGV EMap
João Pedro Jerônimo

Probabilidade

Revisão para A1

Rio de Janeiro
2026

Conteúdo

1	Combinatória	3
1.1	Contagem	4
1.2	Permutação	4
1.3	Arranjos	5
1.4	Combinações	5
1.5	Permutação Circular	6
2	Primeiros passos em Probabilidade	7
2.1	Conjuntos e Definição Ingênua de Probabilidade	8
2.2	Tabela Amostral e Demonstração por Interpretação	9
2.2.1	Ordem Importa e Reposição	9
2.2.2	Ordem Importa e Sem Reposição	9
2.2.3	Ordem não Importa e Sem Reposição	9
2.2.4	Ordem não Importa e Reposição	9
2.3	Teoremas Úteis	10
2.4	Problema do Aniversário	11
2.5	Propriedades da Probabilidade	11
2.6	Eventos Independentes	13
3	Probabilidade Condicional	14
3.1	Como o Conhecimento influencia na Probabilidade	15
3.2	O Teorema de Bayes	16
3.2.1	Falácia do Promotor	17
3.3	Lei da Probabilidade Total	18
4	Variáveis Aleatórias Discretas	20
4.1	Experimentos Aleatórios	21
4.2	Função de Massa	21
4.3	Transformações sobre as variáveis	22
4.4	Função Acumulada	23
5	Esperança, Medidas de Dispersão e Quantificadores de Independência	24
5.1	O Valor Médio	25
5.1.1	Law of the Unconscious Statistician	25
5.1.2	Esperança e Independência	27
5.1.3	Monotonicidade da Esperança	27
5.1.4	Função de Sobrevivência	28
5.2	Medidas de Dispersão	28
5.2.1	Propriedades	29
5.2.2	Desigualdade de Chebyshev	31
5.3	Quantificadores de Independência	32
6	Distribuições de Variáveis Aleatórias Discretas	37

Combinatória

Antes de passarmos para os conteúdos mais complexos de probabilidade (que na minha opinião são mais fáceis que combinatória), vamos revisar alguns conceitos de probabilidade do ensino médio (eu não tive isso no ensino médio, mas me disseram que se vê lá né)

1.1 Contagem

No tópico de contagem, duas coisas vão ser muito importantes para nós, o princípio fundamental da contagem e a estratégia de abordagem de problemas.

Teorema 1.1.1 (Princípio Fundamental da Contagem): Dada uma decisão D_1 com x escolhas, e uma decisão **consecutiva** D_2 com y escolhas, de forma que cada decisão x tomada tem y opções disponíveis, o número total de maneiras de realizar ambas as decisões é $x \cdot y$.

Demonstração: Vamos demonstrar por *indução*. Para uma única etapa (caso base), existem exatamente a_1 opções. Suponha que para n etapas, o número de maneiras de realizar todas as decisões seja $a_1 \cdot \dots \cdot a_n$. Agora vamos adicionar uma nova decisão D_{n+1} com a_{n+1} escolhas. Se visualizarmos as primeiras n decisões como uma única decisão com $a_1 \cdot \dots \cdot a_n$ possibilidades, então o número total de maneiras de realizar todas as decisões é $(a_1 \cdot \dots \cdot a_n) \cdot a_{n+1} = a_1 \cdot \dots \cdot a_n \cdot a_{n+1}$, como queríamos demonstrar. $\square$

Isso nos traz uma estratégia de abordagem de problemas bem definida

- **Postura:** Sempre colocar no papel o que se sabe e o que se quer, e tentar organizar as informações de forma a facilitar a visualização do problema.
- **Divisão:** Sempre que possível, dividir o problema em subproblemas menores, e resolver cada um deles separadamente.
- **Não adiar dificuldades:** Se uma das decisões a serem tomadas for mais restrita que as demais, esta deve ser tomada primeiro, para que as demais decisões possam ser tomadas com mais liberdade.

1.2 Permutação

Usamos a permutação para saber de quantas maneiras podemos organizar um conjunto de elementos de forma ordenada.

Definição 1.2.1 (Permutação de elementos **distintos**): Se temos n elementos distintos, o número de maneiras de organizá-los em uma sequência ordenada é dado por

$$P_n = n! = n \cdot (n - 1) \cdot \dots \cdot 2 \cdot 1 \quad (1)$$

Exemplo: Quantos anagramas existem na palavra “VIDRO”? A palavra “VIDRO” possui 5 letras distintas, então o número de anagramas é $5! = 5 \cdot 4 \cdot 3 \cdot 2 \cdot 1 = 120$.

Mas essa situação é um pouco mais complicada quando temos elementos repetidos, como na palavra “MAMÃO”. Nesse caso, temos 5 letras, mas a letra “A” se repete 2 vezes.

Definição 1.2.2 (Permutação de elementos **distintos**): Se temos n elementos, dos quais n_1 são idênticos, n_2 são idênticos, ..., n_k são idênticos, o número de maneiras de organizá-los em uma sequência ordenada é dado por

$$P_n^{n_1, n_2, \dots, n_k} = \frac{n!}{n_1! \cdot n_2! \cdot \dots \cdot n_k!} \quad (2)$$

Vamos tentar pensar no porquê dessa fórmula! Imagina que eu tenho uma palavra qualquer, e nela eu tenho DUAS letras repetidas. Se eu fixo uma das letras em um lugar, a outra letra pode ir para qualquer posição da palavra. No entanto, se eu fixo a segunda letra, a primeira **também** pode ir para qualquer posição, e eu acabo contando as **mesmas** palavras duas vezes. Por exemplo:

$$ABCA \rightarrow ABCA \quad (3)$$

mesma palavra, mas com as posições do A trocadas, logo, foi contabilizada duas vezes. Se eu tivesse 3 letras repetidas, eu teria contado a mesma palavra $3!$ vezes, e assim por diante. Por isso, para corrigir isso, eu divido pelo fatorial do número de letras repetidas.

Exemplo: Quantos anagramas existem na palavra “MAMÃO”? A palavra “MAMÃO” possui 5 letras, das temos 2 letras “A” e 2 letras “M” repetidas, então o número de anagramas é

$$P_5^{2,2} = \frac{5!}{2! \cdot 2!} = \frac{120}{2 \cdot 2} = 30 \quad (4)$$

1.3 Arranjos

Dado um grupo de n elementos, eu quero selecionar k elementos distintos e organizá-los em uma sequência ordenada, de forma que, ao trocar a ordem dos elementos, eu obtenha uma **sequência diferente**. Por exemplo, se eu quiser saber, dentro dos meus **competidores**, quantas combinações possíveis de **primeiro**, **segundo** e **terceiro** lugar existem, se eu troco o **primeiro** pelo **segundo**, então vira uma sequência diferente, e portanto, é um arranjo diferente.

Definição 1.3.1 (Arranjo de tamanho k para n elementos): O arranjo de tamanho k para n elementos distintos é dado por

$$A_n^k = n(n-1)\dots(n-k+1) = \frac{n!}{(n-k)!} \quad (5)$$

Por que seria essa fórmula? Bom, se eu tenho n elementos, para o primeiro elemento da sequência eu tenho n opções. Para o segundo elemento, eu já usei um elemento, então eu tenho $n-1$ opções. Para o terceiro elemento, eu já usei dois elementos, então eu tenho $n-2$ opções. E assim por diante, até que eu tenha escolhido k elementos. Então, o número total de maneiras de escolher e organizar esses k elementos é dado pelo produto $n(n-1)\dots(n-k+1)$.

1.4 Combinações

Dado um grupo de n elementos, eu quero selecionar k elementos distintos, mas agora a ordem não importa. Por exemplo, se eu quero saber a combinação de ingredientes para o meu sanduíche, se eu coloco o **hamburguer** antes do **queijo**, ou o **queijo** antes do **alface**, isso não faz diferença nenhuma.

Definição 1.4.1 (Combinação de n elementos escolhendo k): O número de combinações de n elementos distintos escolhendo k elementos é dado por

$$C_n^k = \frac{n!}{k! \cdot (n-k)!} = \frac{A_n^k}{k!} = \binom{n}{k} \quad (6)$$

A lógica aqui é montarmos justamente o arranjo anterior, primeiro calculamos de quantas formas podemos organizar k elementos onde a **ordem** influencia na contagem. Depois disso, queremos compensar as contagens extras que realizamos, ou seja, se eu tenho k elementos, eu posso organizá-los de $k!$ formas diferentes, e todas essas formas são a mesma combinação. Então, para compensar isso, dividimos pelo fatorial de k .

1.5 Permutação Circular

De quantas formas podemos organizar n elementos distintos em um círculo? Para isso usamos a permutação circular.

Definição 1.5.1 (Permutação circular de n elementos): A permutação circular de n elementos distintos é dada por

$$P_n^{\text{circ}} = (n-1)! \quad (7)$$

Para entender melhor a lógica vamos para um exemplo. Suponha que eu tenho 5 pessoas, A , B , C , D e E . Vamos agora organizar elas em um círculo.

$$A \rightarrow B \rightarrow C \rightarrow D \rightarrow E \rightarrow A \quad (8)$$

perfeito! Mas e se eu organizar elas assim?

$$B \rightarrow C \rightarrow D \rightarrow E \rightarrow A \rightarrow B \quad (9)$$

percebe que é a mesma organização, só que com outro ponto de referência? Então, para cada permutação linear de n elementos, existem n permutações circulares equivalentes. Por isso, para calcular a permutação circular, dividimos a permutação linear por n , ou seja, $P_n^{\text{circ}} = \frac{P_n}{n} = \frac{n!}{n} = (n-1)!$.

Primeiros passos em Probabilidade

2.1 Conjuntos e Definição Ingênua de Probabilidade

Toda a teoria de probabilidade é construída em cima da teoria de conjuntos, então muitos teoremas de probabilidade são apenas teoremas de conjuntos aplicados a eventos.

Definição 2.1.1 (Espaço Amostral): O espaço amostral S é o conjunto de todos os resultados possíveis de um experimento aleatório.

Definição 2.1.2 (Evento): Um evento E é um subconjunto do espaço amostral S , ou seja, $E \subseteq S$.

Corolário 1.1.1.1: Dado S um espaço amostral e $A, B \subseteq S$ sendo eventos em S , temos que

1. $A \cup B$ é o evento onde **ou** A **ou** B ocorrem.
2. $A \cap B$ é o evento onde **ambos** A e B ocorrem.
3. A^c é o evento onde A **não** ocorre.

Exemplo: Dada uma moeda, jogamos ela 10 vezes (cada jogada é **independente**), então, se for **cara**, é 1 e se for coroa é 0. Escrevemos então a jogada como uma sequência de 10 bits, onde cada bit é 0 ou 1.

$$(1, 0, 0, 1, 1, 0, 1, 0, 0, 1) \quad (10)$$

vejamos alguns eventos:

- Jogada i ser cara e o resto ser coroa

$$A_i = \{(\dots, 1, \dots) \text{ tal que } 1 \text{ está na posição } i \text{ e } i \in \{1, 2, \dots, 10\}\} \quad (11)$$

- Ao menos uma jogada ser cara

$$B = \cup_{i=1}^{10} A_i \quad (12)$$

- Todas as jogadas são cara

$$C = \cap_{i=1}^{10} A_i \quad (13)$$

Teorema 2.1.1 (Lei de De Morgan): Dado S um espaço amostral e $A, B \subseteq S$ sendo eventos em S , temos que

1. $(A \cup B)^c = A^c \cap B^c$
2. $(A \cap B)^c = A^c \cup B^c$

Demonstração: Para a primeira igualdade, temos que provar que $(A \cup B)^c \subseteq A^c \cap B^c$ e depois $A^c \cap B^c \subseteq (A \cup B)^c$. Para a primeira parte, seja

$$x \in (A \cup B)^c \Leftrightarrow x \notin A \cup B \quad (14)$$

logo, $x \notin A$ e $x \notin B$, ou seja, $x \in A^c$ e $x \in B^c$, então $x \in A^c \cap B^c \Rightarrow (A \cup B)^c \subseteq A^c \cap B^c$. Para a volta, seja $x \in A^c \cap B^c$, então $x \in A^c$ e $x \in B^c$, ou seja, $x \notin A$ e $x \notin B$, então $x \notin (A \cup B)$, ou seja, $A^c \cap B^c \subseteq (A \cup B)^c$.

Para a segunda igualdade, faremos o mesmo raciocínio. Seja $x \in (A \cap B)^c$ então $x \notin A \cap B$, ou seja, x não ocorre **simultaneamente** em A e B , logo $x \notin A$ **ou** $x \notin B$, ou seja, $x \in A^c$ **ou**

$x \in B^c$, então $x \in A^c \cup B^c \Rightarrow (A \cap B)^c \subseteq A^c \cup B^c$. Para a volta, seja $x \in A^c \cup B^c$, então $x \in A^c$ ou $x \in B^c$, ou seja, $x \notin A$ ou $x \notin B$, logo $x \notin (A \cap B)$, ou seja, $A^c \cup B^c \subseteq (A \cap B)^c$. $\square$

Com todas essas definições, teoremas e revisão de contagem, nós conseguimos finalmente definir de maneira **informal** o que é a probabilidade de um evento ocorrer

Definição 2.1.3 (Naive Probability Definition): Dado um espaço amostral S e um evento $E \subseteq S$, a probabilidade de E ocorrer é dada por

$$\mathbb{P}(E) = \frac{|E|}{|S|} \quad (15)$$

2.2 Tabela Amostral e Demonstração por Interpretação

A tabela amostral é muito útil para organizar **quais ferramentas** de contagem utilizamos sob **determinadas condições** de um **experimento**

	Ordem Importa	Ordem não Importa
Reposição	n^k	$\binom{n+k-1}{k}$
Sem Reposição	$\frac{n!}{(n-k)!}$	$\binom{n}{k}$

Antes de continuarmos e mostrarmos algumas identidades interessantes para nos ajudar a resolver alguns problemas, vamos discorrer o porquê de cada uma das fórmulas mencionadas anteriormente.

2.2.1 Ordem Importa e Reposição

Se a ordem importa, então estamos lidando com arranjos. Se há reposição, então para cada elemento escolhido, ele volta para o conjunto de elementos disponíveis, ou seja, na primeira retirada, eu tenho n elementos disponíveis, na segunda, eu ainda tenho n pois o anterior foi colocado de volta, e assim por diante. Logo, o número de maneiras de escolher k elementos com reposição é dado por n^k .

2.2.2 Ordem Importa e Sem Reposição

Estamos lidando literalmente com os arranjos como já vimos antes, então será a mesma fórmula do arranjo, ou seja, $\frac{n!}{(n-k)!}$.

2.2.3 Ordem não Importa e Sem Reposição

É exatamente o caso da combinação padrão que discutimos anteriormente, ou seja, $\binom{n}{k}$.

2.2.4 Ordem não Importa e Reposição

Esse caso é um pouco mais complicado. Você saber de quantas formas possíveis você pode escolher k elementos de um conjunto de n elementos, mas agora você pode escolher o mesmo elemento mais de uma vez, isso é equivalente a **perguntar de quantos jeitos diferentes é possível distribuir k partículas independentes em n caixas diferentes**, mas por quê? Isso não parece nada intuitivo.

Interprete uma associação, cada partícula é um **sorteio** e cada caixa é um **elemento do conjunto**. Quando eu falo **partícula i vai ficar na caixa p** , isso quer dizer em termos do sorteio que, no i -ésimo sorteio, o elemento escolhido foi o p -ésimo elemento do conjunto. Então, se eu tenho k partículas e n caixas, isso é equivalente a dizer que eu tenho k sorteios e n elementos disponíveis para escolher. Como eu posso escolher um mesmo elemento mais de uma vez, isso é equivalente

a dizer que eu posso colocar mais de uma partícula na mesma caixa. Para fazer o cálculo de fato, utilizamos a abordagem de pontos e traços, tenha em mente a seguinte divisão

$$\dots / \cdot / \dots / \cdot / \cdot \quad (16)$$

Essa representação é o mesmo que dizer que na primeira caixa, eu tenho 3 partículas, na segunda eu tenho 1 e assim em diante, a quantidade de pontos entre os traços representa a quantidade de partículas em cada caixa. Como temos k partículas, temos k pontos, e como temos n caixas, temos $n - 1$ traços. Logo, o número total de maneiras de organizar esses pontos e traços vai ser o número de maneiras de escolher k pontos dentre todos os $k + n - 1$ elementos, ou seja, $\binom{n+k-1}{k}$.

2.3 Teoremas Úteis

Aqui nós vamos mostrar alguns teoremas que serão muito úteis para nós na hora de resolver problemas de probabilidade. Suas demonstrações não serão algébricas, mas sim por interpretação, ou seja, vamos interpretar o que cada lado da equação significa e mostrar que eles são equivalentes.

Teorema 2.3.1:

$$n \binom{n-1}{k-1} = k \binom{n}{k} \quad (17)$$

Demonstração: Queremos saber de quantas formas podemos escolher k pessoas de um grupo de n pessoas, e dentre essas k pessoas, queremos escolher uma pessoa para ser o **líder**.

No lado direito da igualdade, quando fazemos

$$k \binom{n}{k} \quad (18)$$

primeiro fazemos a contagem de quantas formas podemos escolher k pessoas de um grupo de n pessoas (combinação) e, dentro dessas k , quantas podem ser o **líder**.

Já no lado esquerdo, quando fazemos

$$n \binom{n-1}{k-1} \quad (19)$$

primeiro eu vou escolher o **líder** do grupo dentre as n pessoas, e das $n - 1$ que sobraram, eu vou montar um grupo de $k - 1$ para completar k com o líder que eu escolhi. $\square$

Teorema 2.3.2 (Identidade de Vandermonde):

$$\binom{m+n}{k} = \sum_{j=0}^k \binom{m}{j} \binom{n}{k-j} \quad (20)$$

Demonstração: Eu quero escolher k pessoas de um grupo de $m + n$ pessoas. Eu posso dividir esse grupo em dois subgrupos, um com m pessoas e outro com n pessoas. Depois

disso, posso dividir em duas etapas, primeiro eu escolho j pessoas do grupo de m pessoas, e depois eu escolho $k - j$ pessoas do grupo de n pessoas, assim completo um grupo de k pessoas. Como j pode variar de 0 até k , eu somo todas as possibilidades, e assim obtenho a **Identidade de Vandermonde**. $\square$

2.4 Problema do Aniversário

Que tal resolvermos um problema bem paradoxal para estimular nosso pensamento **probabilístico**? O problema do aniversário é o seguinte: qual a probabilidade de, em um grupo de n pessoas, **pelo menos** duas delas fazerem aniversário no mesmo dia? Parece que para que isso aconteça, o grupo precisa ser grande, mas não é bem assim. Antes de resolvermos o problema, vou enunciar um teorema que será útil para provar o caso mais óbvio.

Teorema 2.4.1 (Princípio da Casa dos Pombos): Se n pombos são colocados em m casas, e $n > m$, então **pelo menos** uma casa terá mais de um pombo.

Agora podemos enunciar as etapas da resolução do problema! Primeira coisa que fazemos é **remover as restrições**. Uma delas é o dia 29 de fevereiro, que só ocorre em anos bissextos, então vamos **desconsiderar** esse dia. Outro ponto é que **cada dia** tem a **mesma chance** de ocorrer e são eventos **independentes**. Nessa situação, o mais fácil é calcular a probabilidade do evento **contrário**, ou seja, a probabilidade de que **todos do grupo tem aniversários diferentes**.

$$\mathbb{P}(\text{todos diferentes}) = \frac{365}{365} \cdot \frac{364}{365} \cdot \frac{363}{365} \cdots \frac{365 - k + 1}{365} = \frac{365!}{(365-k)! 365^k} \quad (21)$$

Aqui, nós vamos no raciocínio que o primeiro aniversariante tem 365 opções, o segundo tem 364 opções, o terceiro tem 363 opções e assim por diante, até que o último aniversariante tenha $365 - k + 1$ opções. Como cada pessoa tem 365 opções, então o número total de possibilidades é 365^k . Logo, a probabilidade de **pelo menos** duas pessoas fazerem aniversário no mesmo dia é

$$\mathbb{P}(\text{pelo menos dois iguais}) = 1 - \mathbb{P}(\text{todos diferentes}) = 1 - \frac{365!}{(365-k)! 365^k} \quad (22)$$

Quando $k = 23$, a probabilidade de que **pelo menos** duas pessoas façam aniversário no mesmo dia é de aproximadamente 50%.

2.5 Propriedades da Probabilidade

Dado toda a introdução que fizemos, podemos agora enunciar algumas propriedades da probabilidade que serão muito úteis. Antes, precisamos saber dos seguintes axiomas:

$$\begin{aligned} \mathbb{P}(\emptyset) &= 0 & \mathbb{P}(S) &= 1 & \mathbb{P}(A) &\geq 0 \\ \mathbb{P}\left(\bigcup_{n=1}^{\infty} A_n\right) &= \sum_{n=1}^{\infty} \mathbb{P}(A_n) & \rightarrow A_i \cap A_j &= \emptyset \quad \forall i \neq j \end{aligned} \quad (23)$$

Agora podemos enunciar as propriedades e suas demonstrações

Teorema 2.5.1:

$$\mathbb{P}(A^c) = 1 - \mathbb{P}(A) \quad (24)$$

Demonstração:

$$\begin{aligned} 1 = \mathbb{P}(S) &\Leftrightarrow 1 = \mathbb{P}(A^c \cup A) \\ &\Leftrightarrow 1 = \mathbb{P}(A^c) + \mathbb{P}(A) \Leftrightarrow \mathbb{P}(A^c) = 1 - \mathbb{P}(A) \end{aligned} \quad (25)$$

□

Teorema 2.5.2: Se $A \subseteq B$, então $\mathbb{P}(A) \leq \mathbb{P}(B)$

Demonstração: Montamos B como $A \cup (B \cap A^c)$, se montarmos dessa forma, A e $(B \cap A^c)$ são disjuntos. Antes de prosseguirmos, aqui está uma figura que ilustra a situação




Figura 1: Ilustração da relação entre os conjuntos A e B

Dito isso, podemos então escrever:

$$\mathbb{P}(B) = \mathbb{P}(A \cup (B \cap A^c)) = \mathbb{P}(A) + \mathbb{P}(B \cap A^c) \geq \mathbb{P}(A) \quad (26)$$

□

Teorema 2.5.3:

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B) \quad (27)$$

Demonstração: Montamos $A \cup B$ como $A \cup (B \cap A^c)$, se montarmos dessa forma, A e $(B \cap A^c)$ são disjuntos.

Dito isso, podemos então escrever:

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B \cap A^c) \quad (28)$$

Temos então que mostrar que

$$\mathbb{P}(B \cap A^c) = \mathbb{P}(B) - \mathbb{P}(A \cap B) \quad (29)$$

para isso, vamos mostrar que, $(B \cap A^c) \cup (A \cap B) = B$. Para provar isso, vamos mostrar que $(B \cap A^c) \cup (A \cap B) = B \cap (A \cup A^c)$. Se $x \in B$, então $x \in A$ **ou** $x \notin A$, logo, $x \in S$, dessa forma

$$x \in B \cap (A \cup A^c) \Leftrightarrow x \in B \cap S \Leftrightarrow x \in B \quad (30)$$

e temos que $B \cap A^c$ e $A \cap B$ são disjuntos, logo

$$\begin{aligned} \mathbb{P}(B) &= \mathbb{P}((B \cap A^c) \cup (A \cap B)) = \mathbb{P}(B \cap A^c) + \mathbb{P}(A \cap B) \\ &\Leftrightarrow \\ \mathbb{P}(B \cap A^c) &= \mathbb{P}(B) - \mathbb{P}(A \cap B) \end{aligned} \quad (31)$$

□

Teorema 2.5.4:

$$\begin{aligned} \mathbb{P}(A \cup B \cup C) &= \mathbb{P}(A) + \mathbb{P}(B) + \mathbb{P}(C) \\ &\quad - \mathbb{P}(A \cap B) - \mathbb{P}(A \cap C) - \mathbb{P}(B \cap C) \\ &\quad + \mathbb{P}(A \cap B \cap C) \end{aligned} \quad (32)$$

2.6 Eventos Independentes

Dois eventos A e B são independentes se a ocorrência de um não afeta a probabilidade do outro.

Definição 2.6.1 (Eventos Independentes): Dois eventos A e B são independentes quando

$$\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B) \quad (33)$$

muitas vezes é difícil achar uma formulação rigorosa para mostrar que dois eventos são independentes sem uma tabela registrada das probabilidades, mas a **intuição** é um grande aliado nesses casos. Por exemplo, se eu joga uma moeda e um dado, a ocorrência de **cara** na moeda não afeta a probabilidade de sair 6 no dado (desde que ambos sejam justos), então esses dois eventos são **independentes**.

Probabilidade Condicional

3.1 Como o Conhecimento influencia na Probabilidade

Em probabilidade, conseguimos utilizar conhecimento prévio para atualizar as nossas previsões, por exemplo, se eu sei que nas últimas 10 jogadas de um dado, o número 6 saiu 8 vezes, então a **dependendo** das minhas **premissas** (por exemplo, eu não tenho garantia que o dado é justo), eu posso atualizar a minha previsão e dizer que eu tenho uma chance grande de cair 6 novamente.

Exemplo: Ao jogarmos um dado justo 2 vezes, dado que eu sei que a soma de ambos os valores que caíram é 6, qual é a probabilidade de que o primeiro valor seja 2? Sabemos que a soma de ambos os valores que caíram é 6, então o espaço amostral é reduzido para

$$(1, 5), (2, 4), (3, 3), (4, 2), (5, 1) \quad (34)$$

dentro das possibilidades, a probabilidade vai ser

$$\mathbb{P}(\text{primeiro valor é 2} \mid \text{soma é 6}) = \frac{1}{5} \quad (35)$$

Definição 3.1.1 (Probabilidade Condicional): Dado um espaço amostral S e dois eventos $A, B \subseteq S$, a probabilidade de A ocorrer dado que B ocorreu é dada por

$$\mathbb{P}(A \mid B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} \quad (36)$$

Teorema 3.1.1: Se A e B são independentes, então

$$\mathbb{P}(A \mid B) = \mathbb{P}(A) \quad (37)$$

Demonstração: Pela definição:

$$\mathbb{P}(A \mid B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} \quad (38)$$

Como são independentes:

$$\mathbb{P}(A \mid B) = \frac{\mathbb{P}(A) \cdot \mathbb{P}(B)}{\mathbb{P}(B)} = \mathbb{P}(A) \quad (39)$$

□

Exemplo: Voltando no exemplo do dado com soma 6, vamos separar o problema em dois eventos para aplicar a definição de probabilidade condicional. Seja A o evento de que o primeiro valor seja 2, e seja B o evento de que a soma dos valores seja 6. Então, temos que

$$\mathbb{P}(B) = \frac{5}{36} \quad \mathbb{P}(A \cap B) = \frac{1}{36} \quad (40)$$

então aplicando a definição:

$$\mathbb{P}(A \mid B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} = \frac{\frac{1}{36}}{\frac{5}{36}} = \frac{1}{5} \quad (41)$$

3.2 O Teorema de Bayes

Teorema 3.2.1:

$$\mathbb{P}(A \cap B) = \mathbb{P}(A | B) \cdot \mathbb{P}(B) = \mathbb{P}(B | A) \cdot \mathbb{P}(A) \quad (42)$$

Demonstração: Sabemos que $\mathbb{P}(A \cap B) = \mathbb{P}(B \cap A)$, manipulando então a definição de probabilidade condicional, temos que

$$\mathbb{P}(A|B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} \Leftrightarrow \mathbb{P}(A \cap B) = \mathbb{P}(A | B) \cdot \mathbb{P}(B) \quad (43)$$

e

$$\mathbb{P}(B|A) = \frac{\mathbb{P}(B \cap A)}{\mathbb{P}(A)} \Leftrightarrow \mathbb{P}(B \cap A) = \mathbb{P}(B | A) \cdot \mathbb{P}(A) \quad (44)$$

□

Teorema 3.2.2 (Teorema de Bayes): Sejam A e B dois eventos, então temos que

$$\mathbb{P}(A | B) = \frac{\mathbb{P}(B | A) \cdot \mathbb{P}(A)}{\mathbb{P}(B)} \quad (45)$$

Demonstração: Aplicando o Teorema 3.2.1, temos que

$$\mathbb{P}(A|B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} = \frac{\mathbb{P}(B | A) \cdot \mathbb{P}(A)}{\mathbb{P}(B)} \quad (46)$$

□

Pode não parecer, mas esse é um dos teoremas **mais importantes** da probabilidade, mas também um dos que gera **mais confusão**. Vamos considerar, por exemplo, um exame que vai me dizer se **tenho malária**. Vamos supor também que

- Apenas 1% da população tem malária
- O teste acerta 99% dos doentes
- O teste acerta 99% dos saudáveis

Analizando rapidamente, se o teste der positivo, isso parece falar que **a chance de eu ter malária é de 99%**, mas isso **não é verdade**. Nós queremos calcular

$$\mathbb{P}(\text{Doente}|\text{Positivo}) \quad (47)$$

pelo Teorema 3.2.2, temos que

$$\mathbb{P}(\text{Doente}|\text{Positivo}) = \frac{\mathbb{P}(\text{Positivo}|\text{Doente}) \cdot \mathbb{P}(\text{Doente})}{\mathbb{P}(\text{Positivo})} = \frac{0.99 \cdot 0.01}{\mathbb{P}(\text{Positivo})} \quad (48)$$

para calcular $\mathbb{P}(\text{Positivo})$, vamos usar a lei da probabilidade total (vamos enunciar ela mais formalmente depois), mas ela diz que podemos expressar essa probabilidade como

$$\begin{aligned}\mathbb{P}(\text{Positivo}) &= \mathbb{P}(\text{Positivo}|\text{Doente}) \cdot \mathbb{P}(\text{Doente}) + \mathbb{P}(\text{Positivo}|\text{Saudável}) \cdot \mathbb{P}(\text{Saudável}) \\ &= 0.99 \cdot 0.01 + 0.01 \cdot 0.99 = 0.0198\end{aligned}\quad (49)$$

voltando para a fórmula anterior

$$\mathbb{P}(\text{Doente}|\text{Positivo}) = \frac{0.99 \cdot 0.01}{0.0198} = 0.5 \quad (50)$$

então se eu sei que meu teste deu positivo, na verdade, a chance de eu ter malária é de apenas 50%, e não 99% como parecia inicialmente. Isso é um exemplo clássico de como o Teorema de Bayes nos ajuda a atualizar nossas previsões com base em informações novas.

3.2.1 Falácia do Promotor

Um caso muito famoso onde essa confusão teve consequências graves, foi o caso de *Sally Clark*. Em 1999, ela estava sendo julgada pelo assassinato de seus dois bebês, que morreram de *Síndrome da Morte Súbita Infantil*.



Figura 2: Sally Clark

O promotor do caso alegou que a probabilidade de duas crianças morrerem de *Síndrome da Morte Súbita Infantil* na mesma família era de 1 em 73 milhões, e que isso provava que ela era culpada. No entanto, essa alegação foi baseada em uma falácia estatística, pois não considerou outros fatores, como histórico familiar, condições de saúde e outros fatores de risco. Resumidamente, ele confundiu

$$\mathbb{P}(\text{Evidência}|\text{Inocência}) \quad (51)$$

com

$$\mathbb{P}(\text{Inocência}|\text{Evidência}) \quad (52)$$

Anos depois a condenação foi anulada. Diversos estatísticos apontaram que houve uso incorreto de probabilidade no julgamento.

3.3 Lei da Probabilidade Total

A lei da probabilidade total dita como as probabilidades condicionais de eventos conhecidos se combinam para formar a probabilidade de um evento desconhecido. Vamos enunciar o teorema e depois vamos mostrar um exemplo.

Teorema 3.3.1 (Lei da Probabilidade Total): Sejam $A_1, A_2, \dots, A_n$ eventos disjuntos 2 a 2, ou seja, $A_i \cap A_j = \emptyset$ para $i \neq j$ e $\bigcup_{i=1}^n A_i = S$ onde S é o espaço amostral, então para qualquer evento B , desde que $\mathbb{P}(A_i)$ e $\mathbb{P}(B|A_i)$ existam e sejam conhecidos, temos que

$$\mathbb{P}(B) = \sum_{i=1}^n \mathbb{P}(B | A_i) \cdot \mathbb{P}(A_i) \quad (53)$$

Demonstração:

$$\begin{aligned} \mathbb{P}(B) &= \mathbb{P}(B \cap S) \\ &= \mathbb{P}(B \cap (A_1 \cup A_2 \cup \dots \cup A_n)) \\ &= \mathbb{P}((B \cap A_1) \cup (B \cap A_2) \cup \dots \cup (B \cap A_n)) \\ &= \mathbb{P}(B \cap A_1) + \mathbb{P}(B \cap A_2) + \dots + \mathbb{P}(B \cap A_n) \\ &= \mathbb{P}(B | A_1) \cdot \mathbb{P}(A_1) + \dots + \mathbb{P}(B | A_n) \cdot \mathbb{P}(A_n) \end{aligned} \quad (54)$$

□

Esse evento é muito útil quando temos informações sobre outros eventos, mas não temos sobre o evento objetivo que gostaríamos de conhecer. Como vimos no exemplo da malária, nós tínhamos informações sobre a probabilidade de um teste dar positivo dado que a pessoa estava doente, mas não tínhamos informações sobre a probabilidade total do teste dar positivo, e para calcular isso, usamos a lei da probabilidade total.

Conseguimos expandir esse teorema para o caso de múltiplas condições, mas antes de fazer isso, vamos enunciar um teorema que vai nos ajudar a fazer isso.

Teorema 3.3.2 (Equivalência probabilística do condicionamento): A função $\tilde{\mathbb{P}}(A) = \mathbb{P}(A|E)$ com E sendo um evento possível qualquer, é uma probabilidade.

Demonstração: Para que a função seja uma probabilidade, ela precisa estar sujeita aos axiomas da probabilidade, ou seja, ela precisa satisfazer as seguintes condições:

1. $\tilde{\mathbb{P}}(S) = 1$
2. $\tilde{\mathbb{P}}(A) \geq 0$
3. $\tilde{\mathbb{P}}\left(\bigcup_{j=1}^n A_j\right) = \sum_{j=1}^n \tilde{\mathbb{P}}(A_j)$

Provando $\tilde{\mathbb{P}}(S) = 1$: Se sabemos que o evento E ocorreu, então nosso espaço amostral é reduzido para **todos os eventos em que E ocorreu**, ou seja, o nosso espaço amostral vira E .

$$\tilde{\mathbb{P}}(E) = \mathbb{P}(E|E) = \frac{\mathbb{P}(E \cap E)}{\mathbb{P}(E)} = \frac{\mathbb{P}(E)}{\mathbb{P}(E)} = 1 \quad (55)$$

Provando $\tilde{\mathbb{P}}(A) \geq 0$: Pela definição de probabilidade condicional, temos que

$$\tilde{\mathbb{P}}(A) = \mathbb{P}(A|E) = \frac{\mathbb{P}(A \cap E)}{\mathbb{P}(E)} \quad (56)$$

como a função de cima e a de baixo são maiores que 0, a divisão inteira será maior que 0.

Provando $\tilde{\mathbb{P}}\left(\bigcup_{j=1}^n A_j\right) = \sum_{j=1}^n \tilde{\mathbb{P}}(A_j)$: Pela definição de probabilidade condicional, temos que

$$\begin{aligned} \tilde{\mathbb{P}}\left(\bigcup_{j=1}^n A_j\right) &= \mathbb{P}\left(\bigcup_{j=1}^n A_j \mid E\right) \\ &= \frac{\mathbb{P}\left(\left(\bigcup_{j=1}^n A_j\right) \cap E\right)}{\mathbb{P}(E)} \\ &= \frac{\mathbb{P}\left(\bigcup_{j=1}^n (A_j \cap E)\right)}{\mathbb{P}(E)} \\ &= \frac{\sum_{j=1}^n \mathbb{P}(A_j \cap E)}{\mathbb{P}(E)} \\ &= \sum_{j=1}^n \frac{\mathbb{P}(A_j \cap E)}{\mathbb{P}(E)} \\ &= \sum_{j=1}^n \tilde{\mathbb{P}}(A_j) \end{aligned} \quad (57)$$

□

Com esse teorema, podemos expandir a lei da probabilidade total

Teorema 3.3.3 (Lei da Probabilidade Total com Condicionamento Extra): Sejam $A_1, A_2, \dots, A_n$ eventos disjuntos 2 a 2, ou seja, $A_i \cap A_j = \emptyset$ para $i \neq j$ e $\bigcup_{i=1}^n A_i = S$ onde S é o espaço amostral, então para qualquer evento B e E , desde que $\mathbb{P}(A_i|E)$ e $\mathbb{P}(B|A_i \cap E)$ existam e sejam conhecidos, temos que

$$\mathbb{P}(B \mid E) = \sum_{i=1}^n \mathbb{P}(B \mid A_i \cap E) \cdot \mathbb{P}(A_i \mid E) \quad (58)$$

Demonstração: Pelo Teorema 3.3.2, podemos renomear $\tilde{\mathbb{P}}(B) = \mathbb{P}(B|E)$, então podemos aplicar a lei da probabilidade total para essa função, ou seja, temos que

$$\begin{aligned} \tilde{\mathbb{P}}(B) &= \sum_{i=1}^n \tilde{\mathbb{P}}(B \mid A_i) \cdot \tilde{\mathbb{P}}(A_i) \\ &\Leftrightarrow \\ \mathbb{P}(B \mid E) &= \sum_{i=1}^n \mathbb{P}(B \mid A_i \cap E) \cdot \mathbb{P}(A_i \mid E) \end{aligned} \quad (59)$$

□

Esse teorema nos permite utilizar a lei da probabilidade total em problemas mais complexos e com mais restrições.

Variáveis Aleatórias Discretas

4.1 Experimentos Aleatórios

Dentro de um experimento qualquer, estamos a todo momento medindo quantidades, como por exemplo, o número de vezes que um dado caiu em 6, ou o número de vezes que uma moeda caiu em **cara**. Essas quantidades são chamadas de **variáveis aleatórias**.

Definição 4.1.1 (Variável Aleatória Discreta): Uma variável aleatória discreta é uma função $X : S \rightarrow \mathbb{R}$ que associa a cada resultado do espaço amostral S um número real $\mathbb{R}$ e tal que o conjunto de valores assumidos por X ,

$$\text{Im}(X) = \{X(s) : s \in S\} \quad (60)$$

é **finito** ou **enumerável**.

Exemplo: Dado um experimento de jogar uma moeda honesta 3 vezes, poderíamos ter as seguintes variáveis aleatórias discretas:

$$\begin{aligned} X &= \text{número de caras} \\ Y &= \text{número de transições de cara para coroa} \end{aligned} \quad (61)$$

O nome de **aleatório** não vem do número em si, mas vem da **naturaza do experimento** conter aleatoriedade

4.2 Função de Massa

É a função que descreve a probabilidade de cada valor que a variável aleatória discreta pode assumir. Por exemplo, se eu jogo uma moeda honesta 3 vezes, a variável aleatória X que mede o número de caras pode assumir os valores 0, 1, 2 e 3. A função de massa de probabilidade vai me dizer qual a probabilidade de cada um desses valores ocorrer.

Definição 4.2.1 (Função de Massa de Probabilidade (PMF)): A função de massa de probabilidade (ou PMF) de uma variável aleatória discreta X é uma função $p_X : \mathbb{R} \rightarrow [0, 1]$ definida por

$$p_X(x) = \mathbb{P}(X = x) \quad (62)$$

para todo $x \in \mathbb{R}$. A função de massa de probabilidade satisfaz as seguintes propriedades:

1. $p_X(x) \geq 0$ para todo $x \in \mathbb{R}$
2. $\sum_{x \in \text{Im}(X)} p_X(x) = 1$

Outra função de massa muito importante é a que descreve o comportamento de múltiplas variáveis aleatórias conjuntamente

Definição 4.2.2 (Função de Massa Conjunta): Sejam $X_1, \dots, X_n$ variáveis aleatórias discretas, a função de massa conjunta é uma função $p_{X_1, \dots, X_n} : \mathbb{R}^n \rightarrow [0, 1]$ definida por

$$p_{X_1, \dots, X_n}(x_1, \dots, x_n) = \mathbb{P}(X_1 = x_1, \dots, X_n = x_n) \quad (63)$$

Definição 4.2.3 (Função de Massa Condicional): Sejam $X_1, \dots, X_n$ variáveis aleatórias discretas e Y uma variável aleatória discreta, a função de massa condicional é uma função $p_{X_1, \dots, X_n|Y} : \mathbb{R}^n \rightarrow [0, 1]$ definida por

$$p_{X_1, \dots, X_n|Y}(x_1, \dots, x_n|y) = \mathbb{P}(X_1 = x_1, \dots, X_n = x_n|Y = y) \quad (64)$$

Ela descreve a probabilidade de cada combinação de valores que as variáveis aleatórias podem assumir. Por exemplo, se eu jogo uma moeda honesta 3 vezes e defino as variáveis

$$X = \text{número de caras} \quad Y = \text{número de coroas} \quad (65)$$

e eu gostaria de saber $\mathbb{P}(X = 2, Y = 0)$. A função de massa me retornaria 0, afinal, eu não posso ter 3 caras e 0 coroas ao mesmo tempo. Já se eu quisesse saber $\mathbb{P}(X = 2, Y = 1)$, a função de massa me retornaria $3/8$, afinal, existem 3 maneiras de ter 2 caras e 1 coroa em 3 jogadas, e o total de possibilidades é 8.

Perceba que ao saber o valor de Y no exemplo acima, isso me dá algum tipo de informação sobre o valor de X ! Isso me é um indicativo que X e Y **não são independentes**. Será que a função de massa pode nos ajudar a descobrir se duas variáveis aleatórias são independentes?

Definição 4.2.4 (Independência de Variáveis Aleatórias): Duas variáveis aleatórias X e Y são independentes se, e somente se, a função de massa conjunta for igual ao produto das funções de massa marginais:

$$p_{X,Y}(x, y) = p_X(x) \cdot p_Y(y) \quad (66)$$

para todos x e y .

Corolário 3.3.3.1 (Independência por Condicionalidade):

$$X \text{ e } Y \text{ são independentes} \Leftrightarrow \mathbb{P}(X = x|Y = y) = \mathbb{P}(X = x) \quad (67)$$

Por que uma definição e não um teorema? Isso vem diretamente da teoria dos conjuntos e definições de probabilidade em conjuntos que vimos anteriormente! Inclusive, muitos teoremas se estendem para cá!

Teorema 4.2.1 (Lei da Probabilidade Total):

$$\begin{aligned} \mathbb{P}(X = x) &= \sum_y \mathbb{P}(X = x|Y = y) \cdot \mathbb{P}(Y = y) \\ &= \sum_y \mathbb{P}(X = x, Y = y) \end{aligned} \quad (68)$$

4.3 Transformações sobre as variáveis

Esse tema é bem profundo, mas agora no início, nós vamos ver algumas transformações básicas que podem ser aplicadas em variáveis aleatórias e **como** elas influenciam nas probabilidades dos eventos. Para os casos abaixo, considere X e Y variáveis aleatórias.

- $a \cdot X$ com $a \in \mathbb{R}$: Se a imagem de X é $x_1, \dots, x_n$, então a imagem de $a \cdot X$ é $a \cdot x_1, \dots, a \cdot x_n$. A função de massa de probabilidade de $a \cdot X$ é dada por

$$p_{a \cdot X}(a \cdot x) = p_X(x) \quad (69)$$

ou seja, as probabilidades não mudam, apenas os valores que a variável aleatória pode assumir.

- $X + b$ com $b \in \mathbb{R}$: Se a imagem de X é $x_1, \dots, x_n$, então a imagem de $X + b$ é $x_1 + b, \dots, x_n + b$. A função de massa de probabilidade de $X + b$ é dada por

$$p_{X+b}(x + b) = p_X(x) \quad (70)$$

ou seja, as probabilidades não mudam, apenas os valores que a variável aleatória pode assumir.

- $X + Y$: Se a imagem de X é $x_1, \dots, x_n$ e a imagem de Y é $y_1, \dots, y_m$, então a imagem de $X + Y$ é $x_1 + y_1, \dots, x_n + y_m$. A função de massa de probabilidade de $X + Y$ pode ser calculada analiticamente, no entanto, não será o foco nesse momento. Como os problemas nessa etapa são simples, podemos calcular o novo espaço amostral de $X + Y$ manualmente e calcular as probabilidades com base nas probabilidades de X e Y . Esse raciocínio se aplica a qualquer função $g(X, Y)$

4.4 Função Acumulada

A função de distribuição acumulada (CDF) calcula a probabilidade do valor mostrado pela variável ser menor que um x .

Definição 4.4.1 (Função de Distribuição Acumulada (CDF)): A função de distribuição acumulada (CDF) de uma variável aleatória discreta X é uma função $F_X : \mathbb{R} \rightarrow [0, 1]$ definida por

$$F_X(x) = \mathbb{P}(X \leq x) \quad (71)$$

para todo $x \in \mathbb{R}$. A função de distribuição acumulada satisfaz as seguintes propriedades:

1. $F_X(x)$ é não decrescente
2. $\lim_{x \rightarrow -\infty} F_X(x) = 0$
3. $\lim_{x \rightarrow \infty} F_X(x) = 1$

Essa função pode não parecer super útil no momento, mas ela é muito útil para calcular probabilidades de intervalos, por exemplo, se eu quero saber a probabilidade de X estar entre a e b !

Teorema 4.4.1:

$$\mathbb{P}(a < X \leq b) = F_X(b) - F_X(a) \quad (72)$$

Esperança, Medidas de Dispersão e Quantificadores de Independência

5.1 O Valor Médio

Em problemas cotidianos, muitas vezes gostamos de fazer a pergunta “Quanto eu ganho em média?”, “Quanto eu perco em média?”, “Quantos pontos eu consigo em média?”, ... A esperança matemática é justamente a resposta para essa pergunta, ela nos dá o valor médio esperado de uma variável aleatória, que intuitivamente seria o valor que, se eu fosse chutar que cairia, seria o valor que eu chutaria. Por exemplo, se eu tenho uma contagem de caras e coroas em n jogadas, eu com certeza chutaria que cairiam $n/2$ caras e $n/2$ coroas, afinal, a moeda é honesta.

Definição 5.1.1 (Esperança de uma Variável Aleatória Discreta): A esperança de uma variável aleatória discreta X é definida por

$$\mathbb{E}[X] = \sum_x x \cdot \mathbb{P}(X = x) \quad (73)$$

A esperança existe desde que a soma esteja bem definida (existem casos que ela pode divergir e não existe um valor de esperança).

5.1.1 Law of the Unconscious Statistician

Esse teorema é nomeado de forma a tirar sarro de estatísticos. Acontece que, se você tem uma variável aleatória X e uma função g , ao fazer $g(X)$, você pode pensar de forma inocente, que

$$\mathbb{E}[g(X)] = \sum_x g(x) \cdot \mathbb{P}(X = x) \quad (74)$$

mas isso na verdade está **corretíssimo**, acontece que a demonstração desse teorema é mais complexa, mas o seu resultado intuitivo está **correto**

Teorema 5.1.1.1 (Law of the Unconscious Statistician (LOTUS)): Sejam X uma variável aleatória discreta e g uma função, então

$$\mathbb{E}[g(X)] = \sum_x g(x) \cdot \mathbb{P}(X = x) \quad (75)$$

Demonstração: Pensando numa demonstração **não rigorosa**, mas intuitiva, podemos pensar que, para encontrar a probabilidade de um $z = g(x)$ ocorrer, precisamos encontrar todos os valores de x que vão gerar aquele z . O somatório faz isso em cima dos locais corretos e soma $zp(z)$

$$\begin{aligned} \mathbb{E}[Z] &= \sum_z z \mathbb{P}(Z = z) = \sum_z z \left(\sum_{g(x)=z} \mathbb{P}(X = x) \right) \\ &= \sum_z \sum_{g(x)=z} z \mathbb{P}(X = x) \\ &= \sum_z \sum_{g(x)=z} g(x) \mathbb{P}(X = x) \\ &= \sum_x g(x) \mathbb{P}(X = x) \end{aligned} \quad (76)$$

□

Corolário 5.1.1.1 (*Linearidade da Esperança*): A esperança é linear, ou seja, para quaisquer constantes a e b e variáveis aleatórias X e Y , temos

$$\mathbb{E}[aX + bY] = a\mathbb{E}[X] + b\mathbb{E}[Y] \quad (77)$$

Demonstração:

$$\begin{aligned} \mathbb{E}[aX + bY] &= \sum_{x,y} (ax + by) \cdot \mathbb{P}(X = x, Y = y) \\ &= \sum_{x,y} ax \cdot \mathbb{P}(X = x, Y = y) + \sum_{x,y} by \cdot \mathbb{P}(X = x, Y = y) \\ &= a \sum_x x \sum_y \cdot \mathbb{P}(X = x, Y = y) + b \sum_y y \sum_x \cdot \mathbb{P}(X = x, Y = y) \end{aligned} \quad (78)$$

Pela lei da probabilidade total, temos que

$$\begin{aligned} \sum_y \mathbb{P}(X = x, Y = y) &= \mathbb{P}(X = x) \\ \sum_x \mathbb{P}(X = x, Y = y) &= \mathbb{P}(Y = y) \end{aligned} \quad (79)$$

Logo:

$$\begin{aligned} \mathbb{E}[aX + bY] &= a \sum_x x \cdot \mathbb{P}(X = x) + b \sum_y y \cdot \mathbb{P}(Y = y) \\ &= a\mathbb{E}[X] + b\mathbb{E}[Y] \end{aligned} \quad (80)$$

□

Teorema 5.1.1.2 (LOTUS com duas variáveis): Sejam X e Y variáveis aleatórias discretas e g uma função, então

$$\mathbb{E}[g(X, Y)] = \sum_{x,y} g(x, y) \cdot \mathbb{P}(X = x, Y = y) \quad (81)$$

Demonstração: Fazendo uma demonstração não rigorosa, mas intuitiva, podemos pensar que, para encontrar a probabilidade de um $z = g(x, y)$ ocorrer, precisamos encontrar todos os valores de x e y que vão gerar aquele z . O somatório faz isso em cima dos locais corretos e soma $zp(z)$

$$\begin{aligned} \mathbb{E}[Z] &= \sum_z z \mathbb{P}(Z = z) = \sum_z z \left(\sum_{g(x,y)=z} \mathbb{P}(X = x, Y = y) \right) \\ &= \sum_z \sum_{g(x,y)=z} z \mathbb{P}(X = x, Y = y) \\ &= \sum_z \sum_{g(x,y)=z} g(x, y) \mathbb{P}(X = x, Y = y) \\ &= \sum_{x,y} g(x, y) \mathbb{P}(X = x, Y = y) \end{aligned} \quad (82)$$

□

5.1.2 Esperança e Independência

A esperança também pode ser afetada pela independência de variáveis aleatórias.

Teorema 5.1.2.1 (Esperança de Variáveis Aleatórias Independentes): Sejam X e Y variáveis aleatórias discretas independentes, então

$$\mathbb{E}[XY] = \mathbb{E}[X] \cdot \mathbb{E}[Y] \quad (83)$$

a volta não vale

Demonstração: Pela definição de independência, temos que

$$\mathbb{P}(X = x, Y = y) = \mathbb{P}(X = x) \cdot \mathbb{P}(Y = y) \quad (84)$$

então

$$\begin{aligned} \mathbb{E}[XY] &= \sum_{x,y} xy \cdot \mathbb{P}(X = x, Y = y) \\ &= \sum_{x,y} xy \cdot \mathbb{P}(X = x) \cdot \mathbb{P}(Y = y) \\ &= \sum_x x \cdot \mathbb{P}(X = x) \sum_y y \cdot \mathbb{P}(Y = y) \\ &= \mathbb{E}[X] \cdot \mathbb{E}[Y] \end{aligned} \quad (85)$$

Um contra exemplo para o caso contrário são as variáveis X e Y tais que

$$\mathbb{P}(X = 1, Y = 1) = \frac{1}{2} \quad \mathbb{P}(X = -1, Y = -1) = \frac{1}{2} \quad (86)$$

aqui conseguimos ver que

$$\mathbb{E}[X] = \mathbb{E}[Y] = 0 \quad (87)$$

no entanto

$$\mathbb{E}[XY] = 1 \quad (88)$$

pois $X \cdot Y$ é sempre 1 □

5.1.3 Monotonicidade da Esperança

Teorema 5.1.3.1 (Monotonicidade da Esperança): Sejam X e Y variáveis aleatórias discretas, se $X \geq Y$, então

$$\mathbb{E}[X] \geq \mathbb{E}[Y] \quad (89)$$

Demonstração: Como $X \geq Y$, temos que $X - Y \geq 0$, então

$$\mathbb{E}[X - Y] \geq 0 \Leftrightarrow \mathbb{E}[X] - \mathbb{E}[Y] \geq 0 \Leftrightarrow \mathbb{E}[X] \geq \mathbb{E}[Y] \quad (90)$$

□

5.1.4 Função de Sobrevivência

Conseguimos expressar a esperança em termos da função de sobrevivência, que é a função que nos dá a probabilidade de uma variável aleatória ser maior que um certo valor.

Definição 5.1.4.1 (Função de Sobrevivência): A função de sobrevivência de uma variável aleatória discreta X é uma função $G_X : \mathbb{R} \rightarrow [0, 1]$ definida por

$$G_X(x) = \mathbb{P}(X > x) \quad (91)$$

para todo $x \in \mathbb{R}$. A função de sobrevivência satisfaz as seguintes propriedades:

1. $G_X(x)$ é não crescente
2. $\lim_{x \rightarrow -\infty} G_X(x) = 1$
3. $\lim_{x \rightarrow \infty} G_X(x) = 0$

Teorema 5.1.4.1 (Esperança em termos da Função de Sobrevivência): Sejam X uma variável aleatória discreta não negativa, então

$$\mathbb{E}[X] = \sum_{x=0}^{\infty} G_X(x) \quad (92)$$

Demonstração: Seja I_j a variável aleatória definida como:

$$I_j = \begin{cases} 1 & X \geq j \\ 0 & X < j \end{cases} \quad (93)$$

conseguimos decompor a variável aleatória X como

$$X = \sum_{j=1}^{\infty} I_j \quad (94)$$

por exemplo, se $X = 3$, então $I_1 = I_2 = I_3 = 1$ e $I_j = 0$ para $j > 3$. Então a esperança de X será

$$\mathbb{E}[X] = \mathbb{E}\left[\sum_{j=1}^{\infty} I_j\right] = \sum_{j=1}^{\infty} \mathbb{E}[I_j] \quad (95)$$

Agora só precisamos mostrar que $\mathbb{E}[I_j] = \mathbb{P}(X \geq j)$. Pela definição de I_j , sua esperança será

$$\mathbb{E}[I_j] = 1 \cdot \mathbb{P}(I_j = 1) + 0 \cdot \mathbb{P}(I_j = 0) = \mathbb{P}(I_j = 1) = \mathbb{P}(X \geq j) \quad (96)$$

logo

$$\mathbb{E}[X] = \sum_{j=1}^{\infty} \mathbb{P}(X \geq j) = \sum_{x=0}^{\infty} G_X(x) \quad (97)$$

□

5.2 Medidas de Dispersão

Essas medidas nos ajudam a entender o quanto os valores da variável aleatória estão espalhados em torno da média. Se a esperança nos dá o valor que esperamos que a variável aleatória assuma,

as medidas de dispersão nos dizem o quão “*bem comportadas*” essas variáveis são, elas se concentram perto da média? Ou elas se espalham em vários lugares?

Definição 5.2.1 (Desvio Médio): O desvio médio de uma variável aleatória discreta X é definido por

$$DM[X] = \mathbb{E}[|X - \mathbb{E}[X]|] \quad (98)$$

Definição 5.2.2 (Variância): A variância de uma variável aleatória discreta X é definida por

$$\mathbb{V}[X] = \mathbb{E}[(X - \mathbb{E}[X])^2] \quad (99)$$

Definição 5.2.3 (Desvio Padrão): O desvio padrão de uma variável aleatória discreta X é definido por

$$\sigma[X] = \sqrt{\mathbb{V}[X]} \quad (100)$$

5.2.1 Propriedades

A variância e o desvio padrão são as medidas de dispersão mais utilizadas. Vamos enunciar e demonstrar algumas propriedades dessas medidas de dispersão.

Teorema 5.2.1.1:

$$\mathbb{V}[aX + b] = a^2 \mathbb{V}[X] \quad (101)$$

Demonstração:

$$\begin{aligned} \mathbb{V}[aX + b] &= \mathbb{E}[(aX + b - \mathbb{E}[aX + b])^2] \\ &= \mathbb{E}[(aX + b - (a\mathbb{E}[X] + b))^2] \\ &= \mathbb{E}[(aX - a\mathbb{E}[X])^2] \\ &= \mathbb{E}[a^2(X - \mathbb{E}[X])^2] \\ &= a^2 \mathbb{E}[(X - \mathbb{E}[X])^2] \\ &= a^2 \mathbb{V}[X] \end{aligned} \quad (102)$$

□

Teorema 5.2.1.2:

$$\sigma[aX + b] = |a| \sigma[X] \quad (103)$$

Demonstração: Pela propriedade anterior, temos que

$$\sigma[aX + b] = \sqrt{\mathbb{V}[aX + b]} = \sqrt{a^2 \mathbb{V}[X]} = |a| \sqrt{\mathbb{V}[X]} = |a| \sigma[X] \quad (104)$$

□

Teorema 5.2.1.3:

$$\text{DM}[aX + b] = |a| \text{DM}[X] \quad (105)$$

Demonstração: Pela definição de desvio médio, temos que

$$\begin{aligned} \text{DM}[aX + b] &= \mathbb{E}[|aX + b - \mathbb{E}[aX + b]|] \\ &= \mathbb{E}[|aX + b - (a\mathbb{E}[X] + b)|] \\ &= \mathbb{E}[|aX - a\mathbb{E}[X]|] \\ &= \mathbb{E}[|a| |X - \mathbb{E}[X]|] \\ &= |a| \mathbb{E}[|X - \mathbb{E}[X]|] \\ &= |a| \text{DM}[X] \end{aligned} \quad (106)$$

□

Intuitivamente, quando nós adicionamos uma constante b em uma variável, a média vai se descolar esse exato mesmo valor, no entanto, como todos os pontos vão se mover exatamente b unidades, a dispersão vai se manter a mesma. No entanto, se multiplicarmos a variável por uma constante a , os erros que já existiam vão se ampliar em a vezes, então a dispersão vai se multiplicar por a também.

Teorema 5.2.1.4:

$$\mathbb{V}[X] = \mathbb{E}[X^2] - (\mathbb{E}[X])^2 \quad (107)$$

Demonstração:

$$\begin{aligned} \mathbb{V}[X] &= \mathbb{E}[(X - \mathbb{E}[X])^2] \\ &= \mathbb{E}[X^2 - 2X\mathbb{E}[X] + (\mathbb{E}[X])^2] \\ &= \mathbb{E}[X^2] - 2\mathbb{E}[X]\mathbb{E}[X] + (\mathbb{E}[X])^2 \\ &= \mathbb{E}[X^2] - (\mathbb{E}[X])^2 \end{aligned} \quad (108)$$

□

Teorema 5.2.1.5: Se X e Y são variáveis aleatórias independentes, então

$$\mathbb{V}[X + Y] = \mathbb{V}[X] + \mathbb{V}[Y] \quad (109)$$

Demonstração:

$$\begin{aligned}
\mathbb{V}[X + Y] &= \mathbb{E}[(X + Y)^2] - (\mathbb{E}[X + Y])^2 \\
&= \mathbb{E}[X^2 + 2XY + Y^2] - (\mathbb{E}[X] + \mathbb{E}[Y])^2 \\
&= \mathbb{E}[X^2] + 2\mathbb{E}[XY] + \mathbb{E}[Y^2] - (\mathbb{E}[X])^2 - 2\mathbb{E}[X]\mathbb{E}[Y] - (\mathbb{E}[Y])^2 \\
&= \mathbb{E}[X^2] + 2\mathbb{E}[X]\mathbb{E}[Y] + \mathbb{E}[Y^2] - (\mathbb{E}[X])^2 - 2\mathbb{E}[X]\mathbb{E}[Y] - (\mathbb{E}[Y])^2 \\
&= \mathbb{E}[X^2] - (\mathbb{E}[X])^2 + \mathbb{E}[Y^2] - (\mathbb{E}[Y])^2 \\
&= \mathbb{V}[X] + \mathbb{V}[Y]
\end{aligned} \tag{110}$$

□

5.2.2 Desigualdade de Chebyshev

Essa desigualdade nos dá uma generalização da probabilidade estar distante de sua média. Vamos ver o teorema e sua demonstração, depois nós elaboramos mais

Teorema 5.2.2.1 (Desigualdade de Chebyshev): Sejam X uma variável aleatória discreta com média $\mathbb{E}[X] = \mu$ e desvio padrão $\sigma = \sigma[X]$. Denote $P = \{x \in \mathbb{R} \mid |x - \mu| < k\sigma\}$, ou seja, P é o intervalo aberto $(x - k\sigma, x + k\sigma)$. Então, para qualquer $k > 0$, temos que

$$\mathbb{P}(X \notin P) \leq \frac{1}{k^2} \equiv \mathbb{P}(|X - \mu| \geq k\sigma) \leq \frac{1}{k^2} \tag{111}$$

Demonstração:

$$\begin{aligned}
\mathbb{V}[X] &= \mathbb{E}[(X - \mu)^2] \\
&= \sum_x (x - \mu)^2 \cdot \mathbb{P}(X = x) \\
&= \sum_{x \in P} (x - \mu)^2 \cdot \mathbb{P}(X = x) + \sum_{x \notin P} (x - \mu)^2 \cdot \mathbb{P}(X = x)
\end{aligned} \tag{112}$$

por conta da definição dos x no intervalo P , temos que, para valores de x que **não estão** no intervalo:

$$\begin{aligned}
|x - \mu| &\geq k\sigma \\
(x - \mu)^2 &\geq k^2\sigma^2
\end{aligned} \tag{113}$$

logo, como a primeira parte da soma é maior que 0, podemos fazer:

$$\begin{aligned}
\mathbb{V}[X] &\geq \sum_{x \notin P} \sigma^2 k^2 \cdot \mathbb{P}(X = x) \\
\sigma^2 &\geq \sigma^2 k^2 \sum_{x \notin P} \mathbb{P}(X = x) \\
1 &\geq k^2 \mathbb{P}(X \notin P) \\
\frac{1}{k^2} &\geq \mathbb{P}(X \notin P)
\end{aligned} \tag{114}$$

□

Como interpretamos esse teorema então?

- Existe no máximo $\frac{1}{4}$ de chance de uma variável aleatória estar a mais de 2 desvios padrões da média

- Existe no máximo $\frac{1}{9}$ de chance de uma variável aleatória estar a mais de 3 desvios padrões da média
- Existe no máximo $\frac{1}{16}$ de chance de uma variável aleatória estar a mais de 4 desvios padrões da média

E assim em diante para um k qualquer. Ou seja, ele atribui uma probabilidade máxima de o quão bem comportada a variável aleatória é, ou seja, o quão concentrada ela está em torno da média. Quanto maior o k , mais difícil é que os valores da variável aleatória estejam distantes. Isso também mostra uma quantificação de **valores extremos**. Por exemplo, é **muito improvável** que, ao jogar uma moeda honesta 100 vezes, eu consiga 90 caras. A desigualdade de chebyshev nos dá justamente uma formalização da intuição de que, quanto mais distante da média, mais improvável é que o evento ocorra.

5.3 Quantificadores de Independência

A independência de variáveis aleatórias é um conceito muito importante, mas como podemos quantificar o quão independentes duas variáveis aleatórias são?

Definição 5.3.1 (Covariância): A covariância de duas variáveis aleatórias discretas X e Y é definida por

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])] \quad (115)$$

Sabemos que $X - \mathbb{E}[X]$ é a distância dos valores de X até sua média. Quando isso é maior ou igual a 0, então a maioria dos valores está acima da média. Quando multiplicamos isso por $Y - \mathbb{E}[Y]$, se o valor for positivo e grande, é um indicativo que, conforme X está acima da média, Y **também está** acima da média. Se o valor for negativo e grande, é um indicativo que, conforme X está acima da média, Y **está abaixo** da média. Se o valor for próximo de 0, então não há uma relação clara entre as duas variáveis aleatórias.

Teorema 5.3.1:

$$\text{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X] \cdot \mathbb{E}[Y] \quad (116)$$

Demonstração:

$$\begin{aligned} \text{Cov}(X, Y) &= \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])] \\ &= \mathbb{E}[XY - X\mathbb{E}[Y] - Y\mathbb{E}[X] + \mathbb{E}[X]\mathbb{E}[Y]] \\ &= \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y] - \mathbb{E}[Y]\mathbb{E}[X] + \mathbb{E}[X]\mathbb{E}[Y] \\ &= \mathbb{E}[XY] - \mathbb{E}[X] \cdot \mathbb{E}[Y] \end{aligned} \quad (117)$$

□

Temos um teorema muito importante que relaciona a covariância com a independência de variáveis aleatórias.

Teorema 5.3.2:

$$X \text{ e } Y \text{ são independentes} \Rightarrow \text{Cov}(X, Y) = 0 \quad (118)$$

a volta não vale

Demonstração: Pelo Teorema 5.3.1, temos que

$$\text{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X] \cdot \mathbb{E}[Y] \quad (119)$$

como sabemos que X e Y são independentes, então $\mathbb{E}[XY] = \mathbb{E}[X] \cdot \mathbb{E}[Y]$, e portanto:

$$\text{Cov}(X, Y) = \mathbb{E}[X] \cdot \mathbb{E}[Y] - \mathbb{E}[X] \cdot \mathbb{E}[Y] = 0 \quad (120)$$

.

Agora se analisarmos a volta, vamos supor que $X = \{1, 0, -1\}$ e $Y = X^2$ de forma que $\mathbb{P}(X = i) = \frac{1}{3}$ para $i = 1, 0, -1$. Conseguimos ver que $\mathbb{E}[X] = 0$ e $\mathbb{E}[XY] = \mathbb{E}[X^3] = 0$, logo, temos que

$$\text{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X] \cdot \mathbb{E}[Y] = 0 - 0 \cdot \mathbb{E}[Y] = 0 \quad (121)$$

No entanto, vamos checar a condição de independência:

$$\begin{aligned} \mathbb{P}(X = 0, Y = 0) &= \mathbb{P}(X = 0) = \frac{1}{3} \\ \mathbb{P}(X = 0) \cdot \mathbb{P}(Y = 0) &= \frac{1}{3} \cdot \frac{1}{3} = \frac{1}{9} \end{aligned} \quad (122)$$

logo, X e Y **não são independentes** □

A covariância é muito útil, mas ela tem um problema, a **escala**. Vamos ver isso na prática com alguns exemplos

Exemplo: Sejam X a altura de uma população e Y o peso dessa população. Se X é medido em m e Y em kg , poderíamos obter uma covariância de

$$\text{Cov}(X, Y) = 0.7 \text{ m} \cdot \text{kg} \quad (123)$$

No entanto, se mudarmos a unidade de medida de X para cm e Y para g , teríamos

$$\text{Cov}(100 \cdot X, 1000 \cdot Y) = 100 \cdot 1000 \text{ Cov}(X, Y) = 70000 \text{ cm} \cdot \text{g} \quad (124)$$

Essas covariâncias representam a **mesma relação**, mas os números são completamente diferentes. Enquanto o primeiro aparenta ser uma correlação baixa, o segundo aparenta ser uma correlação altíssima.

Para resolver esses problemas de escala e dificuldade de interpretabilidade, nós utilizamos uma outra medida, a **correlação**.

Definição 5.3.2 (Correlação): A correlação de duas variáveis aleatórias discretas X e Y é definida por

$$\rho(X, Y) = \frac{\text{Cov}(X, Y)}{\sigma[X] \cdot \sigma[Y]} \quad (125)$$

A principal vantagem da correlação é que ela é **adimensional**, ou seja, ela não depende da unidade de medida das variáveis aleatórias. Além de se situar no intervalo $[-1, 1]$. Antes de provarmos algumas de suas propriedades (juntamente com a covariância), vamos definir ambas com um pouco de **álgebra linear**. Vamos definir a covariância como um **produto interno**.

Teorema 5.3.3 (Covariância como Produto Interno): Sejam X e Y variáveis aleatórias discretas, então a covariância entre X e Y pode ser interpretada como o produto interno entre dois vetores.

Demonstração: Sejam $X = \{x_i\}_{i=1}^m$ e $Y = \{y_i\}_{i=1}^n$, defina a matriz de probabilidade:

$$\begin{pmatrix} p_{11} & p_{12} & \cdots & p_{1n} \\ p_{21} & p_{22} & \cdots & p_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ p_{m1} & p_{m2} & \cdots & p_{mn} \end{pmatrix} \quad (126)$$

de forma que $\mathbb{P}(X = x_i, Y = y_j) = p_{ij}$. Defina também os vetores

$$\begin{aligned} v_X &= (x_1 \ x_1 \ \cdots \ x_1 \ x_2 \ x_2 \ \cdots \ x_2 \ \cdots \ x_m \ x_m \ \cdots \ x_m)^T \\ v_Y &= (y_1 \ y_2 \ \cdots \ y_n \ y_1 \ y_2 \ \cdots \ y_n \ \cdots \ y_1 \ y_2 \ \cdots \ y_n)^T \end{aligned} \quad (127)$$

e os vetores **resíduos**

$$\begin{aligned} r_X &= v_X - \mathbb{E}[X] \cdot \mathbb{1} \\ r_Y &= v_Y - \mathbb{E}[Y] \cdot \mathbb{1} \end{aligned} \quad (128)$$

onde $\mathbb{1}$ é o vetor coluna de números 1 do tamanho do vetor v_X e v_Y . Vamo definir $\omega(x, y)$ como o seguinte produto interno:

$$\omega(x, y) = \sum_{i,j} x_i y_j p_{ij} \quad (129)$$

segue a demonstração que essa função é um produto interno: Para ela ser um produto interno, é necessário satisfazer:

$$\begin{aligned} \omega(x, y) &= \omega(y, x) \\ \omega(\alpha x + \beta y, z) &= \alpha \omega(x, z) + \beta \omega(y, z) \\ \omega(x, x) &\geq 0 \quad \omega(x, x) = 0 \Leftrightarrow x = 0 \end{aligned} \quad (130)$$

Para a primeira condição:

$$\sum_{i,j} x_i y_j p_{ij} = \sum_{j,i} y_j x_i p_{ji} \quad (131)$$

Para a segunda condição:

$$\begin{aligned}
\omega(\alpha x + \beta y, z) &= \sum_{i,j} (\alpha x_i + \beta y_i) z_j p_{ij} \\
&= \sum_{i,j} \alpha x_i z_j p_{ij} + \sum_{i,j} \beta y_i z_j p_{ij} \\
&= \alpha \sum_{i,j} x_i z_j p_{ij} + \beta \sum_{i,j} y_i z_j p_{ij} \\
&= \alpha \omega(x, z) + \beta \omega(y, z)
\end{aligned} \tag{132}$$

Para a terceira condição: Perceba que $\omega(x, y) = \mathbb{E}[XY]$, logo, $\omega(x, x) = \mathbb{E}[X^2] \geq 0$ e é igual a 0 se, e somente se, $X = 0$.

Mostrado que essa função é um produto interno, podemos ver que a covariância é justamente o produto interno entre os vetores de resíduos:

$$\begin{aligned}
\omega(r_X, r_Y) &= \sum_{i,j} (x_i - \mathbb{E}[X])(y_j - \mathbb{E}[Y]) p_{ij} \\
&= \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])] \\
&= \text{Cov}(X, Y)
\end{aligned} \tag{133}$$

□

Agora que sabemos que a covariância é um produto interno, podemos utilizar essa relação para mostrar outras propriedades da covariância

Teorema 5.3.4:

$$\begin{aligned}
\text{Cov}(X, Y) &= \text{Cov}(Y, X) \\
\text{Cov}(X, X) &= \mathbb{V}[X] \\
\text{Cov}(\alpha X + \beta Y, Z) &= \alpha \text{Cov}(X, Z) + \beta \text{Cov}(Y, Z)
\end{aligned} \tag{134}$$

Demonstração: Segue da definição de produto interno

□

Teorema 5.3.5:

$$-1 \leq \rho(X, Y) \leq 1 \tag{135}$$

Demonstração: Utilizando os vetores resíduos que definimos na demonstração do Teorema 5.3.3, temos que

$$\cos \theta = \frac{\omega(r_X, r_Y)}{\|r_X\| \|r_Y\|} = \frac{\text{Cov}(X, Y)}{\sigma[X] \cdot \sigma[Y]} = \rho(X, Y) \tag{136}$$

□

Teorema 5.3.6:

$$\mathbb{V}(X + Y) = \mathbb{V}[X] + \mathbb{V}[Y] + 2 \text{Cov}(X, Y) \quad (137)$$

Demonstração:

$$\begin{aligned} \mathbb{V}[X + Y] &= \mathbb{E}[(X + Y)^2] - (\mathbb{E}[X + Y])^2 \\ &= \mathbb{E}[X^2 + 2XY + Y^2] - (\mathbb{E}[X])^2 - 2\mathbb{E}[X]\mathbb{E}[Y] - (\mathbb{E}[Y])^2 \\ &= \mathbb{E}[X^2] + 2\mathbb{E}[XY] + \mathbb{E}[Y^2] - (\mathbb{E}[X])^2 - 2\mathbb{E}[X]\mathbb{E}[Y] - (\mathbb{E}[Y])^2 \\ &= \mathbb{E}[X^2] - (\mathbb{E}[X])^2 + \mathbb{E}[Y^2] - (\mathbb{E}[Y])^2 + 2(\mathbb{E}[XY] - \mathbb{E}[X] \cdot \mathbb{E}[Y]) \\ &= \mathbb{V}[X] + \mathbb{V}[Y] + 2 \text{Cov}(X, Y) \end{aligned} \quad (138)$$

□

Teorema 5.3.7:

$$\text{Cov}(aX + b, Y) = a \text{Cov}(X, Y) \quad (139)$$

Demonstração:

$$\begin{aligned} \text{Cov}(aX + b, Y) &= \mathbb{E}[(aX + b - \mathbb{E}[aX + b])(Y - \mathbb{E}[Y])] \\ &= \mathbb{E}[(aX + b - (a\mathbb{E}[X] + b))(Y - \mathbb{E}[Y])] \\ &= \mathbb{E}[(aX - a\mathbb{E}[X])(Y - \mathbb{E}[Y])] \\ &= a\mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])] \\ &= a \text{Cov}(X, Y) \end{aligned} \quad (140)$$

□

Teorema 5.3.8:

$$\rho(aX + b, Y) = \begin{cases} \rho(X, Y) & a > 0 \\ -\rho(X, Y) & a < 0 \end{cases} \quad (141)$$

Demonstração:

$$\begin{aligned} \rho(aX + b, Y) &= \frac{\text{Cov}(aX + b, Y)}{\sigma[aX + b] \cdot \sigma[Y]} \\ &= \frac{a \text{Cov}(X, Y)}{|a| \sigma[X] \cdot \sigma[Y]} \end{aligned} \quad (142)$$

e temos que

$$\frac{a}{|a|} = \text{sign}(a) \quad (143)$$

□

Distribuições de Variáveis Aleatórias Disc- retas

