

FGV EMap
João Pedro Jerônimo

Probabilidade

Revisão para A1

Rio de Janeiro
2026

Conteúdo

1	Combinatória	4
1.1	Contagem	5
1.2	Permutação	5
1.3	Arranjos	6
1.4	Combinações	6
1.5	Permutação Circular	7
1.6	Ferramentas de Contagem	8
1.6.1	Tabela Amostral	8
1.6.1.1	Ordem Importa e Reposição	8
1.6.1.2	Ordem Importa e Sem Reposição	8
1.6.1.3	Ordem não Importa e Sem Reposição	8
1.6.1.4	Ordem não Importa e Reposição	9
1.6.2	Identidades Úteis	9
1.7	Contagem do Complementar	10
2	Primeiros passos em Probabilidade	11
2.1	Fundamentos	12
2.1.1	Naive Definition	12
2.1.2	Conjuntos	12
2.2	Propriedades da Probabilidade	13
2.3	Eventos Independentes	15
2.4	Problema do Aniversário	16
3	Probabilidade Condicional	17
3.1	Como o Conhecimento influencia na Probabilidade	18
3.2	Independência	18
3.3	Lei da Probabilidade Total	20
3.4	O Teorema de Bayes	22
3.4.1	Falácia do Promotor	23
4	Variáveis Aleatórias Discretas	25
4.1	Experimentos Aleatórios	26
4.2	Função de Massa	26
4.2.1	Probabilidade Marginal	26
4.2.2	Probabilidade Conjunta	26
4.2.3	Relação entre as funções de massa	27
4.2.3.1	Independência	27
4.2.3.2	Marginalização	28
4.3	Transformações sobre as variáveis	28
4.4	Função Acumulada e de Sobrevivência	29
5	Esperança	30
5.1	O Valor Médio	31
5.2	Law of the Unconscious Statistician	31
5.3	Esperança e Independência	33
5.4	Monotonicidade da Esperança	34
5.5	Função de Sobrevivência	34
6	Medidas de Dispersão	36
6.1	Introdução	37
6.2	Propriedades	37

6.3	Desigualdade de Chebyshev	39
7	Quantificadores de Independência	41
7.1	Quantificadores de Independência	42
7.2	O Problema de Escala da Covariância	43
7.3	Aprofundamento: Covariância como Produto Interno	43
7.4	Propriedades	45
8	Distribuições de Variáveis Aleatórias Discretas	47
8.1	O que é uma distribuição?	48
8.2	Bernoulli	48
8.3	Binomial	48
8.4	Hípergeométrica	51
8.5	Geométrica	53
8.6	Binomial Negativa	55
8.7	Poisson	57

Combinatória

1.1 Contagem

A probabilidade é muito derivada do conceito de contar todas as saídas possíveis de um experimento/teste, por conta disso, é **fundamental** que fiquemos **craques** em contagem. A contagem é uma ferramenta que nos permite organizar e estruturar as possibilidades de um experimento, e assim, calcular a probabilidade de um evento ocorrer (depois vemos como fazer isso). O importante agora é entendermos os principais princípios dessa área da matemática.

Teorema 1.1.1 (Princípio Fundamental da Contagem): Dada uma decisão D_1 com x escolhas, e uma decisão **consecutiva** D_2 com y escolhas, de forma que cada decisão x tomada tem y opções disponíveis, o número total de maneiras de realizar ambas as decisões é $x \cdot y$.

Demonstração: Vamos demonstrar por *indução*. Para uma única etapa (caso base), existem exatamente a_1 opções. Suponha que para n etapas, o número de maneiras de realizar todas as decisões seja $a_1 \cdot \dots \cdot a_n$. Agora vamos adicionar uma nova decisão D_{n+1} com a_{n+1} escolhas. Se visualizarmos as primeiras n decisões como uma única decisão com $a_1 \cdot \dots \cdot a_n$ possibilidades, então o número total de maneiras de realizar todas as decisões é $(a_1 \cdot \dots \cdot a_n) \cdot a_{n+1} = a_1 \cdot \dots \cdot a_n \cdot a_{n+1}$, como queríamos demonstrar. $\square$

Isso nos traz uma estratégia de abordagem de problemas bem definida

- **Postura:** Sempre colocar no papel o que se sabe e o que se quer, e tentar organizar as informações de forma a facilitar a visualização do problema.
- **Divisão:** Sempre que possível, dividir o problema em subproblemas menores, e resolver cada um deles separadamente.
- **Não adiar dificuldades:** Se uma das decisões a serem tomadas for mais restrita que as demais, esta deve ser tomada primeiro, para que as demais decisões possam ser tomadas com mais liberdade.

1.2 Permutação

Usamos a permutação para saber de quantas maneiras podemos organizar um conjunto de elementos de forma ordenada.

Definição 1.2.1 (Permutação de elementos **distintos**): Se temos n elementos distintos, o número de maneiras de organizá-los em uma sequência ordenada é dado por

$$P_n = n! = n \cdot (n - 1) \cdot \dots \cdot 2 \cdot 1 \quad (1)$$

Exemplo: Quantos anagramas existem na palavra “VIDRO”? A palavra “VIDRO” possui 5 letras distintas, então o número de anagramas é $5! = 5 \cdot 4 \cdot 3 \cdot 2 \cdot 1 = 120$.

Mas essa situação é um pouco mais complicada quando temos elementos repetidos, como na palavra “MAMÃO”. Nesse caso, temos 5 letras, mas a letra “A” se repete 2 vezes.

Definição 1.2.2 (Permutação de elementos **distintos**): Se temos n elementos, dos quais n_1 são idênticos, n_2 são idênticos, ..., n_k são idênticos, o número de maneiras de organizá-los em uma sequência ordenada é dado por

$$P_n^{n_1, n_2, \dots, n_k} = \frac{n!}{n_1! \cdot n_2! \cdot \dots \cdot n_k!} \quad (2)$$

Vamos tentar pensar no porquê dessa fórmula! Imagina que eu tenho uma palavra qualquer, e nela eu tenho DUAS letras repetidas. Se eu fixo uma das letras em um lugar, a outra letra pode ir para qualquer posição da palavra. No entanto, se eu fixo a segunda letra, a primeira **também** pode ir para qualquer posição, e eu acabo contando as **mesmas** palavras duas vezes. Por exemplo:

$$ABCA \rightarrow ABCA \quad (3)$$

mesma palavra, mas com as posições do A trocadas, logo, foi contabilizada duas vezes. Se eu tivesse 3 letras repetidas, eu teria contado a mesma palavra $3!$ vezes, e assim por diante. Por isso, para corrigir isso, eu divido pelo fatorial do número de letras repetidas.

Exemplo: Quantos anagramas existem na palavra “MAMÃO”? A palavra “MAMÃO” possui 5 letras, das temos 2 letras “A” e 2 letras “M” repetidas, então o número de anagramas é

$$P_5^{2,2} = \frac{5!}{2! \cdot 2!} = \frac{120}{2 \cdot 2} = 30 \quad (4)$$

1.3 Arranjos

Dado um grupo de n elementos, eu quero selecionar k elementos distintos e organizá-los em uma sequência ordenada, de forma que, ao trocar a ordem dos elementos, eu obtenha uma **sequência diferente**. Por exemplo, se eu quiser saber, dentro dos meus **competidores**, quantas combinações possíveis de **primeiro**, **segundo** e **terceiro** lugar existem, se eu troco o **primeiro** pelo **segundo**, então vira uma sequência diferente, e portanto, é um arranjo diferente.

Definição 1.3.1 (Arranjo de tamanho k para n elementos): O arranjo de tamanho k para n elementos distintos é dado por

$$A_n^k = n(n-1)\dots(n-k+1) = \frac{n!}{(n-k)!} \quad (5)$$

Por que seria essa fórmula? Bom, se eu tenho n elementos, para o primeiro elemento da sequência eu tenho n opções. Para o segundo elemento, eu já usei um elemento, então eu tenho $n-1$ opções. Para o terceiro elemento, eu já usei dois elementos, então eu tenho $n-2$ opções. E assim por diante, até que eu tenha escolhido k elementos. Então, o número total de maneiras de escolher e organizar esses k elementos é dado pelo produto $n(n-1)\dots(n-k+1)$.

1.4 Combinações

Dado um grupo de n elementos, eu quero selecionar k elementos distintos, mas agora a ordem não importa. Por exemplo, se eu quero saber a combinação de ingredientes para o meu sanduíche, se eu coloco o **hamburguer** antes do **queijo**, ou o **queijo** antes do **alface**, isso não faz diferença nenhuma.

Definição 1.4.1 (Combinação de n elementos escolhendo k): O número de combinações de n elementos distintos escolhendo k elementos é dado por

$$C_n^k = \frac{n!}{k! \cdot (n-k)!} = \frac{A_n^k}{k!} = \binom{n}{k} \quad (6)$$

A lógica aqui é montarmos justamente o arranjo anterior, primeiro calculamos de quantas formas podemos organizar k elementos onde a **ordem** influencia na contagem. Depois disso, queremos compensar as contagens extras que realizamos, ou seja, se eu tenho k elementos, eu posso organizá-los de $k!$ formas diferentes, e todas essas formas são a mesma combinação. Então, para compensar isso, dividimos pelo fatorial de k .

Existe uma propriedade muito interessante que podemos usar para calcular combinações, ela mostra que, se eu quero escolher um grupo de k elementos de um conjunto de n elementos, o número de maneiras de fazer isso é o mesmo que escolher $n - k$ elementos do mesmo conjunto. Ou seja, $C_n^k = C_n^{n-k}$.

Teorema 1.4.1:

$$C_n^k = C_n^{n-k} \quad (7)$$

Demonstração: Queremos mostrar que

$$\binom{n}{k} = \binom{n}{n-k} \quad (8)$$

vamos desenvolver ambos os lados

$$\binom{n}{k} = \frac{n!}{k!(n-k)!} \quad (9)$$

$$\binom{n}{n-k} = \frac{n!}{(n-k)!(n-(n-k))!} = \frac{n!}{k!(n-k)!} \quad (10)$$

□

1.5 Permutação Circular

De quantas formas podemos organizar n elementos distintos em um círculo? Para isso usamos a permutação circular.

Definição 1.5.1 (Permutação circular de n elementos): A permutação circular de n elementos distintos é dada por

$$P_n^{\text{circ}} = (n-1)! \quad (11)$$

Para entender melhor a lógica vamos para um exemplo. Suponha que eu tenho 5 pessoas, A , B , C , D e E . Vamos agora organizar elas em um círculo.

$$A \rightarrow B \rightarrow C \rightarrow D \rightarrow E \rightarrow A \quad (12)$$

perfeito! Mas e se eu organizar elas assim?

$$B \rightarrow C \rightarrow D \rightarrow E \rightarrow A \rightarrow B \quad (13)$$

percebe que é a mesma organização, só que com outro ponto de referência? Então, para cada permutação linear de n elementos, existem n permutações circulares equivalentes. Por isso, para calcular a permutação circular, dividimos a permutação linear por n , ou seja, $P_n^{\text{circ}} = \frac{P_n}{n} = \frac{n!}{n} = (n-1)!$.

1.6 Ferramentas de Contagem

Daqui a pouco, vamos definir melhor uma definição ingênua sobre probabilidade, mas de antemão, ela envolve **a contagem de todas as possibilidades que um experimento pode ter**. no mundo real, é impossível contar todas as saídas possíveis de um experimento na mão, mas isso não é um problema! Mesmo quando as saídas de um **experimento** são **numerosas e complexas de se contar na mão**, ainda podemos utilizar algumas ferramentas na área da contagem para nos ajudar a calcular as possibilidades!

1.6.1 Tabela Amostral

A tabela amostral é muito útil para organizar **quais ferramentas** de contagem utilizamos sob **determinadas condições** de um **experimento**.

	Ordem Importa	Ordem não Importa
Reposição	n^k	$\binom{n+k-1}{k}$
Sem Reposição	$\frac{n!}{(n-k)!}$	$\binom{n}{k}$

Antes de explicar a origem de cada fórmula, vou enunciar as **restrições** associadas à cada fórmula

- **Ordem Importa:** A ordem dos elementos escolhidos influencia na contagem, ou seja, se eu escolher os elementos a e b , a sequência (a, b) é diferente da sequência (b, a) .
- **Ordem não Importa:** A ordem dos elementos escolhidos não influencia na contagem, ou seja, se eu escolher os elementos a e b , a sequência (a, b) é igual à sequência (b, a) .
- **Reposição:** Cada elemento escolhido volta para o conjunto de elementos disponíveis, ou seja, posso escolher o mesmo elemento mais de uma vez.
- **Sem Reposição:** Cada elemento escolhido não volta para o conjunto de elementos disponíveis, ou seja, não posso escolher o mesmo elemento mais de uma vez.

1.6.1.1 Ordem Importa e Reposição

Se a ordem importa, então estamos lidando com arranjos. Se há reposição, então para cada elemento escolhido, ele volta para o conjunto de elementos disponíveis, ou seja, na primeira retirada, eu tenho n elementos disponíveis, na segunda, eu ainda tenho n pois o anterior foi colocado de volta, e assim por diante. Logo, o número de maneiras de escolher k elementos com reposição é dado por n^k .

1.6.1.2 Ordem Importa e Sem Reposição

Estamos lidando literalmente com os arranjos como já vimos antes, então será a mesma fórmula do arranjo, ou seja, $\frac{n!}{(n-k)!}$.

1.6.1.3 Ordem não Importa e Sem Reposição

É exatamente o caso da combinação padrão que discutimos anteriormente, ou seja, $\binom{n}{k}$.

1.6.1.4 Ordem não Importa e Reposição

Esse caso é um pouco mais complicado. Você saber de quantas formas possíveis você pode escolher k elementos de um conjunto de n elementos, mas agora você pode escolher o mesmo elemento mais de uma vez, isso é equivalente a **perguntar de quantos jeitos diferentes é possível distribuir k partículas independentes em n caixas diferentes**, mas por quê? Isso não parece nada intuitivo.

Interprete uma associação, cada partícula é um **sorteio** e cada caixa é um **elemento do conjunto**. Quando eu falo **partícula i vai ficar na caixa p** , isso quer dizer em termos do sorteio que, no i -ésimo sorteio, o elemento escolhido foi o p -ésimo elemento do conjunto. Então, se eu tenho k partículas e n caixas, isso é equivalente a dizer que eu tenho k sorteios e n elementos disponíveis para escolher. Como eu posso escolher um mesmo elemento mais de uma vez, isso é equivalente a dizer que eu posso colocar mais de uma partícula na mesma caixa. Para fazer o cálculo de fato, utilizamos a abordagem de pontos e traços, tenha em mente a seguinte divisão

$$\dots / \cdot / \dots / \cdot / \cdot \quad (14)$$

Essa representação é o mesmo que dizer que na primeira caixa, eu tenho 3 partículas, na segunda eu tenho 1 e assim em diante, a quantidade de pontos entre os traços representa a quantidade de partículas em cada caixa. Como temos k partículas, temos k pontos, e como temos n caixas, temos $n - 1$ traços. Logo, o número total de maneiras de organizar esses pontos e traços vai ser o número de maneiras de escolher k pontos dentre todos os $k + n - 1$ elementos, ou seja, $\binom{n+k-1}{k}$.

1.6.2 Identidades Úteis

Mesmo com as ferramentas de contagem que vimos antes, existem diversas situações complexas na área que ainda exigem certas **sacadas**. As identidades que vamos mostrar são **justamente essas sacadas**.

Teorema 1.6.2.1:

$$n \binom{n-1}{k-1} = k \binom{n}{k} \quad (15)$$

Demonstração: Queremos saber de quantas formas podemos escolher k pessoas de um grupo de n pessoas, e dentre essas k pessoas, queremos escolher uma pessoa para ser o **líder**.

No lado direito da igualdade, quando fazemos

$$k \binom{n}{k} \quad (16)$$

primeiro fazemos a contagem de quantas formas podemos escolher k pessoas de um grupo de n pessoas (combinação) e, dentro dessas k , quantas podem ser o **líder**.

Já no lado esquerdo, quando fazemos

$$n \binom{n-1}{k-1} \quad (17)$$

primeiro eu vou escolher o **líder** do grupo dentre as n pessoas, e das $n - 1$ que sobraram, eu vou montar um grupo de $k - 1$ para completar k com o líder que eu escolhi. $\square$

Teorema 1.6.2.2 (Identidade de Vandermonde):

$$\binom{m+n}{k} = \sum_{j=0}^k \binom{m}{j} \binom{n}{k-j} \quad (18)$$

Demonstração: Eu quero escolher k pessoas de um grupo de $m+n$ pessoas. Eu posso dividir esse grupo em dois subgrupos, um com m pessoas e outro com n pessoas. Depois disso, posso dividir em duas etapas, primeiro eu escolho j pessoas do grupo de m pessoas, e depois eu escolho $k-j$ pessoas do grupo de n pessoas, assim completo um grupo de k pessoas. Como j pode variar de 0 até k , eu somo todas as possibilidades, e assim obtenho a **Identidade de Vandermonde**. $\square$

1.7 Contagem do Complementar

Essa técnica parece até boba, mas muitas vezes deixamos passar situações que são mais fáceis de serem resolvidas quando pensamos no **complementar** do que queremos. Essa estratégia consiste em, se eu não sei como calcular o total de possibilidades de uma situação específica, eu posso tentar calcular o da situação **oposta**. Por exemplo, eu quero saber de quantas formas possíveis, dentro de uma sala com n pessoas, existem pelo menos 2 pessoas com o mesmo aniversário. Calcular isso diretamente é bem difícil, no entanto, o complementar é muito fácil, que é **de quantas formas eu garanto que todos tem um dia diferente de aniversário**, que se resume a aplicar uma combinação de n nos 365 dias do ano. Dessa forma, calcular de quantas formas eu posso garantir que pelo menos 2 pessoas tem o mesmo aniversário é muito mais fácil, pois é só fazer $365^n - \binom{365}{n}$

Primeiros passos em Probabilidade

2.1 Fundamentos

2.1.1 Naive Definition

Antes de vermos propriedades teoremas e definições difíceis, vamos começar com uma definição **super simples** do que é uma probabilidade. Intuitivamente, a probabilidade é a chance de um evento ocorrer. Se eu repetir um experimento x vezes, quantas dessas x vezes o evento ocorreu? Com essa noção mais prática de probabilidade, podemos fazer a seguinte definição

Definição 2.1.1.1 (Naive Probability Definition): Seja S o conjunto de **todas** as possíveis saídas de um experimento, e E é um possível **acontecimento** dentro do experimento, então a probabilidade de E ocorrer é

$$\mathbb{P}(E) = \frac{|E|}{|S|} \quad (19)$$

Essa definição mostra a probabilidade do evento ocorrer como uma fração, onde o numerador são **todas as formas que o evento pode ocorrer** sobre **todos os eventos possíveis de ocorrer**. Por exemplo, se eu jogar um dado justo, todos os valores possíveis são $S = \{1, 2, 3, 4, 5, 6\}$, a chance de sair evento “caiu 2” seria $E = \{2\}$, então a probabilidade de cair 2 seria

$$\mathbb{P}(E) = \frac{|E|}{|S|} = \frac{1}{6} \quad (20)$$

2.1.2 Conjuntos

Dada essa definição ingênua de probabilidade, podemos começar a pensar em como formalizar isso utilizando a ideia de **conjuntos**! Na verdade essa é a formalização mais básica de probabilidade. Vamos enunciar algumas definições então.

Definição 2.1.2.1 (Espaço Amostral): O espaço amostral S é o conjunto de **todos os resultados possíveis** de um experimento aleatório.

Definição 2.1.2.2 (Evento): Um evento E é um subconjunto do espaço amostral S , ou seja, $E \subseteq S$.

Essa definição de E parece bem simples, mas se pararmos para pensar, um evento nada mais é que um conjunto de resultados possíveis de um experimento aleatório. Voltando ao exemplo do dado, se o meu espaço amostral é $S = \{1, 2, 3, 4, 5, 6\}$, faz sentido afirmar que “cair 3” é um evento. Porém, falar “cair o número 7” não faz sentido, pois 7 não está no espaço amostral, logo, não é um **evento**.

Corolário 1.6.2.2.1: Dado S um espaço amostral e $A, B \subseteq S$ sendo eventos em S , temos que

1. $A \cup B$ é o evento onde **ou** A **ou** B ocorrem.
2. $A \cap B$ é o evento onde **ambos** A **e** B ocorrem.
3. A^c é o evento onde A **não** ocorre.

Exemplo: Dada uma moeda, jogamos ela 10 vezes (cada jogada é **independente**), então, se for **cara**, é 1 e se for coroa é 0. Escrevemos então a jogada como uma sequência de 10 bits, onde cada bit é 0 ou 1.

$$(1, 0, 0, 1, 1, 0, 1, 0, 0, 1) \quad (21)$$

vejamos alguns eventos:

- Jogada i ser cara e o resto ser coroa

$$A_i = \{(\dots, 1, \dots) \text{ tal que } 1 \text{ está na posição } i \text{ e } i \in \{1, 2, \dots, 10\}\} \quad (22)$$

- Ao menos uma jogada ser cara

$$B = \cup_{i=1}^{10} A_i \quad (23)$$

- Todas as jogadas são cara

$$C = \cap_{i=1}^{10} A_i \quad (24)$$

Teorema 2.1.2.1 (Lei de De Morgan): Dado S um espaço amostral e $A, B \subseteq S$ sendo eventos em S , temos que

1. $(A \cup B)^c = A^c \cap B^c$
2. $(A \cap B)^c = A^c \cup B^c$

Demonstração: Para a primeira igualdade, temos que provar que $(A \cup B)^c \subseteq A^c \cap B^c$ e depois $A^c \cap B^c \subseteq (A \cup B)^c$. Para a primeira parte, seja

$$x \in (A \cup B)^c \Leftrightarrow x \notin A \cup B \quad (25)$$

logo, $x \notin A$ e $x \notin B$, ou seja, $x \in A^c$ e $x \in B^c$, então $x \in A^c \cap B^c \Rightarrow (A \cup B)^c \subseteq A^c \cap B^c$. Para a volta, seja $x \in A^c \cap B^c$, então $x \in A^c$ e $x \in B^c$, ou seja, $x \notin A$ e $x \notin B$, então $x \notin (A \cup B)$, ou seja, $A^c \cap B^c \subseteq (A \cup B)^c$.

Para a segunda igualdade, faremos o mesmo raciocínio. Seja $x \in (A \cap B)^c$ então $x \notin A \cap B$, ou seja, x não ocorre **simultaneamente** em A e B , logo $x \notin A$ **ou** $x \notin B$, ou seja, $x \in A^c$ **ou** $x \in B^c$, então $x \in A^c \cup B^c \Rightarrow (A \cap B)^c \subseteq A^c \cup B^c$. Para a volta, seja $x \in A^c \cup B^c$, então $x \in A^c$ **ou** $x \in B^c$, ou seja, $x \notin A$ **ou** $x \notin B$, logo $x \notin (A \cap B)$, ou seja, $A^c \cup B^c \subseteq (A \cap B)^c$. $\square$

2.2 Propriedades da Probabilidade

Dado toda a introdução que fizemos, podemos agora enunciar algumas propriedades da probabilidade que serão muito úteis. Antes, precisamos saber dos seguintes axiomas:

$$\begin{aligned} \mathbb{P}(\emptyset) &= 0 & \mathbb{P}(S) &= 1 & \mathbb{P}(A) &\geq 0 \\ \mathbb{P}\left(\bigcup_{n=1}^{\infty} A_n\right) &= \sum_{n=1}^{\infty} \mathbb{P}(A_n) & \rightarrow A_i \cap A_j &= \emptyset \quad \forall i \neq j \end{aligned} \quad (26)$$

Agora podemos enunciar as propriedades e suas demonstrações

Teorema 2.2.1:

$$\mathbb{P}(A^c) = 1 - \mathbb{P}(A) \quad (27)$$

Demonstração:

$$\begin{aligned}
1 = \mathbb{P}(S) &\Leftrightarrow 1 = \mathbb{P}(A^c \cup A) \\
&\Leftrightarrow 1 = \mathbb{P}(A^c) + \mathbb{P}(A) \Leftrightarrow \mathbb{P}(A^c) = 1 - \mathbb{P}(A)
\end{aligned}
\tag{28}$$

□

Teorema 2.2.2: Se $A \subseteq B$, então $\mathbb{P}(A) \leq \mathbb{P}(B)$

Demonstração: Montamos B como $A \cup (B \cap A^c)$, se montarmos dessa forma, A e $(B \cap A^c)$ são disjuntos. Antes de prosseguirmos, aqui está uma figura que ilustra a situação




Figura 1: Ilustração da relação entre os conjuntos A e B

Dito isso, podemos então escrever:

$$\mathbb{P}(B) = \mathbb{P}(A \cup (B \cap A^c)) = \mathbb{P}(A) + \mathbb{P}(B \cap A^c) \geq \mathbb{P}(A) \tag{29}$$

□

Teorema 2.2.3 (Princípio da Inclusão-Exclusão):

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B) \tag{30}$$

Demonstração: Montamos $A \cup B$ como $A \cup (B \cap A^c)$, se montarmos dessa forma, A e $(B \cap A^c)$ são disjuntos.

Dito isso, podemos então escrever:

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B \cap A^c) \tag{31}$$

Temos então que mostrar que

$$\mathbb{P}(B \cap A^c) = \mathbb{P}(B) - \mathbb{P}(A \cap B) \tag{32}$$

para isso, vamos mostra que, $(B \cap A^c) \cup (A \cap B) = B$. Para provar isso, vamos mostrar que $(B \cap A^c) \cup (A \cap B) = B \cap (A \cup A^c)$. Se $x \in B$, então $x \in A$ **ou** $x \notin A$, logo, $x \in S$, dessa forma

$$x \in B \cap (A \cup A^c) \Leftrightarrow x \in B \cap S \Leftrightarrow x \in B \quad (33)$$

e temos que $B \cap A^c$ e $A \cap B$ são disjuntos, logo

$$\begin{aligned} \mathbb{P}(B) &= \mathbb{P}((B \cap A^c) \cup (A \cap B)) = \mathbb{P}(B \cap A^c) + \mathbb{P}(A \cap B) \\ &\Leftrightarrow \\ \mathbb{P}(B \cap A^c) &= \mathbb{P}(B) - \mathbb{P}(A \cap B) \end{aligned} \quad (34)$$

□

Teorema 2.2.4:

$$\begin{aligned} \mathbb{P}(A \cup B \cup C) &= \mathbb{P}(A) + \mathbb{P}(B) + \mathbb{P}(C) \\ &\quad - \mathbb{P}(A \cap B) - \mathbb{P}(A \cap C) - \mathbb{P}(B \cap C) \\ &\quad + \mathbb{P}(A \cap B \cap C) \end{aligned} \quad (35)$$

Demonstração: Derivado direto da outra propriedade. Defina

$$D = A \cup B \quad (36)$$

então pelo Teorema 2.2.3, temos que

$$\mathbb{P}(A \cup B \cup C) = \mathbb{P}(D \cup C) = \mathbb{P}(D) + \mathbb{P}(C) - \mathbb{P}(D \cap C) \quad (37)$$

substituindo $\mathbb{P}(D)$ e $\mathbb{P}(D \cap C)$, temos que

$$\begin{aligned} \mathbb{P}(A \cup B \cup C) &= \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B) \\ &\quad + \mathbb{P}(C) - \mathbb{P}(A \cap C) - \mathbb{P}(B \cap C) \\ &\quad + \mathbb{P}(A \cap B \cap C) \end{aligned} \quad (38)$$

□

A ideia desses teoremas é que, quando contamos os eventos, podemos acabar contando **duas vezes** os eventos que estão em comum, então precisamos subtrair esses eventos que estão em comum. Só que conforme adicionamos mais e mais eventos, podemos acabar subtraindo **demaís** os eventos que estão em comum, então precisamos adicionar de volta esses eventos. E assim por diante, até que tenhamos contado todos os eventos corretamente.

2.3 Eventos Independentes

Dois eventos A e B são independentes se a ocorrência de um não afeta a probabilidade do outro. De imediato, não vamos ver a definição formal de independência, que é fácil, mas vamos nos manter na **intuição**. A independência de dois eventos é perceptível quando **a ocorrência de um evento não influencia na saída de outro**. Por exemplo, se eu jogar um dado e uma moeda, a saída do dado não influencia na saída da moeda, logo, os eventos são independentes. Agora vamos supor que eu estou lançando **dois dados**, no entanto, a saída do segundo é somada à saída do primeiro. Nesse caso, a saída do segundo dado **depende** da saída do primeiro, logo, os eventos **não são** independentes.

2.4 Problema do Aniversário

Que tal resolvermos um problema bem paradoxal para estimular nosso pensamento **probabilístico**? O problema do aniversário é o seguinte: qual a probabilidade de, em um grupo de k pessoas, **pelo menos** duas delas fazerem aniversário no mesmo dia? Parece que para que isso aconteça, o grupo precisa ser grande, mas não é bem assim. Antes de resolvermos o problema, vou enunciar um teorema que será útil para provar o caso mais óbvio.

Teorema 2.4.1 (Princípio da Casa dos Pombos): Se n pombos são colocados em m casas, e $n > m$, então **pelo menos** uma casa terá mais de um pombo.

Agora podemos enunciar as etapas da resolução do problema! Primeira coisa que fazemos é **remover as restrições**. Uma delas é o dia 29 de fevereiro, que só ocorre em anos bissextos, então vamos **desconsiderar** esse dia. Outro ponto é que **cada dia** tem a **mesma chance** de ocorrer e são eventos **independentes**.

Para o caso de termos mais pessoas que dias do ano, pelo Teorema 2.4.1, sabemos que **pelo menos** duas pessoas vão fazer aniversário no mesmo dia, logo a probabilidade será 1.

Agora vamos analisar o caso geral para $k \leq 365$. Nessa situação, o mais fácil é calcular a probabilidade do evento **contrário**, ou seja, a probabilidade de que **todos do grupo tem aniversários diferentes**.

$$\mathbb{P}(\text{todos diferentes}) = \frac{365}{365} \cdot \frac{364}{365} \cdot \frac{363}{365} \cdots \frac{365 - k + 1}{365} = \frac{\frac{365!}{(365-k)!}}{365^k} \quad (39)$$

Aqui, nós vamos no raciocínio que o primeiro aniversariante tem 365 opções, o segundo tem 364 opções, o terceiro tem 363 opções e assim por diante, até que o último aniversariante tenha $365 - k + 1$ opções. Como cada pessoa tem 365 opções, então o número total de possibilidades é 365^k . Logo, a probabilidade de **pelo menos** duas pessoas fazerem aniversário no mesmo dia é

$$\mathbb{P}(\text{pelo menos dois iguais}) = 1 - \mathbb{P}(\text{todos diferentes}) = 1 - \frac{\frac{365!}{(365-k)!}}{365^k} \quad (40)$$

Quando $k = 23$, a probabilidade de que **pelo menos** duas pessoas façam aniversário no mesmo dia é de aproximadamente 50%.

Probabilidade Condicional

3.1 Como o Conhecimento influencia na Probabilidade

Em probabilidade, conseguimos utilizar conhecimento do que aconteceu agora no nosso experimento para entender as chances dos eventos que estão para acontecer.

Exemplo: Ao jogarmos um dado justo 2 vezes, dado que eu sei que a soma de ambos os valores que caíram é 6, mas não sei qual o valor de cada lançamento, qual é a probabilidade de que o primeiro valor seja 2? Sabemos que a soma de ambos os valores que caíram é 6, então o espaço amostral é reduzido para

$$(1, 5), (2, 4), (3, 3), (4, 2), (5, 1) \quad (41)$$

dentro das possibilidades, a probabilidade vai ser

$$\mathbb{P}(\text{primeiro valor é 2} \mid \text{soma é 6}) = \frac{1}{5} \quad (42)$$

Exemplo: Jogamos uma moeda 100 vezes, mas não sabemos se ela é viciada ou não. Sabemos que, se a moeda for justa, nós deveríamos observar uma proporção de $1/2$ para o número de caras e coroas. No entanto, suponha que nós observamos 70 caras e 30 coroas. Isso faz parecer que essa moeda **está viciada** de alguma forma. Essa informação passada me faz crer que a chance do meu lançamento agora, não é mais $1/2$.

Definição 3.1.1 (Probabilidade Condicional): Dado um espaço amostral S e dois eventos $A, B \subseteq S$, a probabilidade de A ocorrer dado que B ocorreu é dada por

$$\mathbb{P}(A \mid B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} \quad (43)$$

Exemplo: Voltando no exemplo do dado com soma 6, vamos separar o problema em dois eventos para aplicar a definição de probabilidade condicional. Seja A o evento de que o primeiro valor seja 2, e seja B o evento de que a soma dos valores seja 6. Então, temos que

$$\mathbb{P}(B) = \frac{5}{36} \quad \mathbb{P}(A \cap B) = \frac{1}{36} \quad (44)$$

então aplicando a definição:

$$\mathbb{P}(A \mid B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} = \frac{\frac{1}{36}}{\frac{5}{36}} = \frac{1}{5} \quad (45)$$

3.2 Independência

Agora que enunciamos o conceito de condicionamento e como **saber** de um evento influencia na probabilidade de outro, podemos formalizar melhor a definição de independência. Quando dizemos que um evento não influencia na probabilidade de outro, isso nos indica que, **se eu sei do resultado do evento A** , isso não me dá **nenhuma informação** sobre o resultado do evento B . Ou seja, a probabilidade de B ocorrer **não muda** se eu sei que A ocorreu. Formalizando isso, temos a seguinte definição.

Definição 3.2.1 (Eventos Independentes): Dois eventos A e B são independentes quando

$$\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B) \quad (46)$$

Ué, a definição que eu falei não parece ter muito a ver com o que eu acabei de escrever, mas na verdade, ela tem sim!

Teorema 3.2.1: Se A e B são independentes, então

$$\mathbb{P}(A \mid B) = \mathbb{P}(A) \quad (47)$$

Demonstração: Pela definição:

$$\mathbb{P}(A \mid B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} \quad (48)$$

Como são independentes:

$$\mathbb{P}(A \mid B) = \frac{\mathbb{P}(A) \cdot \mathbb{P}(B)}{\mathbb{P}(B)} = \mathbb{P}(A) \quad (49)$$

□

Assim, conseguimos formalizar a ideia de **não fornecimento de informação** de um evento sobre outro.

Outro conceito importante que podemos formalizar é que a probabilidade de **dois eventos ocorrerem** simultaneamente é a mesma que a probabilidade de **um evento ocorrer dado que o outro ocorreu** multiplicado pela probabilidade do **outro evento ocorrer**.

Teorema 3.2.2:

$$\mathbb{P}(A \cap B) = \mathbb{P}(A \mid B) \cdot \mathbb{P}(B) = \mathbb{P}(B \mid A) \cdot \mathbb{P}(A) \quad (50)$$

Demonstração: Sabemos que $\mathbb{P}(A \cap B) = \mathbb{P}(B \cap A)$, manipulando então a definição de probabilidade condicional, temos que

$$\mathbb{P}(A \mid B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} \Leftrightarrow \mathbb{P}(A \cap B) = \mathbb{P}(A \mid B) \cdot \mathbb{P}(B) \quad (51)$$

da mesma forma:

$$\mathbb{P}(B \mid A) = \frac{\mathbb{P}(B \cap A)}{\mathbb{P}(A)} \Leftrightarrow \mathbb{P}(B \cap A) = \mathbb{P}(B \mid A) \cdot \mathbb{P}(A) \quad (52)$$

□

É o que mermão? Qual que é a lógica disso? Imagine que nós **sabemos** que um evento A ocorreu, se sabemos que A ocorreu, qual seria a probabilidade que, dentro do universo de A , o evento B ocorra também? No entanto, para que isso aconteça, precisamos que A ocorra também, logo, pelo princípio da multiplicação, precisamos multiplicar ambas as probabilidades (queremos que as representar a chance dos **dois** eventos ocorrerem), ambas que são dadas justamente por

$$\mathbb{P}(B \mid A) \cdot \mathbb{P}(A) \quad (53)$$

3.3 Lei da Probabilidade Total

A lei da probabilidade total mostra como podemos representar a probabilidade de um evento B ocorrer em função da sua chance de acontecer sob a perspectiva da ocorrência de outros eventos disjuntos no **mesmo espaço amostral**.

Teorema 3.3.1 (Lei da Probabilidade Total): Sejam $A_1, A_2, \dots, A_n$ eventos disjuntos 2 a 2, ou seja, $A_i \cap A_j = \emptyset$ para $i \neq j$ e $\bigcup_{i=1}^n A_i = S$ onde S é o espaço amostral, então para qualquer evento B , desde que $\mathbb{P}(A_i)$ e $\mathbb{P}(B|A_i)$ existam e sejam conhecidos, temos que

$$\mathbb{P}(B) = \sum_{i=1}^n \mathbb{P}(B | A_i) \cdot \mathbb{P}(A_i) \quad (54)$$

Demonstração:

$$\begin{aligned} \mathbb{P}(B) &= \mathbb{P}(B \cap S) \\ &= \mathbb{P}(B \cap (A_1 \cup A_2 \cup \dots \cup A_n)) \\ &= \mathbb{P}((B \cap A_1) \cup (B \cap A_2) \cup \dots \cup (B \cap A_n)) \\ &= \mathbb{P}(B \cap A_1) + \mathbb{P}(B \cap A_2) + \dots + \mathbb{P}(B \cap A_n) \\ &= \mathbb{P}(B | A_1) \cdot \mathbb{P}(A_1) + \dots + \mathbb{P}(B | A_n) \cdot \mathbb{P}(A_n) \end{aligned} \quad (55)$$

□

Como podemos ver isso de forma intuitiva? Para uma explicação intuitiva, acesse esse vídeo: [PREENCHER]

Esse teorema é muito útil quando temos informações sobre outros eventos, mas não temos sobre o evento objetivo que gostaríamos de conhecer.

Exemplo: Suponha que eu queira saber a probabilidade de uma pessoa ter câncer, mas eu não tenho essa informação. No entanto, eu sei que a pessoa é fumante, e que a probabilidade de uma pessoa ter câncer **dado** que ela é fumante é 0.1, e que a probabilidade de uma pessoa ter câncer dado que ela não é fumante é 0.01. Além disso, eu sei que a probabilidade de uma pessoa ser fumante é 0.2. Então, podemos calcular a probabilidade de uma pessoa ter câncer utilizando a lei da probabilidade total:

$$\begin{aligned} \mathbb{P}(\text{câncer}) &= \mathbb{P}(\text{câncer} | \text{fumante}) \cdot \mathbb{P}(\text{fumante}) + \mathbb{P}(\text{câncer} | \text{não fumante}) \cdot \mathbb{P}(\text{não fumante}) \\ &= 0.1 \cdot 0.2 + 0.01 \cdot 0.8 = 0.02 + 0.008 = 0.028 \end{aligned} \quad (56)$$

Conseguimos expandir esse teorema para o caso de múltiplas condições, mas antes de fazer isso, vamos enunciar um teorema que vai nos ajudar a fazer isso.

Teorema 3.3.2 (Equivalência probabilística do condicionamento): A função $\tilde{\mathbb{P}}(A) = \mathbb{P}(A|E)$ com E sendo um evento possível qualquer, é uma probabilidade.

Demonstração: Para que a função seja uma probabilidade, ela precisa estar sujeita aos axiomas da probabilidade, ou seja, ela precisa satisfazer as seguintes condições:

1. $\tilde{\mathbb{P}}(S) = 1$
2. $\tilde{\mathbb{P}}(A) \geq 0$

$$3. \tilde{\mathbb{P}}\left(\bigcup_{j=1}^n A_j\right) = \sum_{j=1}^n \tilde{\mathbb{P}}(A_j)$$

Provando $\tilde{\mathbb{P}}(S) = 1$: Se sabemos que o evento E ocorreu, então nosso espaço amostral é reduzido para **todos os eventos em que E ocorreu**, ou seja, o nosso espaço amostral vira E .

$$\tilde{\mathbb{P}}(E) = \mathbb{P}(E|E) = \frac{\mathbb{P}(E \cap E)}{\mathbb{P}(E)} = \frac{\mathbb{P}(E)}{\mathbb{P}(E)} = 1 \quad (57)$$

Provando $\tilde{\mathbb{P}}(A) \geq 0$: Pela definição de probabilidade condicional, temos que

$$\tilde{\mathbb{P}}(A) = \mathbb{P}(A|E) = \frac{\mathbb{P}(A \cap E)}{\mathbb{P}(E)} \quad (58)$$

como a função de cima e a de baixo são maiores que 0, a divisão inteira será maior que 0.

Provando $\tilde{\mathbb{P}}\left(\bigcup_{j=1}^n A_j\right) = \sum_{j=1}^n \tilde{\mathbb{P}}(A_j)$: Pela definição de probabilidade condicional, temos que

$$\begin{aligned} \tilde{\mathbb{P}}\left(\bigcup_{j=1}^n A_j\right) &= \mathbb{P}\left(\bigcup_{j=1}^n A_j \mid E\right) \\ &= \frac{\mathbb{P}\left(\left(\bigcup_{j=1}^n A_j\right) \cap E\right)}{\mathbb{P}(E)} \\ &= \frac{\mathbb{P}\left(\bigcup_{j=1}^n (A_j \cap E)\right)}{\mathbb{P}(E)} \\ &= \frac{\sum_{j=1}^n \mathbb{P}(A_j \cap E)}{\mathbb{P}(E)} \\ &= \sum_{j=1}^n \frac{\mathbb{P}(A_j \cap E)}{\mathbb{P}(E)} \\ &= \sum_{j=1}^n \tilde{\mathbb{P}}(A_j) \end{aligned} \quad (59)$$

□

Com esse teorema, podemos expandir a lei da probabilidade total

Teorema 3.3.3 (Lei da Probabilidade Total com Condicionamento Extra): Sejam $A_1, A_2, \dots, A_n$ eventos disjuntos 2 a 2, ou seja, $A_i \cap A_j = \emptyset$ para $i \neq j$ e $\bigcup_{i=1}^n A_i = S$ onde S é o espaço amostral, então para qualquer evento B e E , desde que $\mathbb{P}(A_i|E)$ e $\mathbb{P}(B|A_i \cap E)$ existam e sejam conhecidos, temos que

$$\mathbb{P}(B \mid E) = \sum_{i=1}^n \mathbb{P}(B \mid A_i \cap E) \cdot \mathbb{P}(A_i \mid E) \quad (60)$$

Demonstração: Pelo Teorema 3.3.2, podemos renomear $\tilde{\mathbb{P}}(B) = \mathbb{P}(B|E)$, então podemos aplicar a lei da probabilidade total para essa função, ou seja, temos que

$$\begin{aligned}\tilde{\mathbb{P}}(B) &= \sum_{i=1}^n \tilde{\mathbb{P}}(B \mid A_i) \cdot \tilde{\mathbb{P}}(A_i) \\ &\Leftrightarrow \\ \mathbb{P}(B \mid E) &= \sum_{i=1}^n \mathbb{P}(B \mid A_i \cap E) \cdot \mathbb{P}(A_i \mid E)\end{aligned}\tag{61}$$

□

Esse teorema nos permite utilizar a lei da probabilidade total em problemas mais complexos e com mais restrições.

Exemplo (A Moeda Viciada): Considere duas urnas diferentes

$$\begin{aligned}A_1 &= 3 \text{ bolas vermelhas e } 1 \text{ azul} \\ A_2 &= 1 \text{ bola vermelha e } 3 \text{ azuis}\end{aligned}\tag{62}$$

Uma das urnas é escolhida ao acaso, e uma bola é retirada da urna escolhida com

$$\mathbb{P}(A_1) = \mathbb{P}(A_2) = 0.5\tag{63}$$

em seguida, retiramos duas bolas da urna escolhida **sem reposição**. Queremos saber então qual é a **probabilidade** de que do valor da segunda bola dado o da primeira. Por exemplo

$$\begin{aligned}V_1 &= \text{primeira bola é vermelha} \\ V_2 &= \text{segunda bola é vermelha}\end{aligned}\tag{64}$$

quero saber então

$$\mathbb{P}(V_2 \mid V_1) = \mathbb{P}(V_2 \mid V_1, A_1) \cdot \mathbb{P}(A_1 \mid V_1) + \mathbb{P}(V_2 \mid V_1, A_2) \cdot \mathbb{P}(A_2 \mid V_1)\tag{65}$$

calcular apenas $\mathbb{P}(V_2 \mid V_1)$ é difícil, mas se condicionarmos em **qual urna nós tiramos a bola**, conseguimos calcular facilmente.

3.4 O Teorema de Bayes

Suponha que esteja acontecendo a suspeita de um possível **futuro** surto de malária no Rio de Janeiro, e que o governo está preocupado com a situação. Para isso, eles vão realizar um teste de malária em toda a população da cidade, mas o teste não é perfeito! Acontece que meu resultado deu positivo, isso quer dizer que tenho malária? Será que agora eu vou morrer? A verdade é bem mais tranquilizante, e o **teorema de bayes** no mostra essa relação.

Teorema 3.4.1 (Teorema de Bayes): Sejam A e B dois eventos, então temos que

$$\mathbb{P}(A \mid B) = \frac{\mathbb{P}(B \mid A) \cdot \mathbb{P}(A)}{\mathbb{P}(B)}\tag{66}$$

Demonstração: Aplicando o Teorema 3.2.2, temos que

$$\mathbb{P}(A \mid B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} = \frac{\mathbb{P}(B \mid A) \cdot \mathbb{P}(A)}{\mathbb{P}(B)}\tag{67}$$

□

Vamos considerar, no contexto do nosso problema, que

- Apenas 1% da população tem malária
- O teste acerta 99% dos doentes
- O teste acerta 99% dos saudáveis

Analisando rapidamente, se o teste der positivo, isso parece falar que **a chance de eu ter malária é de 99%**, mas isso **não é verdade**. A minha primeira fala se refere à seguinte probabilidade:

$$\mathbb{P}(\text{Positivo}|\text{Doente}) = 0.99 \quad (68)$$

No entanto, meu exame deu positivo e eu não sei se estou mesmo doente ou não, logo, a probabilidade que eu quero saber é

$$\mathbb{P}(\text{Doente}|\text{Positivo}) \quad (69)$$

pelo Teorema 3.4.1, temos que

$$\mathbb{P}(\text{Doente}|\text{Positivo}) = \frac{\mathbb{P}(\text{Positivo}|\text{Doente}) \cdot \mathbb{P}(\text{Doente})}{\mathbb{P}(\text{Positivo})} = \frac{0.99 \cdot 0.01}{\mathbb{P}(\text{Positivo})} \quad (70)$$

para calcular $\mathbb{P}(\text{Positivo})$, usamos o Teorema 3.3.1, mas ela diz que podemos expressar essa probabilidade como

$$\begin{aligned} \mathbb{P}(\text{Positivo}) &= \mathbb{P}(\text{Positivo}|\text{Doente}) \cdot \mathbb{P}(\text{Doente}) + \mathbb{P}(\text{Positivo}|\text{Saudável}) \cdot \mathbb{P}(\text{Saudável}) \\ &= 0.99 \cdot 0.01 + 0.01 \cdot 0.99 = 0.0198 \end{aligned} \quad (71)$$

voltando para a fórmula anterior

$$\mathbb{P}(\text{Doente}|\text{Positivo}) = \frac{0.99 \cdot 0.01}{0.0198} = 0.5 \quad (72)$$

então se eu sei que meu teste deu positivo, na verdade, a chance de eu ter malária é de apenas 50%, e não 99% como parecia inicialmente. Isso é um exemplo clássico de como o Teorema de Bayes nos ajuda a atualizar nossas previsões com base em informações novas.

3.4.1 Falácia do Promotor

Um caso muito famoso onde essa confusão teve consequências graves, foi o caso de *Sally Clark*. Em 1999, ela estava sendo julgada pelo assassinato de seus dois bebês, que morreram de *Síndrome da Morte Súbita Infantil*.



Figura 2: Sally Clark

O promotor do caso alegou que a probabilidade de duas crianças morrerem de *Síndrome da Morte Súbita Infantil* na mesma família era de 1 em 73 milhões, e que isso provava que ela era culpada. No entanto, essa alegação foi baseada em uma falácia estatística, pois não considerou outros fatores, como histórico familiar, condições de saúde e outros fatores de risco. Resumidamente, ele confundiu

$$\mathbb{P}(\text{Evidência}|\text{Inocência}) \quad (73)$$

com

$$\mathbb{P}(\text{Inocência}|\text{Evidência}) \quad (74)$$

Anos depois a condenação foi anulada. Diversos estatísticos apontaram que houve uso incorreto de probabilidade no julgamento.

Variáveis Aleatórias Discretas

4.1 Experimentos Aleatórios

Dentro de um experimento qualquer, estamos a todo momento medindo quantidades, como por exemplo, o número de vezes que um dado caiu em 6, ou o número de vezes que uma moeda caiu em **cara**. Essas quantidades são chamadas de **variáveis aleatórias**.

Definição 4.1.1 (Variável Aleatória Discreta): Uma variável aleatória discreta é uma função $X : S \rightarrow \mathbb{R}$ que associa a cada resultado do espaço amostral S um número real $\mathbb{R}$ e tal que o conjunto de valores assumidos por X ,

$$\text{Im}(X) = \{X(s) : s \in S\} \quad (75)$$

é **finito** ou **enumerável**.

Exemplo: Dado um experimento de jogar uma moeda honesta 3 vezes, poderíamos ter as seguintes variáveis aleatórias discretas:

$$\begin{aligned} X &= \text{número de caras} \\ Y &= \text{número de transições de cara para coroa} \end{aligned} \quad (76)$$

O nome de **aleatório** não vem do número em si, mas vem da **naturaza do experimento** conter aleatoriedade

4.2 Função de Massa

Precisamos definir uma forma de associar cada valor que a variável aleatória pode assumir com a probabilidade que aquele valor ocorra no meu experimento, é aí que entra a **função de massa**.

4.2.1 Probabilidade Marginal

É a função que descreve a probabilidade de cada valor que a variável aleatória discreta pode assumir. Por exemplo, se eu jogo uma moeda honesta 3 vezes, a variável aleatória X que mede o número de caras pode assumir os valores 0, 1, 2 e 3. A função de massa de probabilidade vai me dizer qual a probabilidade de cada um desses valores ocorrer.

Definição 4.2.1.1 (Função de Massa de Probabilidade (PMF)): A função de massa de probabilidade (ou PMF) de uma variável aleatória discreta X é uma função $p_X : \mathbb{R} \rightarrow [0, 1]$ definida por

$$p_X(x) = \mathbb{P}(X = x) \quad (77)$$

para todo $x \in \mathbb{R}$. A função de massa de probabilidade satisfaz as seguintes propriedades:

1. $p_X(x) \geq 0$ para todo $x \in \mathbb{R}$
2. $\sum_{x \in \text{Im}(X)} p_X(x) = 1$

Essa função também é chamada de **Probabilidade Marginal de X** .

4.2.2 Probabilidade Conjunta

Outra função de massa muito importante é a que descreve o comportamento de múltiplas variáveis aleatórias conjuntamente, associando como um conjunto de valores que as variáveis aleatórias podem assumir, e qual a probabilidade de cada conjunto ocorrer.

Definição 4.2.2.1 (Função de Massa Conjunta): Sejam $X_1, \dots, X_n$ variáveis aleatórias discretas, a função de massa conjunta é uma função $p_{X_1, \dots, X_n} : \mathbb{R}^n \rightarrow [0, 1]$ definida por

$$p_{X_1, \dots, X_n}(x_1, \dots, x_n) = \mathbb{P}(X_1 = x_1, \dots, X_n = x_n) \quad (78)$$

Definição 4.2.2.2 (Função de Massa Condicional): Sejam $X_1, \dots, X_n$ variáveis aleatórias discretas e Y uma variável aleatória discreta, a função de massa condicional é uma função $p_{X_1, \dots, X_n|Y} : \mathbb{R}^n \rightarrow [0, 1]$ definida por

$$p_{X_1, \dots, X_n|Y}(x_1, \dots, x_n|y) = \mathbb{P}(X_1 = x_1, \dots, X_n = x_n|Y = y) \quad (79)$$

Ela descreve a probabilidade de cada combinação de valores que as variáveis aleatórias podem assumir. Por exemplo, se eu joga uma moeda honesta 3 vezes e defino as variáveis

$$X = \text{número de caras} \quad Y = \text{número de coroas} \quad (80)$$

e eu gostaria de saber $\mathbb{P}(X = 2, Y = 0)$. A função de massa me retornaria 0, afinal, eu não posso ter 2 caras e 0 coroas ao mesmo tempo. Já se eu quisesse saber $\mathbb{P}(X = 2, Y = 1)$, a função de massa me retornaria $3/8$, afinal, existem 3 maneiras de ter 2 caras e 1 coroa em 3 jogadas, e o total de possibilidades é 8.

4.2.3 Relação entre as funções de massa

Perceba que ao saber o valor de Y no exemplo acima, isso me dá algum tipo de informação sobre o valor de X ! Na verdade, conseguimos obter múltiplas relações entre as funções de massa, como **independência** e **obter a marginal de X a partir da conjunta**, vamos ver como isso funciona.

4.2.3.1 Independência

No exemplo anterior, vimos que, se eu sei o valor de X , eu consigo informações sobre os possíveis valores de Y . Isso me é um indicativo que X e Y **não são independentes**. Será que a função de massa pode nos ajudar a descobrir se duas variáveis aleatórias são independentes? Na verdade sim! Lembra que definimos que dois eventos A e B são independentes quando $\mathbb{P}(A, B) = \mathbb{P}(A) \cdot \mathbb{P}(B)$? Na verdade, perceba que $X = x$ e $Y = y$ **também são eventos**, então podemos aplicar a definição de independência para variáveis aleatórias.

Definição 4.2.3.1.1 (Independência de Variáveis Aleatórias): Duas variáveis aleatórias X e Y são independentes quando a função de massa conjunta for igual ao produto das funções de massa marginais:

$$\begin{aligned} p_{X,Y}(x, y) &= p_X(x) \cdot p_Y(y) \\ \mathbb{P}(X = x, Y = y) &= \mathbb{P}(X = x) \cdot \mathbb{P}(Y = y) \end{aligned} \quad (81)$$

para todos x e y .

E assim como na parte de conjuntos, conseguimos estender isso para a formalização que o conhecimento de variáveis independentes não afeta a probabilidade entre elas

Corolário 3.4.1.1 (Independência por Condicionalidade):

$$X \text{ e } Y \text{ são independentes} \Leftrightarrow \mathbb{P}(X = x|Y = y) = \mathbb{P}(X = x) \quad (82)$$

Exemplo: Voltando no exemplo do dado com soma 6, vamos separar o problema em dois eventos para aplicar a definição de independência. Seja X o evento de que o primeiro valor seja 2, e seja Y o evento de que a soma dos valores seja 6. Então, temos que

$$\mathbb{P}(Y) = \frac{5}{36} \quad \mathbb{P}(X \cap Y) = \frac{1}{36} \quad (83)$$

então aplicando a definição:

$$\mathbb{P}(X | Y) = \frac{\mathbb{P}(X \cap Y)}{\mathbb{P}(Y)} = \frac{\frac{1}{36}}{\frac{5}{36}} = \frac{1}{5} \quad (84)$$

e como $\mathbb{P}(X) = \frac{1}{6}$, temos que

$$\mathbb{P}(X | Y) \neq \mathbb{P}(X) \quad (85)$$

logo, os eventos não são independentes.

4.2.3.2 Marginalização

Lembra que o Teorema 3.3.1 indica como obter a probabilidade de um evento B em função de outros eventos disjuntos? Na verdade, conseguimos aplicar o mesmo raciocínio para variáveis aleatórias, e isso é chamado de **marginalização**. A marginalização nos permite obter a função de massa marginal de uma variável aleatória a partir da função de massa conjunta, para obter o Teorema 4.2.3.2.1, basta definir o evento B como $X = x$ e os eventos A_j como $Y = y_j$

Teorema 4.2.3.2.1 (Lei da Probabilidade Total):

$$\begin{aligned} \mathbb{P}(X = x) &= \sum_y \mathbb{P}(X = x | Y = y) \cdot \mathbb{P}(Y = y) \\ &= \sum_y \mathbb{P}(X = x, Y = y) \end{aligned} \quad (86)$$

4.3 Transformações sobre as variáveis

Esse tema é bem profundo, mas agora no início, nós vamos ver algumas transformações básicas que podem ser aplicadas em variáveis aleatórias e **como** elas influenciam nas probabilidades dos eventos. Para os casos abaixo, considere X e Y variáveis aleatórias.

- $a \cdot X$ com $a \in \mathbb{R}$: Se a imagem de X é $x_1, \dots, x_n$, então a imagem de $a \cdot X$ é $a \cdot x_1, \dots, a \cdot x_n$. A função de massa de probabilidade de $a \cdot X$ é dada por

$$p_{a \cdot X}(a \cdot x) = p_X(x) \quad (87)$$

ou seja, as probabilidades não mudam, apenas os valores que a variável aleatória pode assumir.

- $X + b$ com $b \in \mathbb{R}$: Se a imagem de X é $x_1, \dots, x_n$, então a imagem de $X + b$ é $x_1 + b, \dots, x_n + b$. A função de massa de probabilidade de $X + b$ é dada por

$$p_{X+b}(x + b) = p_X(x) \quad (88)$$

ou seja, as probabilidades não mudam, apenas os valores que a variável aleatória pode assumir.

- $X + Y$: Se a imagem de X é $x_1, \dots, x_n$ e a imagem de Y é $y_1, \dots, y_m$, então a imagem de $X + Y$ é $x_1 + y_1, \dots, x_n + y_m$. A função de massa de probabilidade de $X + Y$ pode ser calculada

analiticamente, no entanto, não será o foco nesse momento. Como os problemas nessa etapa são simples, podemos calcular o novo espaço amostral de $X + Y$ manualmente e calcular as probabilidades com base nas probabilidades de X e Y . Esse raciocínio se aplica a qualquer função $g(X, Y)$

4.4 Função Acumulada e de Sobrevivência

A função de distribuição acumulada (CDF) calcula a probabilidade do valor mostrado pela variável ser menor que um x .

Definição 4.4.1 (Função de Distribuição Acumulada (CDF)): A função de distribuição acumulada (CDF) de uma variável aleatória discreta X é uma função $F_X : \mathbb{R} \rightarrow [0, 1]$ definida por

$$F_X(x) = \mathbb{P}(X \leq x) \quad (89)$$

para todo $x \in \mathbb{R}$. A função de distribuição acumulada satisfaz as seguintes propriedades:

1. $F_X(x)$ é não decrescente
2. $\lim_{x \rightarrow -\infty} F_X(x) = 0$
3. $\lim_{x \rightarrow \infty} F_X(x) = 1$

Definição 4.4.2 (Função de Sobrevivência): A função de sobrevivência de uma variável aleatória discreta X é uma função $G_X : \mathbb{R} \rightarrow [0, 1]$ definida por

$$G_X(x) = \mathbb{P}(X > x) \quad (90)$$

para todo $x \in \mathbb{R}$. A função de sobrevivência satisfaz as seguintes propriedades:

1. $G_X(x)$ é não crescente
2. $\lim_{x \rightarrow -\infty} G_X(x) = 1$
3. $\lim_{x \rightarrow \infty} G_X(x) = 0$

Essa função pode não parecer super útil no momento, mas ela é muito útil para calcular probabilidades de intervalos, por exemplo, se eu quero saber a probabilidade de X estar entre a e b !

Teorema 4.4.1:

$$\mathbb{P}(a < X \leq b) = F_X(b) - F_X(a) \quad (91)$$

Ela também vai nos ajudar muito no futuro quando começarmos a falar sobre variáveis **contínuas**.

Esperança

Esse capítulo terá bastante conceitos importantes, no entanto, também existirão muitos teoremas e demonstrações, principalmente de **propriedades** dos conceitos. Se você preferir, pode pular as demonstrações e ir direto para os conceitos, mas se possível, tente se aprofundar nas demonstrações posteriormente, pois elas vão te ajudar a entender melhor os conceitos.

5.1 O Valor Médio

Em problemas cotidianos, muitas vezes gostamos de fazer a pergunta “*Quanto eu ganho em média?*”, “*Quanto eu perco em média?*”, “*Quantos pontos eu consigo em média?*”, ... A esperança matemática é justamente a resposta para essa pergunta, ela nos dá o valor médio esperado de uma variável aleatória, que intuitivamente seria o valor que, se eu fosse chutar que cairia, seria o valor que eu chutaria. Por exemplo, se eu tenho uma contagem de caras e coroas em n jogadas, eu com certeza chutaria que cairiam $n/2$ caras e $n/2$ coroas, afinal, a moeda é honesta.

Definição 5.1.1 (Esperança de uma Variável Aleatória Discreta): A esperança de uma variável aleatória discreta X é definida por

$$\mathbb{E}[X] = \sum_x x \cdot \mathbb{P}(X = x) \quad (92)$$

A esperança existe desde que a soma esteja bem definida (existem casos que ela pode divergir e não existe um valor de esperança).

5.2 Law of the Unconscious Statistician

Esse teorema é nomeado de forma a tirar sarro de estatísticos. Acontece que, se você tem uma variável aleatória X e uma função g , ao fazer $g(X)$, você pode pensar de forma inocente, que

$$\mathbb{E}[g(X)] = \sum_x g(x) \cdot \mathbb{P}(X = x) \quad (93)$$

mas isso na verdade está **corretíssimo**, acontece que a demonstração desse teorema é mais complexa, mas o seu resultado intuitivo está **correto**

Teorema 5.2.1 (Law of the Unconscious Statistician (LOTUS)): Sejam X uma variável aleatória discreta e g uma função, então

$$\mathbb{E}[g(X)] = \sum_x g(x) \cdot \mathbb{P}(X = x) \quad (94)$$

Demonstração: Pensando numa demonstração **não rigorosa**, mas intuitiva, podemos pensar que, para encontrar a probabilidade de um $z = g(x)$ ocorrer, precisamos encontrar todos os valores de x que vão gerar aquele z . O somatório faz isso em cima dos locais corretos e soma $zp(z)$

$$\begin{aligned}
\mathbb{E}[Z] &= \sum_z z \mathbb{P}(Z = z) = \sum_z z \left(\sum_{g(x)=z} \mathbb{P}(X = x) \right) \\
&= \sum_z \sum_{g(x)=z} z \mathbb{P}(X = x) \\
&= \sum_z \sum_{g(x)=z} g(x) \mathbb{P}(X = x) \\
&= \sum_x g(x) \mathbb{P}(X = x)
\end{aligned} \tag{95}$$

□

Corolário 5.2.1.1 (*Linearidade da Esperança*): A esperança é linear, ou seja, para quaisquer constantes a e b e variáveis aleatórias X e Y , temos

$$\mathbb{E}[aX + bY] = a\mathbb{E}[X] + b\mathbb{E}[Y] \tag{96}$$

Demonstração:

$$\begin{aligned}
\mathbb{E}[aX + bY] &= \sum_{x,y} (ax + by) \cdot \mathbb{P}(X = x, Y = y) \\
&= \sum_{x,y} ax \cdot \mathbb{P}(X = x, Y = y) + \sum_{x,y} by \cdot \mathbb{P}(X = x, Y = y) \\
&= a \sum_x x \sum_y \cdot \mathbb{P}(X = x, Y = y) + b \sum_y y \sum_x \cdot \mathbb{P}(X = x, Y = y)
\end{aligned} \tag{97}$$

Pela lei da probabilidade total, temos que

$$\begin{aligned}
\sum_y \mathbb{P}(X = x, Y = y) &= \mathbb{P}(X = x) \\
\sum_x \mathbb{P}(X = x, Y = y) &= \mathbb{P}(Y = y)
\end{aligned} \tag{98}$$

Logo:

$$\begin{aligned}
\mathbb{E}[aX + bY] &= a \sum_x x \cdot \mathbb{P}(X = x) + b \sum_y y \cdot \mathbb{P}(Y = y) \\
&= a\mathbb{E}[X] + b\mathbb{E}[Y]
\end{aligned} \tag{99}$$

□

Teorema 5.2.2 (LOTUS com duas variáveis): Sejam X e Y variáveis aleatórias discretas e g uma função, então

$$\mathbb{E}[g(X, Y)] = \sum_{x,y} g(x, y) \cdot \mathbb{P}(X = x, Y = y) \tag{100}$$

Demonstração: Fazendo uma demonstração não rigorosa, mas intuitiva, podemos pensar que, para encontrar a probabilidade de um $z = g(x, y)$ ocorrer, precisamos encontrar todos os valores de x e y que vão gerar aquele z . O somatório faz isso em cima dos locais corretos e soma $zp(z)$

$$\begin{aligned}
\mathbb{E}[Z] &= \sum_z z \mathbb{P}(Z = z) = \sum_z z \left(\sum_{g(x,y)=z} \mathbb{P}(X = x, Y = y) \right) \\
&= \sum_z \sum_{g(x,y)=z} z \mathbb{P}(X = x, Y = y) \\
&= \sum_z \sum_{g(x,y)=z} g(x, y) \mathbb{P}(X = x, Y = y) \\
&= \sum_{x,y} g(x, y) \mathbb{P}(X = x, Y = y)
\end{aligned} \tag{101}$$

□

5.3 Esperança e Independência

A esperança também pode ser afetada pela independência de variáveis aleatórias.

Teorema 5.3.1 (Esperança de Variáveis Aleatórias Independentes): Sejam X e Y variáveis aleatórias discretas independentes, então

$$\mathbb{E}[XY] = \mathbb{E}[X] \cdot \mathbb{E}[Y] \tag{102}$$

a volta não vale

Demonstração: Pela definição de independência, temos que

$$\mathbb{P}(X = x, Y = y) = \mathbb{P}(X = x) \cdot \mathbb{P}(Y = y) \tag{103}$$

então

$$\begin{aligned}
\mathbb{E}[XY] &= \sum_{x,y} xy \cdot \mathbb{P}(X = x, Y = y) \\
&= \sum_{x,y} xy \cdot \mathbb{P}(X = x) \cdot \mathbb{P}(Y = y) \\
&= \sum_x x \cdot \mathbb{P}(X = x) \sum_y y \cdot \mathbb{P}(Y = y) \\
&= \mathbb{E}[X] \cdot \mathbb{E}[Y]
\end{aligned} \tag{104}$$

Um contra exemplo para o caso contrário são as variáveis X e Y tais que

$$\mathbb{P}(X = 1, Y = 1) = \frac{1}{2} \quad \mathbb{P}(X = -1, Y = -1) = \frac{1}{2} \tag{105}$$

aqui conseguimos ver que

$$\mathbb{E}[X] = \mathbb{E}[Y] = 0 \tag{106}$$

no entanto

$$\mathbb{E}[XY] = 1 \tag{107}$$

pois $X \cdot Y$ é sempre 1

□

Acontece que, se duas variáveis são independentes, ao fazer XY , os valores de X não influenciam nos valores de Y , logo, todos os valores de XY são “igualmente” prováveis, não no sentido que

cada um tem $1/(|S|)$ de probabilidade, mas num sentido que, se eu pegar um valor de X e um valor de Y , a probabilidade de que eles se encontrem é a mesma, e isso é justamente o que a definição de independência nos diz. Já se eles não forem independentes, como o valor de X influencia no de Y , pode acontecer de existirem valores de XY mais prováveis de aparecer do que outros.

Exemplo (Caso de Independência): Suponha que eu jogue dois dados justos, e defino as variáveis aleatórias

$$X = \text{valor do dado 1} \quad Y = \text{valor do dado 2} \quad (108)$$

Então, X e Y são independentes, e temos que

$$\mathbb{E}[X] = \mathbb{E}[Y] = 3.5 \quad (109)$$

então

$$\mathbb{E}[XY] = \mathbb{E}[X] \cdot \mathbb{E}[Y] = 3.5 \cdot 3.5 = 12.25 \quad (110)$$

Exemplo (Caso de Dependência): Suponha que eu jogue **um** dado justo, e defino as variáveis aleatórias

$$X = \text{valor do dado} \quad Y = \text{valor do dado} \quad (111)$$

aqui é **dependência total**, então

$$X = Y \quad (112)$$

logo, se eu fizesse

$$XY \quad (113)$$

saber o valor de X **automaticamente me dá o valor de Y** , então

$$\mathbb{E}[X]\mathbb{E}[Y] \neq \mathbb{E}[XY] \quad (114)$$

5.4 Monotonicidade da Esperança

A esperança também é uma função **monótona**, ou seja, se uma variável aleatória é maior que outra, a esperança dela também será maior.

Teorema 5.4.1 (Monotonicidade da Esperança): Sejam X e Y variáveis aleatórias discretas, se $X \geq Y$, então

$$\mathbb{E}[X] \geq \mathbb{E}[Y] \quad (115)$$

Demonstração: Como $X \geq Y$, temos que $X - Y \geq 0$, então

$$\mathbb{E}[X - Y] \geq 0 \Leftrightarrow \mathbb{E}[X] - \mathbb{E}[Y] \geq 0 \Leftrightarrow \mathbb{E}[X] \geq \mathbb{E}[Y] \quad (116)$$

□

5.5 Função de Sobrevivência

Conseguimos expressar a esperança em termos da função de sobrevivência (Definição 4.4.2).

Teorema 5.5.1 (Esperança em termos da Função de Sobrevivência): Sejam X uma variável aleatória discreta não negativa, então

$$\mathbb{E}[X] = \sum_{x=0}^{\infty} G_X(x) \quad (117)$$

Demonstração: Seja I_j a variável aleatória definida como:

$$I_j = \begin{cases} 1 & X \geq j \\ 0 & X < j \end{cases} \quad (118)$$

consequimos decompor a variável aleatória X como

$$X = \sum_{j=1}^{\infty} I_j \quad (119)$$

por exemplo, se $X = 3$, então $I_1 = I_2 = I_3 = 1$ e $I_j = 0$ para $j > 3$. Então a esperança de X será

$$\mathbb{E}[X] = \mathbb{E}\left[\sum_{j=1}^{\infty} I_j\right] = \sum_{j=1}^{\infty} \mathbb{E}[I_j] \quad (120)$$

Agora só precisamos mostrar que $\mathbb{E}[I_j] = \mathbb{P}(X \geq j)$. Pela definição de I_j , sua esperança será

$$\mathbb{E}[I_j] = 1 \cdot \mathbb{P}(I_j = 1) + 0 \cdot \mathbb{P}(I_j = 0) = \mathbb{P}(I_j = 1) = \mathbb{P}(X \geq j) \quad (121)$$

logo

$$\mathbb{E}[X] = \sum_{j=1}^{\infty} \mathbb{P}(X \geq j) = \sum_{x=0}^{\infty} G_X(x) \quad (122)$$

□

Medidas de Dispersão

6.1 Introdução

Essas medidas nos ajudam a entender o **quanto** os valores da variável aleatória estão espalhados em torno da média. Se a esperança nos dá o valor que esperamos que a variável aleatória assuma, as medidas de dispersão nos dizem o quão “*bem comportadas*” essas variáveis são, elas se concentram perto da média? Ou elas se espalham em vários lugares? Para uma visualização visual do que essas medidas representam, acesse esse vídeo: [PREENCHER]

Definição 6.1.1 (Desvio Médio): O desvio médio de uma variável aleatória discreta X é definido por

$$DM[X] = \mathbb{E}[|X - \mathbb{E}[X]|] \quad (123)$$

Definição 6.1.2 (Variância): A variância de uma variável aleatória discreta X é definida por

$$\mathbb{V}[X] = \mathbb{E}[(X - \mathbb{E}[X])^2] \quad (124)$$

Definição 6.1.3 (Desvio Padrão): O desvio padrão de uma variável aleatória discreta X é definido por

$$\sigma[X] = \sqrt{\mathbb{V}[X]} \quad (125)$$

6.2 Propriedades

A variância e o desvio padrão são as medidas de dispersão mais utilizadas. Vamos enunciar e demonstrar algumas propriedades dessas medidas de dispersão.

Teorema 6.2.1:

$$\mathbb{V}[aX + b] = a^2 \mathbb{V}[X] \quad (126)$$

Demonstração:

$$\begin{aligned} \mathbb{V}[aX + b] &= \mathbb{E}[(aX + b - \mathbb{E}[aX + b])^2] \\ &= \mathbb{E}[(aX + b - (a\mathbb{E}[X] + b))^2] \\ &= \mathbb{E}[(aX - a\mathbb{E}[X])^2] \\ &= \mathbb{E}[a^2(X - \mathbb{E}[X])^2] \\ &= a^2 \mathbb{E}[(X - \mathbb{E}[X])^2] \\ &= a^2 \mathbb{V}[X] \end{aligned} \quad (127)$$

□

Teorema 6.2.2:

$$\sigma[aX + b] = |a| \sigma[X] \quad (128)$$

Demonstração: Pela propriedade anterior, temos que

$$\sigma[aX + b] = \sqrt{\mathbb{V}[aX + b]} = \sqrt{a^2 \mathbb{V}[X]} = |a| \sqrt{\mathbb{V}[X]} = |a| \sigma[X] \quad (129)$$

□

Teorema 6.2.3:

$$\text{DM}[aX + b] = |a| \text{DM}[X] \quad (130)$$

Demonstração: Pela definição de desvio médio, temos que

$$\begin{aligned} \text{DM}[aX + b] &= \mathbb{E}[|aX + b - \mathbb{E}[aX + b]|] \\ &= \mathbb{E}[|aX + b - (a\mathbb{E}[X] + b)|] \\ &= \mathbb{E}[|aX - a\mathbb{E}[X]|] \\ &= \mathbb{E}[|a| |X - \mathbb{E}[X]|] \\ &= |a| \mathbb{E}[|X - \mathbb{E}[X]|] \\ &= |a| \text{DM}[X] \end{aligned} \quad (131)$$

□

Intuitivamente, quando nós adicionamos uma constante b em uma variável, a média vai se descolar esse exato mesmo valor, no entanto, como todos os pontos vão se mover exatamente b unidades, a dispersão vai se manter a mesma. No entanto, se multiplicarmos a variável por uma constante a , os erros que já existiam vão se ampliar em a vezes, então a dispersão vai se multiplicar por a também.

Teorema 6.2.4 (Variância em função de Esperanças):

$$\mathbb{V}[X] = \mathbb{E}[X^2] - (\mathbb{E}[X])^2 \quad (132)$$

Demonstração:

$$\begin{aligned} \mathbb{V}[X] &= \mathbb{E}[(X - \mathbb{E}[X])^2] \\ &= \mathbb{E}[X^2 - 2X\mathbb{E}[X] + (\mathbb{E}[X])^2] \\ &= \mathbb{E}[X^2] - 2\mathbb{E}[X]\mathbb{E}[X] + (\mathbb{E}[X])^2 \\ &= \mathbb{E}[X^2] - (\mathbb{E}[X])^2 \end{aligned} \quad (133)$$

□

Existe também a variância da soma de variáveis aleatórias! No entanto, vale ressaltar que o teorema abaixo é um **caso específico** do Teorema 7.4.3

Teorema 6.2.5: Se X e Y são variáveis aleatórias independentes, então

$$\mathbb{V}[X + Y] = \mathbb{V}[X] + \mathbb{V}[Y] \quad (134)$$

Demonstração:

$$\begin{aligned}
\mathbb{V}[X + Y] &= \mathbb{E}[(X + Y)^2] - (\mathbb{E}[X + Y])^2 \\
&= \mathbb{E}[X^2 + 2XY + Y^2] - (\mathbb{E}[X] + \mathbb{E}[Y])^2 \\
&= \mathbb{E}[X^2] + 2\mathbb{E}[XY] + \mathbb{E}[Y^2] - (\mathbb{E}[X])^2 - 2\mathbb{E}[X]\mathbb{E}[Y] - (\mathbb{E}[Y])^2 \\
&= \mathbb{E}[X^2] + 2\mathbb{E}[X]\mathbb{E}[Y] + \mathbb{E}[Y^2] - (\mathbb{E}[X])^2 - 2\mathbb{E}[X]\mathbb{E}[Y] - (\mathbb{E}[Y])^2 \\
&= \mathbb{E}[X^2] - (\mathbb{E}[X])^2 + \mathbb{E}[Y^2] - (\mathbb{E}[Y])^2 \\
&= \mathbb{V}[X] + \mathbb{V}[Y]
\end{aligned} \tag{135}$$

□

6.3 Desigualdade de Chebyshev

Essa desigualdade nos dá uma generalização da probabilidade estar distante de sua média. Vamos ver o teorema e sua demonstração, depois nós elaboramos mais

Teorema 6.3.1 (Desigualdade de Chebyshev): Sejam X uma variável aleatória discreta com média $\mathbb{E}[X] = \mu$ e desvio padrão $\sigma = \sigma[X]$. Denote $P = \{x \in \mathbb{R} \mid |x - \mu| < k\sigma\}$, ou seja, P é o intervalo aberto $(x - k\sigma, x + k\sigma)$. Então, para qualquer $k > 0$, temos que

$$\mathbb{P}(X \notin P) \leq \frac{1}{k^2} \equiv \mathbb{P}(|X - \mu| \geq k\sigma) \leq \frac{1}{k^2} \tag{136}$$

Demonstração:

$$\begin{aligned}
\mathbb{V}[X] &= \mathbb{E}[(X - \mu)^2] \\
&= \sum_x (x - \mu)^2 \cdot \mathbb{P}(X = x) \\
&= \sum_{x \in P} (x - \mu)^2 \cdot \mathbb{P}(X = x) + \sum_{x \notin P} (x - \mu)^2 \cdot \mathbb{P}(X = x)
\end{aligned} \tag{137}$$

por conta da definição dos x no intervalo P , temos que, para valores de x que **não estão** no intervalo:

$$\begin{aligned}
|x - \mu| &\geq k\sigma \\
(x - \mu)^2 &\geq k^2\sigma^2
\end{aligned} \tag{138}$$

logo, como a primeira parte da soma é maior que 0, podemos fazer:

$$\begin{aligned}
\mathbb{V}[X] &\geq \sum_{x \notin P} \sigma^2 k^2 \cdot \mathbb{P}(X = x) \\
\sigma^2 &\geq \sigma^2 k^2 \sum_{x \notin P} \mathbb{P}(X = x) \\
1 &\geq k^2 \mathbb{P}(X \notin P) \\
\frac{1}{k^2} &\geq \mathbb{P}(X \notin P)
\end{aligned} \tag{139}$$

□

Como interpretamos esse teorema então?

- Existe no máximo $\frac{1}{4}$ de chance de uma variável aleatória estar a mais de 2 desvios padrões da média
- Existe no máximo $\frac{1}{9}$ de chance de uma variável aleatória estar a mais de 3 desvios padrões da média
- Existe no máximo $\frac{1}{16}$ de chance de uma variável aleatória estar a mais de 4 desvios padrões da média

E assim em diante para um k qualquer. Ou seja, ele atribui uma probabilidade máxima de o quão bem comportada a variável aleatória é, ou seja, o quão concentrada ela está em torno da média. Quanto maior o k , mais difícil é que os valores da variável aleatória estejam distantes. Isso também mostra uma quantificação de **valores extremos**. Por exemplo, é **muito improvável** que, ao jogar uma moeda honesta 100 vezes, eu consiga 90 caras. A desigualdade de chebyshev nos dá justamente uma formalização da intuição de que, quanto mais distante da média, mais improvável é que o evento ocorra.

Quantificadores de Independência

7.1 Quantificadores de Independência

A independência de variáveis aleatórias é um conceito muito importante, mas como podemos quantificar o quão independentes duas variáveis aleatórias são? Dizer se elas são independentes com uma tabelinha de probabilidades bonitinha é muito fácil, mas e se não temos essa informação? E se nossas probabilidades são **estimadas**? E se temos uma quantidade enorme de variáveis aleatórias e queremos saber quais são independentes entre si?

Definição 7.1.1 (Covariância): A covariância de duas variáveis aleatórias discretas X e Y é definida por

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])] \quad (140)$$

Como essa medida indica independência? Sabemos que $X - \mathbb{E}[X]$ é a distância dos valores de X até sua média. Quando isso é maior ou igual a 0, então a maioria dos valores está acima da média. Quando multiplicamos isso por $Y - \mathbb{E}[Y]$, se o valor for positivo e grande, é um indicativo que, conforme X está acima da média, Y **também está** acima da média. Se o valor for negativo e grande, é um indicativo que, conforme X está acima da média, Y **está abaixo** da média. Se o valor for próximo de 0, então não há uma relação clara entre as duas variáveis aleatórias. Mas vale ressaltar que a covariância mede a independência **linear** de variáveis. O fato de ela ser 0 **não significa** que as variáveis são 100% independentes. Antes de mostrar isso, vamos mostrar uma forma mais prática de calcular a covariância.

Teorema 7.1.1 (Covariância em função de Esperanças):

$$\text{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X] \cdot \mathbb{E}[Y] \quad (141)$$

Demonstração:

$$\begin{aligned} \text{Cov}(X, Y) &= \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])] \\ &= \mathbb{E}[XY - X\mathbb{E}[Y] - Y\mathbb{E}[X] + \mathbb{E}[X]\mathbb{E}[Y]] \\ &= \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y] - \mathbb{E}[Y]\mathbb{E}[X] + \mathbb{E}[X]\mathbb{E}[Y] \\ &= \mathbb{E}[XY] - \mathbb{E}[X] \cdot \mathbb{E}[Y] \end{aligned} \quad (142)$$

□

Agora sim podemos mostrar que correlação 0 **não implica independência**, mas o contrário vale.

Teorema 7.1.2:

$$X \text{ e } Y \text{ são independentes} \Rightarrow \text{Cov}(X, Y) = 0 \quad (143)$$

a volta não vale

Demonstração: Pelo Teorema 7.1.1, temos que

$$\text{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X] \cdot \mathbb{E}[Y] \quad (144)$$

como sabemos que X e Y são independentes, então $\mathbb{E}[XY] = \mathbb{E}[X] \cdot \mathbb{E}[Y]$, e portanto:

$$\text{Cov}(X, Y) = \mathbb{E}[X] \cdot \mathbb{E}[Y] - \mathbb{E}[X] \cdot \mathbb{E}[Y] = 0 \quad (145)$$

Agora se analisarmos a volta, vamos supor que $X = \{1, 0, -1\}$ e $Y = X^2$ de forma que $\mathbb{P}(X = i) = \frac{1}{3}$ para $i = 1, 0, -1$. Conseguimos ver que $\mathbb{E}[X] = 0$ e $\mathbb{E}[XY] = \mathbb{E}[X^3] = 0$, logo, temos que

$$\text{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X] \cdot \mathbb{E}[Y] = 0 - 0 \cdot \mathbb{E}[Y] = 0 \quad (146)$$

No entanto, vamos checar a condição de independência:

$$\begin{aligned} \mathbb{P}(X = 0, Y = 0) &= \mathbb{P}(X = 0) = \frac{1}{3} \\ \mathbb{P}(X = 0) \cdot \mathbb{P}(Y = 0) &= \frac{1}{3} \cdot \frac{1}{3} = \frac{1}{9} \end{aligned} \quad (147)$$

logo, X e Y **não são independentes** □

7.2 O Problema de Escala da Covariância

A covariância é muito útil, mas ela tem um problema, a **escala**. Vamos ver isso na prática com alguns exemplos

Exemplo: Sejam X a altura de uma população e Y o peso dessa população. Se X é medido em m e Y em kg , poderíamos obter uma covariância de

$$\text{Cov}(X, Y) = 0.7 \text{ m} \cdot \text{kg} \quad (148)$$

No entanto, se mudarmos a unidade de medida de X para cm e Y para g , teríamos

$$\text{Cov}(100 \cdot X, 1000 \cdot Y) = 100 \cdot 1000 \text{ Cov}(X, Y) = 70000 \text{ cm} \cdot \text{g} \quad (149)$$

Essas covariâncias representam a **mesma relação**, mas os números são completamente diferentes. Enquanto o primeiro aparenta ser uma correlação baixa, o segundo aparenta ser uma correlação altíssima.

Para resolver esses problemas de escala e dificuldade de interpretabilidade, nós utilizamos uma outra medida, a **correlação**.

Definição 7.2.1 (Correlação): A correlação de duas variáveis aleatórias discretas X e Y é definida por

$$\rho(X, Y) = \frac{\text{Cov}(X, Y)}{\sigma[X] \cdot \sigma[Y]} \quad (150)$$

A principal vantagem da correlação é que ela é **adimensional**, ou seja, ela não depende da unidade de medida das variáveis aleatórias. Além de se situar no intervalo $[-1, 1]$.

7.3 Aprofundamento: Covariância como Produto Interno

Esse tópico é um aprofundamento e preparação para futuras demonstrações dentro desse capítulo, se necessário, pode pular esse tópico na primeira leitura. Antes de provarmos algumas das propriedades da correlação (juntamente com a covariância), vamos definir ambas com um pouco de **álgebra linear**. Vamos definir a covariância como um **produto interno**.

Teorema 7.3.1 (Covariância como Produto Interno): Sejam X e Y variáveis aleatórias discretas, então a covariância entre X e Y pode ser interpretada como o produto interno entre dois vetores.

Demonstração: Sejam $X = \{x_i\}_{i=1}^m$ e $Y = \{y_i\}_{i=1}^n$, defina a matriz de probabilidade:

$$\begin{pmatrix} p_{11} & p_{12} & \cdots & p_{1n} \\ p_{21} & p_{22} & \cdots & p_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ p_{m1} & p_{m2} & \cdots & p_{mn} \end{pmatrix} \quad (151)$$

de forma que $\mathbb{P}(X = x_i, Y = y_j) = p_{ij}$. Defina também os vetores

$$\begin{aligned} v_X &= (x_1 \ x_1 \ \cdots \ x_1 \ x_2 \ x_2 \ \cdots \ x_2 \ \cdots \ x_m \ x_m \ \cdots \ x_m)^T \\ v_Y &= (y_1 \ y_2 \ \cdots \ y_n \ y_1 \ y_2 \ \cdots \ y_n \ \cdots \ y_1 \ y_2 \ \cdots \ y_n)^T \end{aligned} \quad (152)$$

e os vetores **resíduos**

$$\begin{aligned} r_X &= v_X - \mathbb{E}[X] \cdot \mathbb{1} \\ r_Y &= v_Y - \mathbb{E}[Y] \cdot \mathbb{1} \end{aligned} \quad (153)$$

onde $\mathbb{1}$ é o vetor coluna de números 1 do tamanho do vetor v_X e v_Y . Vamo definir $\omega(x, y)$ como o seguinte produto interno:

$$\omega(x, y) = \sum_{i,j} x_i y_j p_{ij} \quad (154)$$

segue a demonstração que essa função é um produto interno: Para ela ser um produto interno, é necessário satisfazer:

$$\begin{aligned} \omega(x, y) &= \omega(y, x) \\ \omega(\alpha x + \beta y, z) &= \alpha \omega(x, z) + \beta \omega(y, z) \\ \omega(x, x) &\geq 0 \quad \omega(x, x) = 0 \Leftrightarrow x = 0 \end{aligned} \quad (155)$$

Para a primeira condição:

$$\sum_{i,j} x_i y_j p_{ij} = \sum_{j,i} y_j x_i p_{ji} \quad (156)$$

Para a segunda condição:

$$\begin{aligned} \omega(\alpha x + \beta y, z) &= \sum_{i,j} (\alpha x_i + \beta y_i) z_j p_{ij} \\ &= \sum_{i,j} \alpha x_i z_j p_{ij} + \sum_{i,j} \beta y_i z_j p_{ij} \\ &= \alpha \sum_{i,j} x_i z_j p_{ij} + \beta \sum_{i,j} y_i z_j p_{ij} \\ &= \alpha \omega(x, z) + \beta \omega(y, z) \end{aligned} \quad (157)$$

Para a terceira condição: Perceba que $\omega(x, y) = \mathbb{E}[XY]$, logo, $\omega(x, x) = \mathbb{E}[X^2] \geq 0$ e é igual a 0 se, e somente se, $X = 0$.

Mostrado que essa função é um produto interno, podemos ver que a covariância é justamente o produto interno entre os vetores de resíduos:

$$\begin{aligned}\omega(r_X, r_Y) &= \sum_{i,j} (x_i - \mathbb{E}[X])(y_j - \mathbb{E}[Y])p_{ij} \\ &= \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])] \\ &= \text{Cov}(X, Y)\end{aligned}\tag{158}$$

□

7.4 Propriedades

Agora que sabemos que a covariância é um produto interno, podemos utilizar essa relação para demonstrar outras propriedades da covariância. Nem todas as propriedades aqui enunciadas utilizam dessa definição, mas já preparamos o terreno para não dividir em vários tópicos de propriedade.

Teorema 7.4.1:

$$\begin{aligned}\text{Cov}(X, Y) &= \text{Cov}(Y, X) \\ \text{Cov}(X, X) &= \mathbb{V}[X] \\ \text{Cov}(\alpha X + \beta Y, Z) &= \alpha \text{Cov}(X, Z) + \beta \text{Cov}(Y, Z)\end{aligned}\tag{159}$$

Demonstração: Segue da definição de produto interno

□

Teorema 7.4.2:

$$-1 \leq \rho(X, Y) \leq 1\tag{160}$$

Demonstração: Utilizando os vetores resíduos que definimos na demonstração do Teorema 7.3.1, temos que

$$\cos \theta = \frac{\omega(r_X, r_Y)}{\|r_X\| \|r_Y\|} = \frac{\text{Cov}(X, Y)}{\sigma[X] \cdot \sigma[Y]} = \rho(X, Y)\tag{161}$$

□

Teorema 7.4.3:

$$\mathbb{V}(X + Y) = \mathbb{V}[X] + \mathbb{V}[Y] + 2 \text{Cov}(X, Y)\tag{162}$$

Demonstração:

$$\begin{aligned}
\mathbb{V}[X + Y] &= \mathbb{E}[(X + Y)^2] - (\mathbb{E}[X + Y])^2 \\
&= \mathbb{E}[X^2 + 2XY + Y^2] - (\mathbb{E}[X])^2 - 2\mathbb{E}[X]\mathbb{E}[Y] - (\mathbb{E}[Y])^2 \\
&= \mathbb{E}[X^2] + 2\mathbb{E}[XY] + \mathbb{E}[Y^2] - (\mathbb{E}[X])^2 - 2\mathbb{E}[X]\mathbb{E}[Y] - (\mathbb{E}[Y])^2 \\
&= \mathbb{E}[X^2] - (\mathbb{E}[X])^2 + \mathbb{E}[Y^2] - (\mathbb{E}[Y])^2 + 2(\mathbb{E}[XY] - \mathbb{E}[X] \cdot \mathbb{E}[Y]) \\
&= \mathbb{V}[X] + \mathbb{V}[Y] + 2 \text{Cov}(X, Y)
\end{aligned} \tag{163}$$

□

Teorema 7.4.4:

$$\text{Cov}(aX + b, Y) = a \text{Cov}(X, Y) \tag{164}$$

Demonstração:

$$\begin{aligned}
\text{Cov}(aX + b, Y) &= \mathbb{E}[(aX + b - \mathbb{E}[aX + b])(Y - \mathbb{E}[Y])] \\
&= \mathbb{E}[(aX + b - (a\mathbb{E}[X] + b))(Y - \mathbb{E}[Y])] \\
&= \mathbb{E}[(aX - a\mathbb{E}[X])(Y - \mathbb{E}[Y])] \\
&= a\mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])] \\
&= a \text{Cov}(X, Y)
\end{aligned} \tag{165}$$

□

Teorema 7.4.5:

$$\rho(aX + b, Y) = \begin{cases} \rho(X, Y) & a > 0 \\ -\rho(X, Y) & a < 0 \end{cases} \tag{166}$$

Demonstração:

$$\begin{aligned}
\rho(aX + b, Y) &= \frac{\text{Cov}(aX + b, Y)}{\sigma[aX + b] \cdot \sigma[Y]} \\
&= \frac{a \text{Cov}(X, Y)}{|a| \sigma[X] \cdot \sigma[Y]}
\end{aligned} \tag{167}$$

e temos que

$$\frac{a}{|a|} = \text{sign}(a) \tag{168}$$

□

Distribuições de Variáveis Aleatórias Disc- retas

8.1 O que é uma distribuição?

Até o momento, o curso apresentou problemas que requerem um certo pensamento crítico e raciocínio lógico. As distribuições vem para nos dar uma forma de **automatizar** o raciocínio que fizemos até agora. Elas são funções matemáticas que descrevem o comportamento de variáveis aleatórias, ou seja, elas nos dão a probabilidade de cada valor que a variável aleatória pode assumir.

8.2 Bernoulli

Começamos com a distribuição mais simples, a **bernoulli**. Sempre que você encontrar situações que a variável assume apenas dois valores possíveis (*sim* e *não*, *cara* e *coroa*, *sucesso* e *fracasso*), você pode modelar isso com uma distribuição de bernoulli. A distribuição de bernoulli é a base para muitas outras distribuições, como a binomial, a geométrica, a hipergeométrica, entre outras.

Definição 8.2.1 (Distribuição de Bernoulli): Uma variável aleatória discreta X segue uma distribuição de bernoulli com parâmetro $p \in [0, 1]$ quando sua função de massa de probabilidade é dada por

$$p_X(x) = \begin{cases} p & x = 1 \\ 1 - p & x = 0 \\ 0 & \text{otherwise} \end{cases} \quad (169)$$

Denotamos como

$$X \sim \text{Bernoulli}(p) \quad (170)$$

Essa distribuição é muito útil para modelar eventos que podem ter apenas dois resultados, como cara ou coroa, sucesso ou fracasso, sim ou não, etc. Ela parece até bem bobinha, mas ela é a base para muitas outras distribuições que veremos mais a frente. Essa distribuição é a que se aplica justamente no caso de uma moeda honesta, onde $p = \frac{1}{2}$, basta montarmos a variável aleatória como 1 se for cara e 0 se for coroa.

Teorema 8.2.1: Se $X \sim \text{Bernoulli}(p)$, então

$$\begin{aligned} \mathbb{E}[X] &= p \\ \mathbb{V}[X] &= p(1 - p) \end{aligned} \quad (171)$$

Demonstração:

$$\begin{aligned} \mathbb{E}[X] &= 1 \cdot p + 0 \cdot (1 - p) = p \\ \mathbb{V}[X] &= \mathbb{E}[X^2] - (\mathbb{E}[X])^2 = p - p^2 = p(1 - p) \end{aligned} \quad (172)$$

□

8.3 Binomial

A partir de agora, vamos definir cada distribuição a partir de uma **história**, dessa forma, não ficamos limitados apenas à função de massa daquela distribuição, mas ao que essa distribuição significa. Sempre que um problema indicar que ele quer contar **de quantas formas** um evento pode ocorrer, ou **quantas vezes** um evento ocorre, provavelmente ele está pedindo para modelar o problema com uma distribuição binomial.

Definição 8.3.1 (Distribuição Binomial): Suponha que n tentativas de Bernoulli independentes sejam realizadas, cada uma com a mesma probabilidade p de sucesso. Seja X o **número de sucessos** nessas n jogadas, a distribuição de X é chamada de “*binomial*” com parâmetros n e p . Ela é denotada por

$$X \sim \text{Bin}(n, p) \quad (173)$$

Teorema 8.3.1 (PMF da Binomial): Se $X \sim \text{Bin}(n, p)$, então a função de massa de probabilidade de X é dada por

$$\mathbb{P}(X = k) = \binom{n}{k} p^k (1 - p)^{n-k} \quad (174)$$

para $k = 0, 1, 2, \dots, n$.

Demonstração: Imagine que temos as letras “S” e “F” representando sucesso e fracasso, respectivamente. Para achar a pmf da binomial, dado sua história, podemos imaginar que temos n espaços para formar uma sequência de “S” e “F” e queremos saber de quantas formas diferentes podemos fazer isso. Vamos supor que ocorreram k sucessos, então temos que escolher k espaços para colocar “S” e os outros $n - k$ espaços serão preenchidos com “F”. Ou seja, aplicando o princípio multiplicativo, a probabilidade seria

$$p^k (1 - p)^{n-k} \quad (175)$$

no entanto, existem $\binom{n}{k}$ formas diferentes de escolher os k espaços para colocar “S”. Logo, a probabilidade total será

$$\mathbb{P}(X = k) = \binom{n}{k} p^k (1 - p)^{n-k} \quad (176)$$

□

Teorema 8.3.2 (Simetria da Binomial): Se $X \sim \text{Bin}(n, p)$ e $q = 1 - p$, então

$$n - X \sim \text{Bin}(n, q) \quad (177)$$

Demonstração: Dada a história da distribuição, se X é a quantidade de sucessos entre n tentativas, então $n - X$ é a quantidade de fracassos entre n tentativas. Como a probabilidade de fracasso é $q = 1 - p$, então definindo $Y = n - X$, temos que:

$$\begin{aligned} \mathbb{P}(Y = k) &= \mathbb{P}(n - X = k) = \mathbb{P}(X = n - k) \\ &= \binom{n}{n - k} p^{n-k} (1 - p)^k = \binom{n}{k} q^k (1 - q)^{n-k} \end{aligned} \quad (178)$$

□

Teorema 8.3.3: Se $X \sim \text{Bin}(n, p)$, então

$$\begin{aligned}\mathbb{E}[X] &= np \\ \mathbb{V}[X] &= np(1-p)\end{aligned}\tag{179}$$

Demonstração: Vou demonstrar a esperança de duas formas. A primeira é a mais algébrica. Expresse a esperança de X como a definição:

$$\mathbb{E}[X] = \sum_{k=0}^n k \binom{n}{k} p^k (1-p)^{n-k}\tag{180}$$

pelo Teorema 1.6.2.1, podemos reescrever o somatório como

$$\mathbb{E}[X] = \sum_{k=1}^n n \binom{n-1}{k-1} p^k (1-p)^{n-k}\tag{181}$$

se tomarmos $j = k - 1$, também podemos reescrever o somatório como

$$\begin{aligned}\mathbb{E}[X] &= n \sum_{j=0}^{n-1} \binom{n-1}{j} p^{j+1} (1-p)^{n-1-j} \\ &= np \sum_{j=0}^{n-1} \binom{n-1}{j} p^j (1-p)^{n-1-j}\end{aligned}\tag{182}$$

perceba que o somatório ao lado é a soma de todas as probabilidades de uma distribuição binomial com parâmetros $n - 1$ e p , logo, o somatório é igual a 1. Portanto, temos que

$$\mathbb{E}[X] = np\tag{183}$$

A forma mais intuitiva é utilizando a história da distribuição. Lembra que falamos que ela é a **realização de múltiplas bernoullis independentes**? Como a Bernoulli pode ser expressa como 0 para fracasso e 1 para sucesso, podemos expressar a variável aleatória X como a soma de n variáveis aleatórias independentes de Bernoulli, ou seja,

$$X = \mathbb{I}_1 + \mathbb{I}_2 + \dots + \mathbb{I}_n\tag{184}$$

onde $\mathbb{I}_j \sim \text{Bernoulli}(p)$. Assim, a soma dessas variáveis será exatamente a quantidade de sucessos. Aplicando a linearidade da esperança, temos que

$$\mathbb{E}[X] = \mathbb{E}[\mathbb{I}_1 + \mathbb{I}_2 + \dots + \mathbb{I}_n] = \mathbb{E}[\mathbb{I}_1] + \mathbb{E}[\mathbb{I}_2] + \dots + \mathbb{E}[\mathbb{I}_n] = p + p + \dots + p = np\tag{185}$$

Para a variância, podemos utilizar a mesma ideia. Como as variáveis aleatórias de Bernoulli são independentes, temos que

$$\begin{aligned}\mathbb{V}[X] &= \mathbb{V}[\mathbb{I}_1 + \mathbb{I}_2 + \dots + \mathbb{I}_n] \\ &= \mathbb{V}[\mathbb{I}_1] + \mathbb{V}[\mathbb{I}_2] + \dots + \mathbb{V}[\mathbb{I}_n] \\ &= p(1-p) + p(1-p) + \dots + p(1-p) \\ &= np(1-p)\end{aligned}\tag{186}$$

□

8.4 Hípergeométrica

Essa é uma das mais confusas, pois sua história é bem longa, mas vamos simplificar ao máximo. Quando você conseguir associar um problema com retirar elementos de **dois grupos diferentes** (sem reposição), então você está diante de uma distribuição hípergeométrica.

Definição 8.4.1 (Distribuição Hípergeométrica): Suponha que tenhamos **uma urna** com w **bolas brancas** e b **bolas pretas**. Se tirarmos n bolas da urna *com reposição*, isso nos dá uma distribuição binomial para o número de bolas brancas que tiramos. No entanto, se tirarmos n bolas da urna **sem reposição**, e X for a quantidade de bolas brancas retiradas, então ela segue uma distribuição hípergeométrica, denotada como

$$X \sim \text{HGeo}(w, b, n) \quad (187)$$

Teorema 8.4.1 (PMF da Hípergeométrica): Se $X \sim \text{HGeo}(w, b, n)$, então a função de massa de probabilidade de X é dada por

$$\mathbb{P}(X = k) = \frac{\binom{w}{k} \binom{b}{n-k}}{\binom{w+b}{n}} \quad (188)$$

para $k = \max(0, n - b), \dots, \min(n, w)$.

Demonstração: Temos no total, $w + b$ bolas, e vamos retirar n no total, então nosso espaço amostral é o total de combinação que podemos fazer com n bolas dentre $w + b$, ou seja, $\binom{w+b}{n}$. Agora, para que tenhamos exatamente k bolas brancas, precisamos escolher k bolas dentre as w brancas e $n - k$ bolas dentre as b pretas. Pelo princípio multiplicativo, temos que o número de combinações possíveis é $\binom{w}{k} \cdot \binom{b}{n-k}$. $\square$

Teorema 8.4.2 (Simetria da Hípergeométrica): As distribuições

$$\begin{aligned} X &\sim \text{HGeo}(w, b, n) \\ Y &\sim \text{HGeo}(n, w + b - n, w) \end{aligned} \quad (189)$$

são idênticas

Demonstração: Pela história da distribuição, X é a quantidade de bolas brancas retiradas dentre n bolas retiradas de uma urna com w bolas brancas e b bolas pretas. Se nós criarmos um conjunto de etiquetas, e colocarmos nas bolas, de forma que, se a bola **possui** uma etiqueta, então nós tiramos ela quando estávamos amostrando as bolas, então sabemos que de todas as $w + b$ bolas, n tem a etiqueta e $w + b - n$ **não tem**. Com isso em mente, podemos afirmar que Y representa a quantidade de formas possíveis de escolher w e que essas w bolas **tem a etiqueta**, ou seja, são as bolas que foram retiradas. Logo, a quantidade de bolas brancas retiradas é a mesma que a quantidade de bolas com etiqueta dentre as w bolas brancas. Portanto, as distribuições são idênticas. $\square$

Teorema 8.4.3: Se $X \sim \text{HGeo}(w, b, n)$, então

$$\begin{aligned}\mathbb{E}[X] &= n \frac{w}{w+b} \\ \mathbb{V}[X] &= n \frac{w}{w+b} \frac{b}{b+w} \frac{w+b-n}{w+b-1}\end{aligned}\tag{190}$$

Demonstração: Vamos numerar as bolas brancas de 1 até w , e definir

$$\mathbb{I}_j = \begin{cases} 1 & \text{bola branca } j \text{ foi retirada} \\ 0 & \text{bola branca } j \text{ não foi retirada} \end{cases}\tag{191}$$

definindo essa variável indicadora, podemos expressar a variável aleatória X como

$$X = \mathbb{I}_1 + \mathbb{I}_2 + \dots + \mathbb{I}_w\tag{192}$$

vale ressaltar que X **não é binomial**, pois as variáveis aleatórias $\mathbb{I}_j$ **não são independentes**. No entanto, podemos utilizar a linearidade da esperança para calcular a esperança de X :

$$\mathbb{E}[X] = \mathbb{E}\left[\sum_{j=1}^w \mathbb{I}_j\right] = \sum_{j=1}^w \mathbb{E}[\mathbb{I}_j] = \sum_{j=1}^w \mathbb{P}(I_j = 1)\tag{193}$$

como cada bola tem a mesma probabilidade de ser retirada, temos que

$$\mathbb{P}(I_j = 1) = \frac{n}{w+b}\tag{194}$$

logo

$$\mathbb{E}[X] = n \frac{w}{w+b}\tag{195}$$

Para a variância, aplicamos ela em X , mas como $\mathbb{I}_j$ não são independentes, precisamos aplicar a correção com covariância conforme enunciado no Teorema 7.4.3:

$$\begin{aligned}\mathbb{V}[X] &= \mathbb{V}\left[\sum_{j=1}^w \mathbb{I}_j\right] \\ &= \sum_{j=1}^w \mathbb{V}[\mathbb{I}_j] + 2 \sum_{i < j} \text{Cov}(\mathbb{I}_i, \mathbb{I}_j)\end{aligned}\tag{196}$$

como $\mathbb{I}_j$ é bernoulli, pelo Teorema 8.2.1, temos que

$$\mathbb{V}[\mathbb{I}_j] = \frac{n}{w+b} \left(1 - \frac{n}{w+b}\right)\tag{197}$$

já para a covariância entre duas variáveis aleatórias $\mathbb{I}_i$ e $\mathbb{I}_j$, temos que

$$\text{Cov}(\mathbb{I}_i, \mathbb{I}_j) = \mathbb{E}[\mathbb{I}_i \mathbb{I}_j] - \mathbb{P}(\mathbb{I}_i = 1) \cdot \mathbb{P}(\mathbb{I}_j = 1)\tag{198}$$

pela definição de $\mathbb{I}_i$ e $\mathbb{I}_j$, $\mathbb{E}[\mathbb{I}_i \mathbb{I}_j] = 1$ apenas quando ambos são 1, logo

$$\mathbb{E}[\mathbb{I}_i \mathbb{I}_j] = \mathbb{P}(\mathbb{I}_i = 1, \mathbb{I}_j = 1)\tag{199}$$

Para que ambas as bolas apareçam na mesma amostragem, precisamos escolher $n - 2$ bolas dentre as $w + b - 2$ restantes, logo

$$\mathbb{P}(\mathbb{I}_i = 1, \mathbb{I}_j = 1) = \frac{\binom{w+b-2}{n-2}}{\binom{w+b}{n}} = \frac{n(n-1)}{(w+b)(w+b-1)} \quad (200)$$

logo

$$\text{Cov}(\mathbb{I}_i, \mathbb{I}_j) = \frac{n(n-1)}{(w+b)(w+b-1)} - \frac{n^2}{(w+b)^2} = -\frac{n(w+b-n)}{(w+b)^2(w+b-1)} \quad (201)$$

voltando para a variância de X , o termo abaixo

$$\begin{aligned} 2 \cdot \sum_{i < j} \text{Cov}(\mathbb{I}_i, \mathbb{I}_j) &= 2 \binom{w}{2} \left(-\frac{n(w+b-n)}{(w+b)^2(w+b-1)} \right) \\ &= -w(w-1)n \frac{w+b-n}{(w+b)^2(w+b-1)} \end{aligned} \quad (202)$$

somando tudo

$$\begin{aligned} \mathbb{V}[X] &= n \frac{w}{w+b} \left(1 - \frac{n}{w+b} \right) - w(w-1)n \frac{w+b-n}{(w+b)^2(w+b-1)} \\ &= n \frac{w}{w+b} - n^2 \frac{w}{(w+b)^2} - w(w-1)n \frac{w+b-n}{(w+b)^2(w+b-1)} \\ &= \frac{wn(w+b-n)}{(w+b)^2} \left(1 - \frac{w-1}{w+b-1} \right) \\ &= \frac{wn(w+b-n)}{(w+b)^2} \frac{b}{w+b-1} \end{aligned} \quad (203)$$

reorganizando

$$\mathbb{V}[X] = n \frac{w}{w+b} \frac{b}{b+w} \frac{w+b-n}{w+b-1} \quad (204)$$

□

8.5 Geométrica

Sempre que o seu problema puder ser associado com uma quantidade de tentativas até que um evento ocorra, você pode modelar o problema com uma distribuição geométrica. Ela é muito útil para modelar problemas de confiabilidade, como a quantidade de tentativas até que um equipamento falhe, ou a quantidade de tentativas até que um paciente se recupere.

Definição 8.5.1 (Distribuição Geométrica): Suponha que tenhamos uma sequência de tentativas de Bernoulli independentes, cada uma com a mesma probabilidade p de sucesso. Seja X o número de tentativas **até o primeiro sucesso** (inclusivo, ou seja, a tentativa do sucesso em si entra na contagem), a distribuição de X é chamada de “geométrica” com parâmetro p . Ela é denotada por

$$X \sim \text{Geom}(p) \quad (205)$$

Teorema 8.5.1 (PMF da Geométrica): Se $X \sim \text{Geom}(p)$, então a função de massa de probabilidade de X é dada por

$$\mathbb{P}(X = k) = (1 - p)^{k-1}p \quad (206)$$

para $k = 1, 2, 3, \dots$

Demonstração: Cada jogada que realizarmos terá a probabilidade $1 - p$ de falhar, logo, se queremos que o número de jogadas seja k , precisamos que as primeiras $k - 1$ jogadas falhem e a última jogada seja um sucesso. Pela regra do produto, temos que a probabilidade de isso acontecer é

$$(1 - p)^{k-1}p \quad (207)$$

□

Teorema 8.5.2: Se $X \sim \text{Geom}(p)$, então temos que

$$\begin{aligned} \mathbb{E}[X] &= \frac{1}{p} \\ \mathbb{V}[X] &= \frac{1 - p}{p^2} \end{aligned} \quad (208)$$

Demonstração: Sabemos que a função $f(x) = \frac{1}{1-x}$ converge e pode ser expressa como uma série geométrica, ou seja,

$$\frac{1}{1 - x} = \sum_{k=0}^{\infty} x^k \quad (209)$$

com $|x| < 1$. Derivando ambos os lados, temos que

$$\begin{aligned} \frac{df}{dx} &= \frac{1}{(1 - x)^2} \\ &= 1 + 2x + 3x^2 + 4x^3 + \dots \\ &= \sum_{k=1}^{\infty} kx^{k-1} \end{aligned} \quad (210)$$

e que a segunda derivada é tal que

$$\begin{aligned} \frac{d^2f}{dx^2} &= \frac{2}{(1 - x)^3} \\ &= 2 + 6x + 12x^2 + 20x^3 + \dots \\ &= \sum_{k=0}^{\infty} k(k - 1)x^{k-2} \end{aligned} \quad (211)$$

mas o que isso tem a ver? Veja que:

$$\begin{aligned}
\mathbb{E}[X] &= \sum_{k=1}^{\infty} k(1-p)^{k-1}p = p \sum_{k=1}^{\infty} k(1-p)^{k-1} \\
&= pf'(1-p) = \frac{p}{(1-(1-p))^2} \\
&= \frac{1}{p}
\end{aligned} \tag{212}$$

Para calcular a variância, vamos utilizar de um truque inteligente. Sabemos que $\mathbb{V}[X] = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$. Vamos então calcular $\mathbb{E}[X(X-1)]$:

$$\mathbb{E}[X(X-1)] = \mathbb{E}[X^2 - X] = \mathbb{E}[X^2] - \mathbb{E}[X] \tag{213}$$

utilizando o LOTUS (Teorema 5.2.2), temos que

$$\mathbb{E}[X(X-1)] = \sum_{k=0}^{\infty} k(k-1)(1-p)^{k-1}p \tag{214}$$

deixando p em evidência e tirando um fator $1-p$ para fora, temos que

$$\begin{aligned}
\mathbb{E}[X(X-1)] &= p(1-p) \sum_{k=0}^{\infty} k(k-1)(1-p)^{k-2} \\
&= p(1-p)f''(1-p) = 2p \frac{1-p}{(1-(1-p))^3} \\
&= 2 \frac{1-p}{p^2}
\end{aligned} \tag{215}$$

e como vimos antes

$$\begin{aligned}
\mathbb{E}[X^2] &= \mathbb{E}[X(X-1)] + \mathbb{E}[X] \\
&= 2 \frac{1-p}{p^2} + \frac{1}{p} = \frac{2-p}{p^2}
\end{aligned} \tag{216}$$

voltando para a variância, temos que

$$\begin{aligned}
\mathbb{V}[X] &= \mathbb{E}[X^2] - (\mathbb{E}[X])^2 \\
&= \frac{2-p}{p^2} - \frac{1}{p^2} = \frac{1-p}{p^2}
\end{aligned} \tag{217}$$

□

8.6 Binomial Negativa

Muito parecida com a geométrica, no entanto, é quando o problema pode ser modelado como a quantidade de tentativas até que múltiplos eventos ocorram. Por exemplo, a quantidade de tentativas até que um paciente se recupere **duas vezes**, ou a quantidade de tentativas até que um equipamento falhe **três vezes**.

Definição 8.6.1 (Distribuição Binomial Negativa): Suponha um experimento onde eu vou realizar tentativas de Bernoulli independentes até obter r **sucessos** e cada tentativa tem a mesma probabilidade p de sucesso. Seja X a quantidade de tentativas necessárias para obter r sucessos (onde o último sucesso entra na contagem), dizemos que X tem distribuição **binomial negativa** com parâmetros r e p , denotada por

$$X \sim \text{NegBin}(r, p) \quad (218)$$

Teorema 8.6.1 (PMF da Binomial Negativa): Se $X \sim \text{NegBin}(r, p)$, então a função de massa de probabilidade de X é dada por

$$\mathbb{P}(X = k) = \binom{k-1}{r-1} p^r (1-p)^{k-r} \quad (219)$$

para $k = r, r+1, r+2, \dots$

Demonstração: Seja Y o número de sucesso nas primeiras $k-1$ tentativas e Z o número de sucessos que ocorreram na k -ésima tentativa ($Z \in \{0, 1\}$). O r -ésimo sucesso acontece no k -ésimo lançamento se, e somente se, $Y = r-1$ e $Z = 1$, isto é

$$X = k \Leftrightarrow Y = r-1, Z = 1 \quad (220)$$

Como Y e Z são independentes, temos que

$$\mathbb{P}(X = k) = \mathbb{P}(Y = r-1, Z = 1) = \mathbb{P}(Y = r-1) \cdot \mathbb{P}(Z = 1) \quad (221)$$

como Y é binomial com parâmetros $k-1$ e p e Z é bernoulli com parâmetro p , temos que

$$\mathbb{P}(X = k) = \binom{k-1}{r-1} p^{r-1} (1-p)^{(k-1)-(r-1)} \cdot p = \binom{k-1}{r-1} p^r (1-p)^{k-r} \quad (222)$$

□

Teorema 8.6.2: Se $X \sim \text{NegBin}(r, p)$, então temos que

$$\begin{aligned} \mathbb{E}[X] &= \frac{r}{p} \\ \mathbb{V}[X] &= r \frac{1-p}{p^2} \end{aligned} \quad (223)$$

Demonstração: Assim como a binomial, podemos subdividir essa variável aleatória em r variáveis com outra distribuição. Se eu estou procurando r sucessos, eu posso dividir como a quantidade de jogadas até o primeiro, depois até o segundo etc. E isso é exatamente a distribuição geométrica. Ou seja, podemos expressar X como

$$X = Y_1 + Y_2 + \dots + Y_r \quad (224)$$

com $Y_j \sim \text{Geom}(p)$

Dessa forma, aplicando a linearidade da esperança, temos que

$$\mathbb{E}[X] = \mathbb{E}\left[\sum_{j=1}^r Y_j\right] = \sum_{j=1}^r \mathbb{E}[Y_j] = \sum_{j=1}^r \frac{1}{p} = \frac{r}{p} \quad (225)$$

aplicando a mesma coisa com a variância

$$\mathbb{V}[X] = \mathbb{V}\left[\sum_{j=1}^r Y_j\right] = \sum_{j=1}^r \mathbb{V}[Y_j] = \sum_{j=1}^r \frac{1-p}{p^2} = r \frac{1-p}{p^2} \quad (226)$$

□

8.7 Poisson

Essa é um pouco mais complexa. A poisson representa a quantidade de vezes que um evento ocorre em um intervalo de tempo fixo, mas sabendo quantas vezes ele ocorre em média. Por exemplo, fixando uma janela de 6 segundos, sabemos que em uma avenida passam em média 10 carros, mas não sabemos quantos carros vão passar em cada janela de 6 segundos, podem ser 10, 100 num dia de pico, ou até mais se acontecer algo inesperado, então não há limite para a quantidade real de contagem. Outro exemplo é, dentro de um intervalo fixo, quantas gotas de chuva vão cair em um lago? É literalmente impossível você **limitar** a quantidade de gotas, então a distribuição de poisson é perfeita para modelar esse tipo de problema.

Definição 8.7.1 (Distribuição de Poisson): Seja λ a **média** da quantidade de eventos que ocorrem em um intervalo de tempo fixo e X é a variável aleatória que representa quantas vezes o evento ocorreu nesse mesmo intervalo de tempo, então dizemos que X segue uma distribuição de Poisson com parâmetro λ , denotada por

$$X \sim \text{Poisson}(\lambda) \quad (227)$$

Teorema 8.7.1 (PMF da Poisson): Se $X \sim \text{Poisson}(\lambda)$, então a função de massa de probabilidade de X é dada por

$$\mathbb{P}(X = k) = \frac{\lambda^k e^{-\lambda}}{k!} \quad (228)$$

para $k = 0, 1, 2, \dots$

Demonstração: Estamos avaliando a ocorrência de um evento dentro de um intervalo de tempo fixo. Isso significa que eu posso realizar esse evento uma quantidade n de vezes, no entanto, como o intervalo de tempo não é finito, podemos assumir que n pode ser estendido ao infinito (pois eu não consigo afirmar quantas tentativas podem acontecer dentro do intervalo de tempo. Uma milissegundo? Uma hora? Uma semana? 1000 por milissegundo?). Então nós vamos pegar a distribuição binomial e vamos estender ela ao infinito. Sabemos que

$$\begin{aligned}
\mathbb{P}(X = x) &= \frac{n!}{(n-x)!x!} (p^x)(1-p)^{n-x} \\
&= \frac{n!}{(n-x)!x!} \cdot p^x \cdot \frac{n^x}{n^x} \left(1 - \frac{np}{n}\right)^{n-x} \\
&= \frac{(np)^x}{x!} \cdot \frac{n!}{(n-x)!n^x} \left(1 - \frac{np}{n}\right)^n \left(1 - \frac{np}{n}\right)^{-x}
\end{aligned} \tag{229}$$

tendendo n ao infinito, temos que

$$\lim_{n \rightarrow \infty} \mathbb{P}(X = x) = \lim_{n \rightarrow \infty} \underbrace{\frac{(np)^x}{x!}}_I \cdot \underbrace{\frac{n!}{(n-x)!n^x}}_{II} \underbrace{\left(1 - \frac{np}{n}\right)^n \left(1 - \frac{np}{n}\right)^{-x}}_{III} \tag{230}$$

pelo teorema da multiplicação de limites, podemos separar o limite em três partes. Vamos analisar cada uma separadamente.

I:

$$\begin{aligned}
\lim_{n \rightarrow \infty} \frac{n!}{(n-x)!n^x} &= \lim_{n \rightarrow \infty} \frac{n(n-1)(n-2)\dots(n-x+1)}{n^x} \\
&= \lim_{n \rightarrow \infty} \left(1 - \frac{1}{n}\right) \left(1 - \frac{2}{n}\right) \dots \left(1 - \frac{x-1}{n}\right) \\
&= 1
\end{aligned} \tag{231}$$

II:

$$\lim_{n \rightarrow \infty} \left(1 - \frac{np}{n}\right)^n \tag{232}$$

queremos fixar $\mathbb{E}[X] = np = \lambda$ como fixo

$$\lim_{n \rightarrow \infty} \left(1 - \frac{np}{n}\right)^n = \lim_{n \rightarrow \infty} \left(1 - \frac{\lambda}{n}\right)^n = e^{-\lambda} \tag{233}$$

III:

$$\lim_{n \rightarrow \infty} \left(1 - \frac{np}{n}\right)^{-x} = \lim_{n \rightarrow \infty} \left(1 - \frac{\lambda}{n}\right)^{-x} = 1 \tag{234}$$

logo, voltando para a fórmula original, temos que

$$\lim_{n \rightarrow \infty} \mathbb{P}(X = x) = \lambda^x \frac{e^{-\lambda}}{x!} \tag{235}$$

□

Teorema 8.7.2: Se $X \sim \text{Poisson}(\lambda)$, então temos que

$$\begin{aligned}
\mathbb{E}[X] &= \lambda \\
\mathbb{V}[X] &= \lambda
\end{aligned} \tag{236}$$

Demonstração:

$$\begin{aligned}\mathbb{E}[X] &= \sum_{k=0}^{\infty} k e^{-\lambda} \frac{\lambda^k}{k!} \\ &= e^{-\lambda} \sum_{k=0}^{\infty} \frac{\lambda^k}{(k-1)!}\end{aligned}\tag{237}$$

sabemos pela definição de e^x que

$$e^x = \sum_{k=0}^{\infty} \frac{x^k}{k!}\tag{238}$$

e tirando a derivada, que

$$e^x = \sum_{k=0}^{\infty} k \frac{x^{k-1}}{k!}\tag{239}$$

note que ao multiplicarmos por λ , temos

$$\lambda e^\lambda = \sum_{k=0}^{\infty} k \frac{\lambda^k}{k!}\tag{240}$$

logo

$$\mathbb{E}[X] = e^{-\lambda} \lambda e^\lambda = \lambda\tag{241}$$

Já para a variância, podemos utilizar o mesmo truque

$$\mathbb{V}[X] = \mathbb{E}[X^2] - (\mathbb{E}[X])^2\tag{242}$$

analisando $\mathbb{E}[X^2]$

$$\mathbb{E}[X^2] = \sum_{k=0}^{\infty} k^2 e^{-\lambda} \frac{\lambda^k}{k!}\tag{243}$$

vimos a derivada da função e^x e podemos tirar a segunda derivada, que é

$$e^x = \sum_{k=0}^{\infty} k(k-1) \frac{x^{k-2}}{k!}\tag{244}$$

ou seja, temos que

$$\lambda^2 e^\lambda = \sum_{k=0}^{\infty} k(k-1) \frac{\lambda^k}{k!}\tag{245}$$

logo

$$\mathbb{E}[X^2] = e^{-\lambda} (\lambda^2 e^\lambda + \lambda e^\lambda) = \lambda^2 + \lambda\tag{246}$$

então

$$\mathbb{V}[X] = \mathbb{E}[X^2] - (\mathbb{E}[X])^2 = \lambda^2 + \lambda - \lambda^2 = \lambda\tag{247}$$

□