

FGV EMap  
João Pedro Jerônimo

## Séries Temporais

Revisão para A1

Rio de Janeiro

2026

# Conteúdo

|       |                                                                     |    |
|-------|---------------------------------------------------------------------|----|
| 1     | Introdução às Séries Temporais .....                                | 3  |
| 1.1   | Definições .....                                                    | 4  |
| 1.2   | Por que modelar séries temporais é importante? .....                | 4  |
| 1.2.1 | Dependência Temporal dos Resíduos .....                             | 4  |
| 1.2.2 | Como identificar dependência temporal nos resíduos? .....           | 4  |
| 1.2.3 | Como modelar essa dependência? .....                                | 4  |
| 1.2.4 | Usos .....                                                          | 4  |
| 2     | Modelagem Clássica aplicada ao Tempo .....                          | 6  |
| 2.1   | Modelo linear padrão .....                                          | 7  |
| 2.2   | Balanco Viés-Variância .....                                        | 7  |
| 2.3   | Regularização Lasso e Ridge .....                                   | 7  |
| 2.3.1 | Lasso (Least Absolute Shrinkage and Selection Operator) .....       | 7  |
| 2.3.2 | Ridge Regression .....                                              | 7  |
| 2.4   | Generalized Additive Models (GAM) .....                             | 8  |
| 2.5   | Deep Learning (DL) .....                                            | 8  |
| 2.5.1 | Janelas, Batches e Seta do Tempo .....                              | 8  |
| 3     | Diagnóstico Visual .....                                            | 10 |
| 3.1   | Introdução .....                                                    | 11 |
| 3.2   | Covariáveis .....                                                   | 11 |
| 3.3   | Tendência .....                                                     | 12 |
| 3.4   | Sazonalidade .....                                                  | 12 |
| 3.5   | Resíduos .....                                                      | 13 |
| 3.6   | Split Temporal .....                                                | 14 |
| 4     | Estacionariedade e ACF .....                                        | 16 |
| 4.1   | Introdução .....                                                    | 17 |
| 4.2   | Exemplos de Série .....                                             | 17 |
| 4.3   | Conceitos .....                                                     | 18 |
| 4.4   | ACF e ACVF .....                                                    | 20 |
| 4.5   | IID v.s Ruído Branco .....                                          | 20 |
| 4.6   | Estimação Amostral .....                                            | 21 |
| 5     | Previsão e Baselines .....                                          | 25 |
| 5.1   | Previsão via Autocorrelação $\rho(h)$ e Esperança Condicional ..... | 26 |
| 5.2   | Métodos simples de previsão (baseline) .....                        | 29 |
| 5.2.1 | Método da média .....                                               | 29 |
| 5.2.2 | Método ingênuo (Passeio aleatório sem tendência) .....              | 30 |
| 5.2.3 | Método ingênuo sazonal .....                                        | 31 |
| 5.2.4 | Método do desvio (drift) .....                                      | 32 |
| 5.3   | Valores Ajustados V.S Previsões .....                               | 33 |
| 6     | Diagnóstico de Resíduos .....                                       | 34 |
| 7     | Métricas de Avaliação .....                                         | 36 |
| 8     | Transformações .....                                                | 38 |
| 9     | Modelo AR e PACF .....                                              | 40 |
| 10    | Modelos MA e Invertibilidade .....                                  | 42 |

# **Introdução às Séries Temporais**

## 1.1 Definições

**Definição 1.1.1** (Série Temporal de Tempo Discreto): Conjunto de observações  $y_t$  registradas em intervalos de tempo específico  $t$  medidas de forma **discreta**.

$$\{y_t\}_{t=1}^T \quad (1)$$

*Exemplo:* A temperatura de uma região registrada **diariamente**

**Definição 1.1.2** (Modelo de Séries Temporais): Um modelo de séries temporais para  $\{y_t\}$  é a **especificação da distribuição conjunta** de uma **sequência de variáveis aleatórias**  $\{Y_t\}$  das quais  $\{y_t\}$  é esperada ser uma realização

$$\mathbb{P}(X_1 \leq x_1, \dots, X_n \leq x_n), -\infty < x_1, \dots, x_n < \infty, n = 1, 2, \dots \quad (2)$$

Modelar essa distribuição é muito complexo, pois temos acesso apenas à uma realização da série temporal  $\{Y_t\}$ . Para contornar essa limitação, focamos nos momentos de **primeira** e **segunda** ordem

$$\mathbb{E}[Y_t] \text{ e } \mathbb{E}[Y_t Y_{t+h}] \quad (3)$$

## 1.2 Por que modelar séries temporais é importante?

Até agora, discutimos principalmente o tratamento de dados que não possuem uma estrutura temporal. No entanto, muitas vezes nos deparamos com dados onde o tempo desempenha um papel crucial.

### 1.2.1 Dependência Temporal dos Resíduos

Quando os modelos discutidos anteriormente não conseguem capturar completamente a estrutura dos dados, pode restar uma dependência temporal nos resíduos. Isso significa que as observações ao longo do tempo estão correlacionadas, e essa dependência não foi removida.

Modelar essa dependência temporal pode levar a previsões mais precisas, pois aproveitamos a informação contida na sequência temporal dos dados.

### 1.2.2 Como identificar dependência temporal nos resíduos?

Podemos utilizar ferramentas que vamos conhecer ao longo do curso, como gráficos de autocorrelação (ACF) e testes estatísticos (como o teste de Ljung-Box) para identificar padrões temporais nos resíduos. Esses métodos nos ajudam a verificar se há correlação significativa entre os resíduos em diferentes lags temporais.

### 1.2.3 Como modelar essa dependência?

Uma vez identificada a dependência temporal, podemos usar modelos de séries temporais, como por exemplo os modelos auto-regressivos (AR), modelos de média móvel (MA) ou modelos ARIMA, que são projetados para capturar e modelar essas dependências de maneira eficaz.

### 1.2.4 Usos

Existem 3 usos complementares **principais** para séries temporais:

**Descrever.** Entender o que aconteceu na série: tendência, sazonalidade, choques, mudanças de regime. A pergunta é interpretativa — *o que o traço temporal revela?*

**Diagnosticar.** Avaliar se um modelo (clássico com covariáveis, baseline ingênuo, etc.) ainda deixou memória no tempo nos resíduos. Se os erros em  $t$  e em  $t + h$  ainda se relacionam de forma sistemática, a estrutura temporal não foi absorvida. Ferramentas formais de identificação (por exemplo ACF e testes como Ljung-Box) entram mais adiante no curso; o ponto conceitual já agora é: diagnóstico temporal é parte do trabalho, não um acessório opcional.

**Prever.** Produzir expectativas para  $t + 1, \dots, t + h$  com base no passado disponível até  $t$ . Previsão boa não é apenas “ajustar bem o histórico”; é generalizar para a frente, sob a mesma seta do tempo

# **Modelagem Clássica aplicada ao Tempo**

## 2.1 Modelo linear padrão

É o modelo mais simples que podemos utilizar para modelar a dependência entre uma variável dependente  $y_t$  e variáveis explicativas  $x_{it}$  ao longo do tempo. Já vimos esse modelo  $n$  vezes nos semestres passados, então vou reescrever apenas os passos mais importantes

$$y_t = \beta_0 + \sum_{i=1}^P \beta_i x_{it} + \varepsilon_t \quad \varepsilon_t \sim N(0, \sigma^2) \quad (4)$$

ou, em forma matricial

$$y = X\beta + \varepsilon \quad \varepsilon \sim N(0, \sigma^2 I) \Rightarrow y \sim N(X\beta, \sigma^2 I) \quad (5)$$

onde  $y \in \mathbb{R}^T$  é o vetor das observações da variável dependente,  $X \in \mathbb{R}^{T \times P}$  é a matriz de observações das variáveis explicativas,  $\beta \in \mathbb{R}^P$  é o vetor de pesos atribuindo a importância de cada parâmetro para explicar  $y$  e  $\varepsilon \in \mathbb{R}^T$  é um ruído gaussiano. Com essa estrutura, podemos obter o estimador de máxima verossimilhança de  $\beta$

$$\hat{\beta} = (X^T X)^{-1} X^T y \quad (6)$$

## 2.2 Balanço Viés-Variância

Vale lembrar que dentro do ramo da estatística (inclusive das séries temporais), sempre existirá o balanço **viés e variância**. O erro mais comum de se minimizar em contextos estatísticos é o erro quadrático médio

$$\mathbb{E}[(y_t - \hat{y}_t)^2] = \text{Bias}(\hat{y}_t)^2 + \mathbb{V}[\hat{y}_t]^2 + \sigma^2 \quad (7)$$

Obter modelos mais precisos na previsão de  $y_t$  (com menos viés) acaba resultando em modelos com variação alta (mudanças pequenas nos dados podem impactar muito os resultados) e vice-versa

## 2.3 Regularização Lasso e Ridge

Quando temos muito mais parâmetros do que amostras, o modelo pode se tornar muito instável, e isso pode ser recorrente na análise de séries temporais. Pode ocorrer de um paciente poder ser analisado por apenas 3 semanas, enquanto o modelo leva em conta 15 informações sobre o mesmo. Nesses cenários, podemos introduzir um parâmetro de regularização em nossos modelos

### 2.3.1 Lasso (Least Absolute Shrinkage and Selection Operator)

Em vez de minimizarmos simplesmente o erro quadrático, adicionamos um peso nos valores absolutos dos coeficientes, de forma que se eles crescem muito em módulo, a nossa função de perda não diminui como esperado

$$\sum_{t=1}^T (y_t - \hat{y}_t)^2 + \lambda \sum_{i=1}^P |\beta_i| \quad (8)$$

essa abordagem tende a zerar alguns coeficientes, indicando quais coeficientes realmente influenciam ou não

### 2.3.2 Ridge Regression

Em vez dos valores absolutos, usamos a soma dos quadrados

$$\sum_{t=1}^T (y_t - \hat{y}_t)^2 + \lambda \sum_{i=1}^P \beta_i^2 \quad (9)$$

essa abordagem não costuma zerar os coeficientes, mas os puxa para muito próximo de 0

## 2.4 Generalized Additive Models (GAM)

Extensão dos modelos lineares, permitindo que cada variável possua uma função não-linear associada com ela. A estrutura do GAM é dada por

$$y_t = f_1(x_{1t}) + \dots + f_p(x_{pt}) + \varepsilon_t \quad (10)$$

Aqui,  $f_j(\cdot)$  são funções não-lineares suaves que modelam a relação entre  $y_t$  e  $x_{jt}$ . O exemplo mais conhecido de GAM são os modelos polinomiais

## 2.5 Deep Learning (DL)

Em deep learning, expressamos a relação entre  $y_t$  e suas covariáveis através de uma função complexa  $f$

$$y_t = f(x_{1t}, \dots, x_{pt}) + \varepsilon_t \quad (11)$$

onde  $f$  é uma função altamente flexível modelada por uma rede neural, capazes de capturar padrões complexos e não-lineares dos dados

### 2.5.1 Janelas, Batches e Seta do Tempo

As redes neurais, durante seu treinamento, assumem uma hipótese que muitas vezes esquecemos, mas que são MUITO importantes no nosso contexto. Os dados **podem ser trocados**, eu posso embaralhar minhas amostras **sem perda de informação**. No entanto, o conceito de séries temporais não permite essa premissa, o que podemos fazer para mitigar isso? É aí que entram as **janelas**, onde empacotamos o passado e a dependência temporal entre elas. Por exemplo, imagine que temos a seguinte sequência:

$$\{10, 12, 9, 14, 11, 13, 8, 15\} \quad (12)$$

para podermos alimentar essas informações em uma rede neural, vamos criar uma janela de tamanho 3 e gerar nossos conjuntos de dados e alvo

$$\begin{aligned} \text{Janela 1} &\rightarrow \{10, 12, 9\} \rightarrow 14 \\ \text{Janela 2} &\rightarrow \{11, 13, 8\} \rightarrow 15 \end{aligned} \quad (13)$$

perceba que eu sempre pego um conjunto de 3 valores e digo que o valor resultante (alvo) deve ser o seguinte e assim por diante. Dessa forma, a ordem **entre janelas** passa a ser irrelevante pois a informação de passado e como ele influencia na resposta está incorporada na própria janela. No entanto, vale ressaltar que a ordem **dentro da janela** é **sagrada** e **nunca deve ser alterada**, do contrário a informação temporal entre amostras **se perde**

Como nem tudo são flores, existem alguns pontos de atenção que devemos tomar cuidado. O primeiro é quando formos separar nossos dados nos conjuntos de **treino** e **teste**. Não podemos, ao realizar a divisão, criar janelas com dados em conjuntos diferentes. Por exemplo, se temos a seguinte série, e fazemos a seguinte separação:

$$\left\{ \underbrace{10, 12, 9, 14, 11}_{\text{TREINO}}, \underbrace{13, 8, 15 \dots}_{\text{TESTE}} \right\} \quad (14)$$

em hipótese alguma podemos, dentro das nossas janelas de treino, ter uma janela tipo  $\{14, 11, 13\}$ , pois estaríamos misturando pontos de treino e teste, de forma que nosso modelo estaria vendo o futuro fora do controlado

Além disso, devemos tomar cuidado com **janelas sobrepostas**. Como falei antes, criamos as janelas para que elas possam ser independentes, no entanto, é possível criar janelas que não são independentes (ainda podemos embaralhar elas como artimanha computacional). Por exemplo, dado a série:

$$\{10, 12, 9, 14, 11, 13, 8, 15, \dots\} \quad (15)$$

as janelas  $\{10, 12, 9\}$  e  $\{12, 9, 14\}$  se sobrepõe, de tal forma que elas **NÃO** são independentes pois contém a mesma parcela do passado e como ela influencia nos valores internos. O ponto é que, para um SGD, você **pode** embaralhar essas janelas, mas isso não lhe permite tratá-las como **independentes**

# **Diagnóstico Visual**

### 3.1 Introdução

Antes de testes formais, ARIMA, ACF, PACF, etc., podemos fazer um diagnóstico visual da série temporal. O objetivo é identificar padrões, tendências, sazonalidades e possíveis anomalias nos dados. Essa análise inicial nos ajuda a formular hipóteses sobre o comportamento da série e a escolher modelos apropriados para previsão. Podemos primeiro pensar na série como

$$y_t = T_t + S_t + R_t \quad (16)$$

onde  $T_t$  representa a tendência (nível que a série se move no médio/longo prazo),  $S_t$  a sazonalidade (padrões que se repetem em intervalos fixos) e  $R_t$  os resíduos (por definição, o que sobra após fixar  $T_t$  e  $S_t$ )

*Exemplo:* Vamos analisar a seguinte figura



Visualmente conseguimos identificar cada um dos componentes da série temporal.

**$T$ :** No médio/longo prazo, a tendência é um crescimento linear, com inclinação positiva. Mesmo que existam flutuações de subida e descida, é perceptível que a cada ano o valor de  $y_t$  tende a aumentar.  **$S$ :** A série mostra uma sazonalidade de subida no início de cada ano e descida no final, mostrando um padrão anual claro (mas de forma que a descida sempre se mantém acima do padrão anterior, gerando a tendência positiva citada anteriormente)

### 3.2 Covariáveis

Dentro dessa estrutura, podem existir também **covariáveis explicativas** que influenciam a série temporal. Por exemplo, em uma série de vendas de um produto, fatores como campanhas de marketing, feriados ou eventos especiais podem afetar os valores observados. Incorporar essas covariáveis nos modelos pode melhorar a precisão das previsões e fornecer insights sobre os fatores que impactam a série. Ainda dentro do nosso framework visual, podemos introduzir essas covariáveis como

$$y_t = \underbrace{T_t + S_t}_{\text{Estrutura Temporal}} + \underbrace{x_t^T \beta}_{\text{Covariáveis}} + R_t \quad (17)$$

Na prática,  $T_t$  e  $S_t$  são incorporados dentro de  $x_t$  e não são derivados explicitamente, mas é importante entender que eles existem e como eles caracterizam a série temporal. A análise visual pode nos ajudar a identificar quais covariáveis podem ser relevantes para o modelo e como elas se relacionam com os padrões observados na série.

### 3.3 Tendência

Tendência é o movimento lento do nível da série: crescimento, queda ou platô ao longo de muitos períodos. Em dados mensais, uma média móvel com janela da ordem de um ano (por exemplo 12) alisa oscilações curtas e ajuda a ver esse nível. A média móvel aqui é ajuda visual, não um modelo formal




Figura 2: Exemplo de tendência em uma série temporal

### 3.4 Sazonalidade

Sazonalidade é estrutura que se repete em fases do calendário (mês do ano, dia da semana, hora do dia, ...). Distinguir sazonalidade de “subiu uma vez e nunca mais” é parte da descrição. Três gráficos olham a mesma sazonalidade, mas respondem perguntas diferentes.

**Overlay por ano.** Eixo = mês; uma linha por ano. Serve para ver **o ciclo se repetindo**: o formato do ano (pico/vale em quais meses); se o padrão é estável ou muda de ano para ano (linhas parecidas vs. um ano “fora”); a amplitude. Anos mais “altos” no gráfico ainda carregam tendência — o formato relativo é o que importa




Figura 3: Exemplo de sazonalidade em uma série temporal (overlay por ano)

**Série sem tendência.** Plotar  $y_t$  menos a média móvel (12) no calendário real. Serve para ver a **onda anual na seta do tempo**, depois de tirar o nível lento  $T_t$ . Dá para ver se a oscilação volta

todo ano (liga a  $S_t$ ) e se a amplitude muda ao longo dos anos. Ainda mistura sazonalidade + ruído — não é puro.




Figura 4: Exemplo de sazonalidade em uma série temporal (série sem tendência)

**Boxplot por mês.** Resume o nível típico de cada mês, agregando os anos. Serve para o ranking (quais meses são sistematicamente mais altos/baixos), a dispersão dentro do mês (caixa larga = aquele mês varia muito entre anos) e outliers. Não mostra a trajetória no tempo — cada mês aparece uma vez.




Figura 5: Exemplo de boxplot por mês

Em uma frase: overlay = “como o ano se parece”; sem tendência = “a onda no tempo”; boxplot = “estatística por mês”

### 3.5 Resíduos

Por definição  $R_t = y_t - (T_t + S_t)$ , ou seja, o que sobra após extraírmos a tendência e a sazonalidade. Tomemos por exemplo o seguinte gráfico




Figura 6: Exemplo de resíduos em uma série temporal

Aqui, estratificamos  $T$  que é a média móvel, no entanto, o gráfico ainda contém a estrutura da **sazonalidade**. Podemos, nesse caso, interpretar a sazonalidade como a **média mensal** de  $y_t - T_t$  (detalhes serão melhor compreendidos posteriormente). Removendo essa sazonalidade  $S_t$ , então obtemos um gráfico dos resíduos




Figura 7: Exemplo de resíduos em uma série temporal

Essa extração visual é temporária, serve no momento para termos um entendimento do que são resíduos e como eles se comportam. Posteriormente, vamos aprender a extrair  $T$  e  $S$  de forma formal, utilizando modelos estatísticos

### 3.6 Split Temporal

Comentamos anteriormente sobre, para fazer modelos preditivos das séries temporais, para separar eles em **treino** e **teste**. Sendo mais formal, isso é feito a partir de um **split temporal**, onde, ao invés de embaralhar os dados, pegamos uma parte inicial da série para treino e uma parte final para teste a partir de uma data-fronteira.




Figura 8: Exemplo de split temporal em uma série temporal

# **Estacionariedade e ACF**

## 4.1 Introdução

Visualizamos anteriormente como utilizar de métodos **visuais** para identificar séries temporais, agora nosso foco vai ser formalizar esse conceito. Para tal, no entanto, precisamos definir alguns conceitos muito importantes, como média, covariância e a noção de **estacionariedade**


## 4.2 Exemplos de Série

Esses serão os exemplos que vamos utilizar de forma recorrente

*Exemplo (Ruído Branco):*

$$Y_t = \varepsilon_t \quad (18)$$

Não existe memória, cada instante contém um ruído que não conseguimos traçar a partir dos anteriores




Ruído branco

*Exemplo (AR):*

$$Y_t = \varphi Y_{t-1} + \varepsilon_t, \quad |\varphi| < 1 \quad (19)$$

Depende diretamente do valor anterior, mas não de valores mais antigos. A memória é curta, mas existe




AR(1)

*Exemplo (Passeio Aleatório):*

$$Y_t = Y_{t-1} + \varepsilon_t \quad (20)$$


Acumula os ruídos passados, de forma que a memória é longa e o valor atual depende de todos os valores anteriores



*Exemplo (Tendência Linear):*

$$Y_t = \beta_0 + \beta_1 t + \varepsilon_t \quad (21)$$

A tendência linear é um caso especial de passeio aleatório, onde o valor atual depende do tempo e de todos os valores anteriores



## 4.3 Conceitos

**Definição 4.3.1** (Função Média): Seja  $\{Y_t\}$  uma série temporal onde  $\mathbb{E}[Y_t^2] < \infty$ , então a média em cada instante, denotada como

$$\mu_Y(t) = \mathbb{E}[Y_t] \quad (22)$$

É a tendência central do processo ao longo de  $t$ . Em geral pode depender do tempo: nada obriga  $\mathbb{E}[Y_i] = \mathbb{E}[Y_j]$  para  $i \neq j$

Nos quatro exemplos que comentamos, temos que  $\mathbb{E}[\varepsilon_t] = 0$ , então temos que:

- **Ruído Branco:**  $\mu_Y(t) = 0$
- **Tendência Linear:**  $\mu_Y(t) = \beta_0 + \beta_1 t$
- **AR:**  $\mu_Y(t) = \varphi \cdot \mu_Y(t-1)$

- **Passeio Aleatório:**  $\mu_Y(t) = \mu_Y(t-1)$ , se considerarmos  $Y_0 = 0$ , então  $\mu_Y(t) = 0$ , percebe-se que se mantém constante, isso mostra que uma realização não altera a **média**, mas sim a **covariância** do processo, que cresce com o tempo

**Definição 4.3.2** (Covariância): Dados dois instantes  $r, s$ , definimos a covariância entre  $Y_r$  e  $Y_s$  como

$$\gamma_Y(r, s) = \mathbb{E}[(Y_r - \mu_Y(r))(Y_s - \mu_Y(s))] \quad (23)$$

Para vermos como a correlação nos exemplos vistos se comportam, tenha em mente que  $\mathbb{V}[\varepsilon_t] = \sigma^2$  e  $\gamma_\varepsilon(r, s) = 0$  para  $r \neq s$

- **Ruído Branco:**  $\gamma_Y(r, s) = 0$  para  $r \neq s$ , ou seja, não existe correlação entre os valores da série temporal e  $\gamma_Y(r, s) = \sigma^2$  se  $r = s$ , ou seja, a variância é constante ao longo do tempo
- **Tendência Linear:**

$$\begin{aligned} \gamma_{Y(r,s)} &= \text{Cov}(Y_r, Y_s) \\ &= \text{Cov}(\beta_0 + \beta_1 r + \varepsilon_r, \beta_0 + \beta_1 s + \varepsilon_s) \\ &= \text{Cov}(\varepsilon_r, \varepsilon_s) \\ &= \begin{cases} \sigma^2 & r = s \\ 0 & r \neq s. \end{cases} \end{aligned} \quad (24)$$

- **AR:** Dado que  $Y_t = \varphi Y_{t-1} + \varepsilon_t$ , então temos:

$$\mathbb{V}[Y_t] = \mathbb{V}[\varphi Y_{t-1} + \varepsilon_t] = \varphi^2 \mathbb{V}[Y_{t-1}] + \sigma^2 \quad (25)$$

e se assumirmos que  $Y_t = Y_{t-1}$ :

$$\mathbb{V}[Y_t] = \varphi^2 \mathbb{V}[Y_t] + \sigma^2 \Rightarrow \mathbb{V}[Y_t] = \frac{\sigma^2}{1 - \varphi^2} \quad (26)$$

- **Passeio Aleatório:** Assumindo o caso onde  $Y_t = \varepsilon_1 + \varepsilon_2 + \dots + \varepsilon_t$ , temos que:

$$\mathbb{V}[Y_t] = \mathbb{V}[\varepsilon_1 + \varepsilon_2 + \dots + \varepsilon_t] = t\sigma^2 \quad (27)$$

Ou seja, a variância do passeio aleatório cresce linearmente com o tempo. Além disso, a covariância entre dois instantes  $r$  e  $s$  é dada por

$$\gamma_Y(r, s) = \mathbb{E}[Y_r Y_s] = \mathbb{E}[(\varepsilon_1 + \dots + \varepsilon_r)(\varepsilon_1 + \dots + \varepsilon_s)] = \min(r, s)\sigma^2 \quad (28)$$

**Definição 4.3.3** (Estacionariedade Fraca): Dizemos que uma série temporal  $\{Y_t\}$  é **estacionária fraca** se:

- Média  $\mu_Y(t)$  é constante no tempo
- Covariância  $\gamma_Y(r, s)$  depende apenas da diferença  $|r - s|$  e não dos instantes absolutos  $r$  e  $s$

Como vemos pelos exemplos, as únicas séries que são estacionárias fracas são o **ruído branco** e o **AR**. A tendência linear e o passeio aleatório não são estacionários fracos, pois a média e a covariância dependem do tempo

## 4.4 ACF e ACVF

Como falamos, a covariância de uma série temporal estacionária fraca depende apenas da diferença entre os instantes, então podemos definir a função de covariância como uma função do lag  $h = |r - s|$ , assim:

**Definição 4.4.1** (ACVF): Dada a série temporal  $\{Y_t\}$  estacionária fraca, definimos a função de autocovariância como

$$\gamma_Y(h) = \mathbb{E}[(Y_r - \mu_Y)(Y_{r+h} - \mu_Y)] \quad (29)$$

**Definição 4.4.2** (ACF): Dada a série temporal  $\{Y_t\}$  estacionária fraca, definimos a função de autocorrelação como

$$\rho_Y(h) = \frac{\gamma_Y(h)}{\gamma_Y(0)} \quad (30)$$

A ACF é uma função que mede a correlação entre os valores da série temporal em diferentes lags. Ela nos ajuda a identificar padrões de dependência temporal e a determinar a ordem de modelos AR e MA, é como se ela fosse a função que mede a **memória** da série temporal. Vale ressaltar que não é porque uma série tem estacionaridade fraca que ela não possui memória, como vimos no caso do AR, que é estacionário fraco, mas possui memória curta. O mesmo não ocorre com o passeio aleatório, que não é estacionário fraco e possui memória longa

## 4.5 IID v.s Ruído Branco

A distinção entre um processo **I.I.D.** (independente e identicamente distribuído) e um **Ruído Branco** (White Noise - WN) baseia-se na intensidade da independência estocástica exigida entre os instantes de tempo

**Definição 4.5.1** (Ruído IID):  $\{Y_t\} \sim \text{I.I.D}(0, \sigma^2)$  com  $\sigma^2 < \infty$  se

$$\begin{aligned} \mathbb{E}[Y_t] &= 0 \\ \gamma_Y(h) &= \begin{cases} \sigma^2 & h = 0 \\ 0 & h \neq 0 \end{cases} \end{aligned} \quad (31)$$

Exige independência estocástica completa entre todas as variáveis aleatórias  $Y_t$  e  $Y_s$  ( $t \neq s$ ). Não há qualquer dependência (linear ou não-linear) ou variação nas distribuições marginais

**Definição 4.5.2** (Ruído Branco):  $\{Y_t\} \sim \text{WN}(0, \sigma^2)$  com  $\sigma^2 < \infty$  se

$$\begin{aligned} \mathbb{E}[Y_t] &= 0 \\ \gamma_Y(h) &= \begin{cases} \sigma^2 & h = 0 \\ 0 & h \neq 0 \end{cases} \end{aligned} \quad (32)$$

Exige apenas ausência de correlação linear ( $\text{Cov}(Y_{t+h}, Y_t) = 0$  para  $h \neq 0$ ) e estacionariedade de 2ª ordem

**Teorema 4.5.1** (Relação entre IID e White Noise):

$$\text{I.I.D } (0, \sigma^2) \Rightarrow \text{WN}(0, \sigma^2) \quad (33)$$

## 4.6 Estimação Amostral

No dia a dia, não conseguimos dizer com precisão os parâmetros de uma série temporal, como a média e a covariância. Para contornar essa limitação, utilizamos estimadores amostrais, que são funções das observações da série temporal que nos permitem inferir sobre os parâmetros populacionais

**Definição 4.6.1** (Estimador de média amostral de processo estocástico fracamente estacionário): Dada uma realização  $\{y_1, y_2, \dots, y_T\}$  de um processo estocástico fracamente estacionário  $\{Y_t\}$  com média populacional  $\mathbb{E}[Y_t] = \mu$  e função de autocovariância  $\gamma(h) = \text{Cov}(Y_t, Y_{t+h})$ , o estimador da média amostral é definido por

$$\bar{Y}_t = \frac{1}{T} \sum_{t=1}^T Y_t \quad (34)$$

**Teorema 4.6.1** (Não-viesamento e Variância da Média Amostral): Se  $\{Y_t\}$  for um processo fracamente estacionário com  $\mathbb{E}[Y_t] = \mu$  e autocovariância  $\gamma(h)$  então

- $\bar{Y}_t$  é um estimador não-viesado de  $\mu$
- A variância de  $\bar{Y}_t$  é dada por

$$\mathbb{V}[\bar{Y}_t] = \frac{1}{T} \sum_{h=-(T-1)}^{T-1} \left(1 - \frac{|h|}{T}\right) \gamma(h) \quad (35)$$

*Demonstração:* **Parte do não-viesamento:** Aplicamos a esperança no estimador

$$\mathbb{E}[\bar{Y}_t] = \mathbb{E}\left[\frac{1}{T} \sum_{t=1}^T Y_t\right] = \frac{1}{T} \sum_{t=1}^T \mathbb{E}[Y_t] = \frac{1}{T} \sum_{t=1}^T \mu = \mu \quad (36)$$

**Parte da variância:** Pela definição da variância da soma de variáveis aleatórias, temos

$$\mathbb{V}[\bar{Y}_t] = \mathbb{V}\left[\frac{1}{T} \sum_{t=1}^T Y_t\right] = \frac{1}{T^2} \mathbb{V}\left[\sum_{t=1}^T Y_t\right] = \frac{1}{T^2} \sum_{r=1}^T \sum_{s=1}^T \text{Cov}(Y_r, Y_s) \quad (37)$$

como o processo é fracamente estacionário, podemos reescrever a covariância como uma função do lag  $h = |r - s|$ , assim

$$\mathbb{V}[\bar{Y}_t] = \frac{1}{T^2} \sum_{r=1}^T \sum_{s=1}^T \gamma(|r - s|) \quad (38)$$

se agruparmos os pares  $(r, s)$  cuja a diferença  $r - s$  seja igual a um determinado lag  $h$  ( $\{-(T-1), \dots, T-1\}$ ), nota-se que existem exatamente  $T - |h|$  pares com aquele lag  $h$ . Logo, podemos reescrever a soma como

$$\mathbb{V}[\bar{Y}_t] = \frac{1}{T^2} \sum_{h=-(T-1)}^{T-1} (T - |h|) \gamma(h) = \frac{1}{T} \sum_{h=-(T-1)}^{T-1} \left(1 - \frac{|h|}{T}\right) \gamma(h) \quad (39)$$

□

**Definição 4.6.2** (Autocovariância Amostral): A autocovariância amostral usual para um lag  $h \geq 0$  é definida com o divisor  $T$

$$\hat{\gamma}(h) = \frac{1}{T} \sum_{t=1}^{T-h} (Y_t - \bar{Y}_t)(Y_{t+h} - \bar{Y}_t) \quad 0 \leq h < T \quad (40)$$

**Teorema 4.6.2** (Propriedades do estimador de Autocovariância Amostral):

1. O estimador de autocovariância amostral é viesado em amostra finita, mas é **assintoticamente não-viesado** (isto é,  $\lim_{T \rightarrow \infty} \mathbb{E}[\hat{\gamma}(h)] = \gamma(h)$ )
2. O uso do divisor  $T$  em vez de  $T - h$  garante que a matriz de autocovariância amostral seja **semi-definida positiva**, o que é importante para a consistência de estimadores de modelos de séries temporais e minimiza o MSE para lags elevados

*Demonstração:* Para simplificar a demonstração sem perder generalidade, considere inicialmente o estimador simplificado com  $\mu$  conhecido

$$\tilde{\gamma}(h) = \frac{1}{T} \sum_{t=1}^{T-h} (Y_t - \mu)(Y_{t+h} - \mu) \quad (41)$$

tomando a esperança desse estimador

$$\begin{aligned} \mathbb{E}[\tilde{\gamma}(h)] &= \frac{1}{T} \sum_{t=1}^{T-h} \mathbb{E}[(Y_t - \mu)(Y_{t+h} - \mu)] \\ &= \frac{1}{T} \sum_{t=1}^{T-h} \gamma(h) \\ &= \frac{T-h}{T} \gamma(h) \end{aligned} \quad (42)$$

logo

$$\mathbb{E}[\tilde{\gamma}(h)] - \gamma(h) = -\frac{h}{T} \gamma(h) \quad (43)$$

Quando substituimos  $\mu$  por  $\bar{Y}_t$ , o estimador se torna viesado, mas a diferença entre os dois estimadores é de ordem  $O(\frac{1}{T})$ , logo, o estimador com média amostral também é assintoticamente não-viesado

$$\lim_{T \rightarrow \infty} \mathbb{E}[\hat{\gamma}(h)] = \lim_{T \rightarrow \infty} \left(1 - \frac{h}{T}\right) \gamma(h) = \gamma(h) \quad (44)$$

Com relação à matriz semi-definida positiva, considere o vetor de observações centradas  $Y = (Y_1 - \bar{Y}_T, \dots, Y_T - \bar{Y}_T)^T$ . A matriz de autocovariância amostral de ordem  $k \times k$  definida como

$$\hat{\Gamma}_k = [\hat{\gamma}(i-j)]_{i,j=1}^k \quad (45)$$

pode ser escrita da seguinte forma matricial

$$\hat{\Gamma}_k = \frac{1}{T} X^T X \quad (46)$$

onde  $X_{rj} = Y_{r-j+1} - \bar{Y}_T$  para  $r \in \{1, \dots, T+k-1\}$  e  $j \in \{1, \dots, k\}$ . Para qualquer vetor não-nulo  $a = (a_1, \dots, a_k)^T \in \mathbb{R}^k$ :

$$a^T \hat{\Gamma}_k a = a^T \left( \frac{1}{T} X^T X \right) a = \frac{1}{T} (Xa)^T (Xa) = \frac{1}{T} \|Xa\|^2 \geq 0 \quad (47)$$

Se dividíssemos por  $T-h$  em vez de  $T$ , esse cancelamento matricial exato falharia, podendo gerar matrizes de autocovariância amostrais não-definidas positivas (com variâncias teóricas negativas para combinações lineares da série) e maior variabilidade estatística em  $h$  elevad  $\square$

**Definição 4.6.3** (Autocorrelação Amostral): A autocorrelação amostral é a razão normalizada

$$\hat{\rho}(h) = \frac{\hat{\gamma}(h)}{\hat{\gamma}(0)} \quad (48)$$

**Teorema 4.6.3** (Distribuição Limite sob Hipótese IID - Bartlett): Se  $\{Y_t\} \sim \text{IID}(0, \sigma^2)$  com  $\mathbb{E}[Y_t^4] < \infty$ , então para qualquer  $h > 0$  fixo, quando  $T \rightarrow \infty$ :

$$\sqrt{T} \hat{\rho}_h \xrightarrow{d} \mathcal{N}(0, 1) \quad (49)$$

e isso implica que  $\hat{\rho}_h \approx \mathcal{N}(0, \frac{1}{T})$  para  $T$  grande

*Demonstração:* Sob a hipótese de ruído IID, temos que  $\mu = 0$ ,  $\gamma(0) = \sigma^2$  e  $\gamma(k) = 0 \ \forall k \neq 0$ .

**Passo 1 - Comportamento do Numerador:** Considere o estimador  $\tilde{\gamma}(h) = \frac{1}{T} \sum_{t=1}^{T-h} Y_t Y_{t+h}$ . Defina a sequência de variáveis  $W_t = Y_t Y_{t+h}$ . Como  $\{Y_t\}$  é IID, de média 0

1.  $\mathbb{E}[W_t] = \mathbb{E}[Y_t Y_{t+h}] = \mathbb{E}[Y_t] \mathbb{E}[Y_{t+h}] = 0$
2. Para  $t \neq s$ , as variáveis  $W_t$  e  $W_s$  são não-correlacionadas (Formam uma sequência de diferenças de martingale)
3.  $\mathbb{V}[W_t] = \mathbb{E}[W_t^2] = \mathbb{E}[Y_t^2 Y_{t+h}^2] = \mathbb{E}[Y_t^2] \mathbb{E}[Y_{t+h}^2] = \sigma^4$

Pelo Teorema Central do Limite, para Sequências de Diferenças de Martingale, temos que

$$\sqrt{T} \tilde{\gamma}(h) = \frac{1}{\sqrt{T}} \sum_{t=1}^{T-h} W_t \xrightarrow{d} \mathcal{N}(0, \sigma^4) \quad (50)$$

**Passo 2 - Comportamento do Denominador:** O denominador  $\hat{\gamma}(0)$ , pela lei forte dos grandes números:

$$\hat{\gamma}(0) = \frac{1}{T} \sum_{t=1}^T (Y_t - \bar{Y}_T)^2 \xrightarrow{p} \mathbb{V}[Y_t] = \sigma^2 \quad (51)$$

**Passo 3 - Aplicação do Teorema de Slutsky:** A autocorrelação pode escrita como

$$\sqrt{T}\hat{\rho}(h) = \sqrt{T}\frac{\hat{\gamma}(h)}{\hat{\gamma}(0)} \quad (52)$$

Como a substituição de  $\bar{Y}_T$  por  $\mu = 0$  introduz apenas termos de ordem  $o_p(1)$  (que somem assintoticamente), aplicamos o Teorema de Slutsky combinando a convergência em distribuição do numerador com a convergência em probabilidade do denominador:

$$\sqrt{T}\hat{\rho}(h) = \frac{\sqrt{T}\hat{\gamma}(h)}{\hat{\gamma}(0)} \xrightarrow{d} \frac{\mathcal{N}(0, \sigma^4)}{\sigma^2} = \mathcal{N}\left(0, \frac{\sigma^4}{(\sigma^2)^2}\right) = \mathcal{N}(0, 1) \quad (53)$$

□

**Corolário 4.6.3.1** (*Construção formal do intervalo de confiança da ACF*): Do Teorema 4.6.3, decorre que quando temos um ruído IID e amostras grandes, podemos construir um intervalo de confiança para a autocorrelação amostral. Para um nível de confiança  $1 - \alpha$ :

$$\begin{aligned} \mathbb{P}\left(-z_{1-\alpha/2} \leq \sqrt{T}\hat{\rho}(h) \leq z_{1-\alpha/2}\right) &\approx 1 - \alpha \\ \mathbb{P}\left(-\frac{z_{1-\alpha/2}}{\sqrt{T}} \leq \hat{\rho}(h) \leq \frac{z_{1-\alpha/2}}{\sqrt{T}}\right) &\approx 1 - \alpha \end{aligned} \quad (54)$$

Com esse corolário, podemos interpretar o seguinte: Em um teste de nível de significância  $\alpha = 0.05$  (confiança 95%), usamos o quantil  $z_{0.975} \approx 1.96$ , logo o intervalo de confiança é dado por

$$\left[-\frac{1.96}{\sqrt{T}}, \frac{1.96}{\sqrt{T}}\right] \quad (55)$$

se o valor amostral  $\hat{\rho}(h)$  ultrapassar um desses limites, então rejeita-se a hipótese nula  $H_0$  da **ausência de autocorrelação** no lag  $h$ , ou seja, existe evidência de que a série temporal possui memória linear. Caso contrário, não rejeitamos a hipótese nula, indicando que não há evidência suficiente para afirmar que existe autocorrelação nesse lag

# **Previsão e Baselines**

No capítulo passado, nós definimos ACF, e como podemos utilizar ela para **diagnosticar** a presença de memória linear em uma série temporal. No entanto, não falamos sobre como utilizar essa informação para **prever** o futuro da série temporal

## 5.1 Previsão via Autocorrelação $\rho(h)$ e Esperança Condicional

**Definição 5.1.1:** Seja  $\{Y_t\}$  um processo estocástico **gaussiano e fracamente estacionário**, com média constante  $\mathbb{E}[Y_t] = \mu$ , variância  $\mathbb{V}[Y_t] = \gamma_Y(0) = \sigma^2$  e função de autocorrelação  $\rho_Y(h) = \gamma_Y(h)/\sigma^2$ . O vetor formado pela observação presente  $Y_n$  e pela observação futura  $Y_{n+h}$  segue uma distribuição normal bivariada

$$\begin{pmatrix} Y_n \\ Y_{n+h} \end{pmatrix} \sim \mathcal{N}\left(\begin{pmatrix} \mu \\ \mu \end{pmatrix}, \begin{pmatrix} \sigma^2 & \rho_Y(h)\sigma^2 \\ \rho_Y(h)\sigma^2 & \sigma^2 \end{pmatrix}\right) \quad (56)$$

**Teorema 5.1.1** (Condicional Gaussiana): Sob a hipótese de gaussianidade no processo  $\{Y_t\}$ , a distribuição condicional de  $Y_{n+h}$  dado  $Y_n = y_n$  é dada por

$$Y_{n+h} \mid Y_n = y_n \sim \mathcal{N}(\mu + \rho_Y(h)(y_n - \mu), \sigma^2(1 - \rho_Y(h)^2)) \quad (57)$$

*Demonstração:* Defina a variável transformada  $Z = (Y_{n+h} - \mu) - \beta(Y_n - \mu)$  onde  $\beta$  é uma constante real **a ser determinada** para que  $Z$  e  $Y_n$  sejam **não-correlacionadas**. Pela definição de covariância, temos que

$$\begin{aligned} \text{Cov}(Z, Y_n) &= \text{Cov}((Y_{n+h} - \mu) - \beta(Y_n - \mu), Y_n) \\ &= \text{Cov}(Y_{n+h}, Y_n) - \beta\mathbb{V}[Y_n] \\ &= \gamma_Y(h) - \beta\sigma^2 \end{aligned} \quad (58)$$

para anular a covariância, escolhemos  $\beta = \frac{\gamma_Y(h)}{\sigma^2} = \rho_Y(h)$ , assim:

$$Z = (Y_{n+h} - \mu) - \rho_Y(h)(Y_n - \mu) \quad (59)$$

como  $(Z, Y_n)$  é um vetor normal, temos que o fato de  $\text{Cov}(Z, Y_n) = 0$  implica que  $Z$  e  $Y_n$  são independentes. Utilizando desse fato, sabemos que

$$\begin{aligned} \mathbb{E}[Z \mid Y_n] &= \mathbb{E}[Z] = 0 \\ \mathbb{E}[Y_{n+h} - \mu - \rho_Y(h)(Y_n - \mu) \mid Y_n] &= 0 \\ \mathbb{E}[Y_{n+h} \mid Y_n] - \mu - \rho_Y(h)(Y_n - \mu) &= 0 \\ \mathbb{E}[Y_{n+h} \mid Y_n] &= \mu + \rho_Y(h)(Y_n - \mu) \end{aligned} \quad (60)$$

Já para a variância condicional, temos que

$$\mathbb{V}[Y_{n+h} \mid Y_n] = \mathbb{V}[Z + \rho_Y(h)(Y_n - \mu) \mid Y_n] \quad (61)$$

como é DADO  $Y_n$ , o termo  $\rho_Y(h)(Y_n - \mu)$  é uma constante, logo

$$\begin{aligned}
\mathbb{V}[Y_{n+h} | Y_n] &= \mathbb{V}[Z | Y_n] = \mathbb{V}[Z] \\
&= \mathbb{V}[Y_{n+h} - \mu - \rho_Y(h)(Y_n - \mu)] \\
&= \mathbb{V}[Y_{n+h}] + \rho_Y(h)^2 \mathbb{V}[Y_n] - 2\rho_Y(h) \text{Cov}(Y_{n+h}, Y_n) \\
&= \sigma^2 + \rho_Y(h)^2 \sigma^2 - 2\rho_Y(h) \gamma_Y(h) \\
&= \sigma^2 + \rho_Y(h)^2 \sigma^2 - 2\rho_Y(h)^2 \sigma^2 \\
&= \sigma^2(1 - \rho_Y(h)^2)
\end{aligned} \tag{62}$$

□

Dado esse contexto, podemos agora mostrar que para **qualquer preditor**  $g(Y_n)$ , **o preditor que minimiza o erro quadrático médio** é a **média condicional**  $\mathbb{E}[Y_{n+h} | Y_n]$ .

**Teorema 5.1.2** (Preditor que minimiza o MSE): Para qualquer preditor  $g(Y_n)$  baseado na observação  $Y_n$ , o preditor que minimiza o erro quadrático médio ( $\mathbb{E}[(Y_{n+h} - g(Y_n))^2]$ ) é dado por

$$g(Y_n) = \mathbb{E}[Y_{n+h} | Y_n] \tag{63}$$

*Demonstração:* Definindo o erro quadrático médio como  $f$ , temos:

$$f(y_n) = \mathbb{E}[(Y_{n+h} - g(Y_n))^2 | Y_n = y_n] \tag{64}$$

expandindo o termo quadrático, derivando e igualando a 0, vamos ter que

$$g(Y_n) = \mathbb{E}[Y_{n+h} | Y_n = y_n] \tag{65}$$

□

Sob a hipótese de gaussianidade, o preditor linear possui forma fechada de:

$$\mathbb{E}[Y_{n+h} | Y_n] = \mu + \rho_Y(h)(Y_n - \mu) \tag{66}$$

no entanto, sem essa premissa, o preditor linear pode não possuir forma fechada, mas ainda assim é o preditor que minimiza o erro quadrático médio. E como podemos perceber, a função  $\rho_Y(h)$  determina diretamente a qualidade e o formato da predição

- $\rho_Y(h) \rightarrow 0$ : A previsão tende a  $\mu$  e o erro quadrático médio tende a  $\sigma^2$ , ou seja, a informação presente  $Y_n$  não traz informação útil sobre o futuro  $Y_{n+h}$ . O melhor preditor reduz-se à média incondicional e a incerteza atinge a variância total da série
- $\rho_Y(h) \rightarrow 1$ : A previsão tende a  $Y_n$  e o erro quadrático médio tende a 0, ou seja, a informação presente  $Y_n$  praticamente carrega toda a informação sobre o futuro  $Y_{n+h}$ . O melhor preditor aproxima-se do valor atual e a incerteza diminui significativamente

Mas como eu comentei antes, esse é o melhor preditor **sobre gaussianidade**, mas não necessariamente o melhor preditor **sobre a série temporal**. No entanto, é possível chegar que, definindo um preditor genérico  $l(Y_n) = \alpha Y_n + \beta$ , o melhor  $l$  é exatamente o preditor linear que obtivemos na prova anterior

**Teorema 5.1.3** (Preditor Linear que minimiza o MSE): Para qualquer preditor linear  $l(Y_n) = \alpha Y_n + \beta$  baseado na observação  $Y_n$ , o preditor que minimiza o erro quadrático médio ( $\mathbb{E}[(Y_{n+h} - l(Y_n))^2]$ ) é dado por

$$l(Y_n) = \mu + \rho_Y(h)(Y_n - \mu) \quad (67)$$

e apresenta um erro quadrático médio de  $\sigma^2(1 - \rho_Y(h)^2)$

*Demonstração:* Queremos determinar os escalares  $\alpha$  e  $\beta$  que minimizam o erro quadrático médio

$$f(\alpha, \beta) = \mathbb{E}[(Y_{n+h} - (\alpha Y_n + \beta))^2] \quad (68)$$

expandindo o termo quadrático (e lembrando que  $\mathbb{E}[Y_n] = \mathbb{E}[Y_{n+h}] = \mu$ ), temos que

$$f(\alpha, \beta) = \mathbb{E}[Y_{n+h}^2] - 2\alpha\mathbb{E}[Y_n Y_{n+h}] - 2\beta\mu + \alpha^2\mathbb{E}[Y_n^2] + 2\alpha\beta\mu + \beta^2 \quad (69)$$

e derivando com relação à  $\alpha$

$$\frac{\partial f}{\partial \alpha} = -2\mathbb{E}[Y_n Y_{n+h}] + 2\alpha\mathbb{E}[Y_n^2] + 2\beta\mu = 0 \quad (70)$$

igualando a 0 e isolando  $\alpha$ , temos que

$$\alpha = \frac{\mathbb{E}[Y_n Y_{n+h}] - \beta\mu}{\mathbb{E}[Y_n^2]} \quad (71)$$

agora derivando com relação à  $\beta$

$$\frac{\partial f}{\partial \beta} = -2\mu + 2\alpha\mu + 2\beta = 0 \quad (72)$$

igualando a 0 e isolando  $\beta$ , temos que

$$\beta = \mu(1 - \alpha) \quad (73)$$

substituindo  $\beta$  na equação de  $\alpha$ , temos que

$$\begin{aligned} \alpha &= \frac{\mathbb{E}[Y_n Y_{n+h}] - \mu^2(1 - \alpha)}{\mathbb{E}[Y_n^2]} \\ \alpha\mathbb{E}[Y_n^2] &= \mathbb{E}[Y_n Y_{n+h}] - \mu^2 + \alpha\mu^2 \\ \alpha(\mathbb{E}[Y_n^2] - \mu^2) &= \mathbb{E}[Y_n Y_{n+h}] - \mu^2 \\ \alpha\mathbb{V}[Y_n] &= \text{Cov}(Y_n, Y_{n+h}) \\ \alpha &= \rho_Y(h) \end{aligned} \quad (74)$$

Voltando na equação de  $\beta$ , temos que

$$\beta = \mu(1 - \alpha) = \mu(1 - \rho_Y(h)) \quad (75)$$

agora substituindo na equação do preditor linear, temos que

$$\begin{aligned}
l(Y_n) &= \alpha Y_n + \beta \\
&= \rho_Y(h) Y_n + \mu(1 - \rho_Y(h)) \\
&= \mu + \rho_Y(h)(Y_n - \mu)
\end{aligned} \tag{76}$$

Substituindo isso tudo que encontramos na fórmula do erro quadrático médio, vamos acabar chegando que

$$f(\alpha, \beta) = \sigma^2(1 - \rho_Y(h)^2) \tag{77}$$


□

## 5.2 Métodos simples de previsão (baseline)

Um baseline estabelece o padrão mínimo. Se um modelo sofisticado perde para a média ou para o último valor (previsores que vimos anteriormente), o sofisticado ainda não justificou sua complexidade. O baseline estabelece um **limite inferior** para o desempenho de modelos mais complexos.

**Definição 5.2.1:**  $\hat{Y}_{T+h|T}$  representa a previsão do valor futuro  $Y_{T+h}$  dado os dados observados até o instante  $T$ .

### 5.2.1 Método da média



Média em série sem memória; previsão plana

Figura 9: Ilustração do método da média

Prevemos todas as observações futuras pela média aritmética histórica da amostra:

$$\hat{Y}_{T+h|T} = \bar{Y}_T = \frac{1}{T} \sum_{t=1}^T Y_t \quad \forall h \geq 1 \tag{78}$$

o método da média assume que o processo é **fracamente estacionário**, sem tendência e sem sazonalidade

$$Y_t = \mu + \varepsilon_t, \quad \varepsilon_t \sim \text{WN}(0, \sigma^2) \tag{79}$$

Corresponde ao caso em que a autocorrelação  $\rho(h) \approx 0$  para todo  $h \geq 1$  (série sem memória linear)

Conseguimos notar também que esse estimador é **não-viesado** e **consistente**, ou seja, a previsão converge para o valor real da série temporal à medida que o tamanho da amostra aumenta (pois a média amostral converge para a média populacional).

**Teorema 5.2.1.1** (Variância do Erro de Previsão):

$$\mathbb{V}[\varepsilon_{T+h}] = \sigma^2 \left(1 + \frac{1}{T}\right) \quad \forall h \geq 1 \quad (80)$$

Ou seja, a precisão converge para a variância do ruído branco à medida que o tamanho da amostra aumenta ( $T \rightarrow \infty$ )

*Demonstração:*

$$\begin{aligned} \mathbb{V}[Y_{T+h} - \bar{Y}_T] &= \mathbb{V}[\varepsilon_{T+h}] \\ &= \mathbb{V}[Y_{T+h}] + \mathbb{V}[\bar{Y}_T] - 2 \text{Cov}(Y_{T+h}, \bar{Y}_T) \\ &= \sigma^2 + \frac{\sigma^2}{T} \\ &= \sigma^2 \left(1 + \frac{1}{T}\right) \end{aligned} \quad (81)$$

Aqui a covariância entre  $Y_{T+h}$  e  $\bar{Y}_T$  é nula, pois o ruído branco não possui memória linear, logo não há correlação entre o valor futuro e a média amostral (além de que o valor futuro está fora dos valores utilizados para a estimação da média amostral, pois  $h \geq 1$ )  $\square$

## 5.2.2 Método ingênuo (Passeio aleatório sem tendência)



Ingênuo em passeio; previsão = último valor

Figura 10: Ilustração do método ingênuo

A previsão para qualquer horizonte futuro é o **último valor observado** da série

$$\hat{Y}_{T+h|T} = Y_T \quad \forall h \geq 1 \quad (82)$$

ele assume que o processo segue um **Passeio Aleatório** puro (não-estacionário na variância)

$$Y_t = Y_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim \text{IID}(0, \sigma^2) \quad (83)$$

É o caso limite em que a autocorrelação de curto prazo é extremamente alta ( $\rho(h) \approx 1$  para  $h$  pequeno). O estado atual  $Y_T$  é a melhor estimativa para a posição futura

O erro de previsão acaba por ser a soma dos ruídos futuros acumulados

$$Y_{T+h} - \hat{Y}_{T+h|T} = Y_{T+h} - Y_T = \varepsilon_{T+1} + \dots + \varepsilon_{T+h} \quad (84)$$

É fácil ver que o estimador é não-viezado (basta tirar a esperança do erro de previsão). E podemos mostrar que a variância da previsão aumenta linearmente com o horizonte de previsão, pois a variância do erro de previsão é a soma das variâncias dos ruídos futuros

**Teorema 5.2.2.1** (Variância do Erro de Previsão):

$$\mathbb{V}[Y_{T+h} - \hat{Y}_{T+h|T}] = h\sigma^2 \quad \forall h \geq 1 \quad (85)$$

Ou seja, a precisão da previsão diminui linearmente com o horizonte de previsão, pois a variância do erro de previsão aumenta linearmente com o horizonte de previsão

*Demonstração:*

$$\begin{aligned} \mathbb{V}[Y_{T+h} - \hat{Y}_{T+h|T}] &= \mathbb{V}[\varepsilon_{T+1} + \dots + \varepsilon_{T+h}] \\ &= \mathbb{V}[\varepsilon_{T+1}] + \dots + \mathbb{V}[\varepsilon_{T+h}] \\ &= h\sigma^2 \end{aligned} \quad (86)$$

□

### 5.2.3 Método ingênuo sazonal



Figura 11: Ilustração do método ingênuo sazonal

Para séries com sazonalidade de período  $m$  (ex:  $m = 12$  para dados mensais,  $m = 4$  para dados trimestrais), a previsão copia o valor observado na mesma fase do ciclo sazonal anterior

$$\hat{Y}_{T+h|T} = Y_{T+h-m(K+1)} \quad \forall h \geq 1 \quad K = \left\lfloor \frac{h-1}{m} \right\rfloor \quad (87)$$

Esse método assume um modelo de **Passeio Aleatório Sazonal** sem tendência:

$$Y_t = Y_{t-m} + \varepsilon_t, \quad \varepsilon_t \sim \text{IID}(0, \sigma^2) \quad (88)$$

Já aqui, conseguimos mostrar que a incerteza cresce não com  $h$ , mas a **cada ciclo sazonal completo**

$$\mathbb{V}[\varepsilon_{T+h}] = (K + 1)\sigma^2 \quad (89)$$

**Teorema 5.2.3.1** (Variância do Erro de Previsão):

$$\mathbb{V}[Y_{T+h} - \hat{Y}_{T+h|T}] = (K + 1)\sigma^2 \quad \forall h \geq 1 \quad K = \left\lfloor \frac{h-1}{m} \right\rfloor \quad (90)$$

Ou seja, a precisão da previsão diminui a cada ciclo sazonal completo, pois a variância do erro de previsão aumenta a cada ciclo sazonal completo

*Demonstração:*

$$\begin{aligned} \mathbb{V}[Y_{T+h} - \hat{Y}_{T+h|T}] &= \mathbb{V}[\varepsilon_{T+h-m(K+1)} + \dots + \varepsilon_{T+h}] \\ &= \mathbb{V}[\varepsilon_{T+h-m(K+1)}] + \dots + \mathbb{V}[\varepsilon_{T+h}] \\ &= (K + 1)\sigma^2 \end{aligned} \quad (91)$$

□

## 5.2.4 Método do desvio (drift)




Figura 12: Ilustração do método do desvio

Extrapolamos uma tendência linear permitindo que a previsão mude ao longo do tempo a uma taxa constante  $C$

$$\hat{Y}_{T+h|T} = Y_T + hC \quad \forall h \geq 1 \quad (92)$$

onde a taxa de variação (inclinação do desvio) é estimada pela variação média por período entre a primeira e a última observação da amostra

$$C = \frac{Y_T - Y_1}{T - 1} \quad (93)$$

na intuição geométrica, estamos traçando uma linha reta entre o primeiro e o último ponto da série temporal, e projetando essa linha para frente. Esse método assume um modelo de **Passeio Aleatório com Drift (Tendência)**:

$$Y_t = C + Y_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim \text{WN}(0, \sigma^2) \quad (94)$$

### 5.3 Valores Ajustados V.S Previsões

É importante notar que os métodos de previsão que vimos até agora são **modelos de previsão**, e não **modelos de ajuste**. Ou seja, eles não são modelos que descrevem a série temporal, mas sim modelos que descrevem como prever o futuro da série temporal.

Para um modelo de séries temporais ajustado sobre um conjunto de dados históricos  $\mathcal{F}_T = \{Y_1, \dots, Y_T\}$  temos as seguintes definições

**Definição 5.3.1** (Valores ajustados): O valor ajustado  $\hat{Y}_{t|t-1}$  é a estimativa **dentro da amostra** de um passo à frente ( $h = 1$ ) para instantes passados  $t = 2, 3, \dots, T$ . Representa o valor que o modelo teria previsto para o instante  $t$  conhecendo as observações anteriores  $Y_1, Y_2, \dots, Y_{t-1}$  e com parâmetros globais **já calibrados na amostra completa**

**Definição 5.3.2** (Previsão (Forecast)): A previsão  $\hat{Y}_{T+h|T}$  são as projeções **fora da amostra** de  $h$  passos à frente ( $h \geq 1$ ) para instantes futuros  $t = T + 1, T + 2, \dots$ . Utilizam estritamente a informação disponível até o instante de corte  $T$ , sem qualquer acesso visual ou numérico às realizações reais de  $Y_{T+h}$

# **Diagnóstico de Resíduos**



# **Métricas de Avaliação**



# Transformações



## **Modelo AR e PACF**



# **Modelos MA e Invertibilidade**

