

FGV EMap
João Pedro Jerônimo

Séries Temporais

Revisão para A1

Rio de Janeiro

2026

Conteúdo

1	Introdução às Séries Temporais	4
1.1	Definições	5
1.2	Por que modelar séries temporais é importante?	5
1.2.1	Dependência Temporal dos Resíduos	5
1.2.2	Como identificar dependência temporal nos resíduos?	5
1.2.3	Como modelar essa dependência?	5
1.2.4	Usos	5
2	Modelagem Clássica aplicada ao Tempo	7
2.1	Modelo linear padrão	8
2.2	Balanco Viés-Variância	8
2.3	Regularização Lasso e Ridge	8
2.3.1	Lasso (Least Absolute Shrinkage and Selection Operator)	8
2.3.2	Ridge Regression	8
2.4	Generalized Additive Models (GAM)	9
2.5	Deep Learning (DL)	9
2.5.1	Janelas, Batches e Seta do Tempo	9
3	Diagnóstico Visual	11
3.1	Introdução	12
3.2	Covariáveis	12
3.3	Tendência	13
3.4	Sazonalidade	13
3.5	Resíduos	14
3.6	Split Temporal	15
4	Estacionariedade e ACF	17
4.1	Introdução	18
4.2	Exemplos de Série	18
4.3	Conceitos	19
4.4	ACF e ACVF	21
4.5	IID v.s Ruído Branco	21
4.6	Estimação Amostral	22
5	Previsão e Baselines	26
5.1	Previsão via Autocorrelação $\rho(h)$ e Esperança Condicional	27
5.2	Métodos simples de previsão (baseline)	30
5.2.1	Método da média	30
5.2.2	Método ingênuo (Passeio aleatório sem tendência)	31
5.2.3	Método ingênuo sazonal	32
5.2.4	Método do desvio (drift)	33
5.3	Valores Ajustados V.S Previsões	34
6	Diagnóstico de Resíduos	35
6.1	Introdução	36
6.2	Testes de Autocorrelação conjunta	36
6.2.1	Teste de Box-Pierce	36
6.2.2	Teste de Ljung-Box	37
6.2.3	Distribuição Assintótica e Regra de Decisão Formal	37
6.2.4	Intervalos de Precisão	38
6.3	Intervalo de Previsão por Bootstrap	39

7	Métricas de Avaliação	41
7.1	Erro de previsão V.S Resíduos	42
7.2	Métricas de Avaliação Pontual	42
7.2.1	Métricas de Escala	42
7.2.2	Erros Percentuais	43
7.2.3	Erros Escalados	43
7.3	Métricas de Avaliação Distribucional	44
7.3.1	Erro de Quantil	44
7.3.2	Score de Winkler	45
7.3.3	Continuous Ranked Probability Score	47
8	Transformações	49
8.1	Box-Cox	50
8.2	Operador de Defasagem (Backshift)	51
8.3	Diferenciação	51
8.3.1	Diferenciação de Primeira Ordem	51
8.3.2	Diferenciação de Segunda Ordem	51
9	Modelo AR e PACF	52
9.1	Modelos Autoregressivos (AR)	53
9.1.1	Caso especial AR(1)	53
9.1.2	Estacionariedade do AR(p)	53
9.2	Função de Autocorrelação Parcial (PACF)	55
10	Modelos MA e Invertibilidade	56
10.1	Modelo de Média Móvel (MA)	57
10.2	AR(1) como MA(∞)	57
10.3	Invertibilidade e Representação AR(∞) de um MA(q)	57
10.4	Armadilha Matemática da Não-Identificabilidade do MA(1) não invertível	58
10.5	PACF e ACF do MA(q)	59
11	Modelo ARIMA	60
11.1	Formulação Geral	61
11.2	C e d em Previsões de Longo Prazo	61
11.2.1	$C = 0$ e $d = 0$	61
11.2.2	$C = 0$ e $d = 1$	61
11.2.3	$C \neq 0$ e $d = 1$	62
11.2.4	$d = 2$	62
11.3	Por que ARMA e não só AR ou MA?	63

Introdução às Séries Temporais

1.1 Definições

Definição 1.1.1 (Série Temporal de Tempo Discreto): Conjunto de observações y_t registradas em intervalos de tempo específico t medidas de forma **discreta**.

$$\{y_t\}_{t=1}^T \quad (1)$$

Exemplo: A temperatura de uma região registrada **diariamente**

Definição 1.1.2 (Modelo de Séries Temporais): Um modelo de séries temporais para $\{y_t\}$ é a **especificação da distribuição conjunta** de uma **sequência de variáveis aleatórias** $\{Y_t\}$ das quais $\{y_t\}$ é esperada ser uma realização

$$\mathbb{P}(X_1 \leq x_1, \dots, X_n \leq x_n), -\infty < x_1, \dots, x_n < \infty, n = 1, 2, \dots \quad (2)$$

Modelar essa distribuição é muito complexo, pois temos acesso apenas à uma realização da série temporal $\{Y_t\}$. Para contornar essa limitação, focamos nos momentos de **primeira** e **segunda** ordem

$$\mathbb{E}[Y_t] \text{ e } \mathbb{E}[Y_t Y_{t+h}] \quad (3)$$

1.2 Por que modelar séries temporais é importante?

Até agora, discutimos principalmente o tratamento de dados que não possuem uma estrutura temporal. No entanto, muitas vezes nos deparamos com dados onde o tempo desempenha um papel crucial.

1.2.1 Dependência Temporal dos Resíduos

Quando os modelos discutidos anteriormente não conseguem capturar completamente a estrutura dos dados, pode restar uma dependência temporal nos resíduos. Isso significa que as observações ao longo do tempo estão correlacionadas, e essa dependência não foi removida.

Modelar essa dependência temporal pode levar a previsões mais precisas, pois aproveitamos a informação contida na sequência temporal dos dados.

1.2.2 Como identificar dependência temporal nos resíduos?

Podemos utilizar ferramentas que vamos conhecer ao longo do curso, como gráficos de autocorrelação (ACF) e testes estatísticos (como o teste de Ljung-Box) para identificar padrões temporais nos resíduos. Esses métodos nos ajudam a verificar se há correlação significativa entre os resíduos em diferentes lags temporais.

1.2.3 Como modelar essa dependência?

Uma vez identificada a dependência temporal, podemos usar modelos de séries temporais, como por exemplo os modelos auto-regressivos (AR), modelos de média móvel (MA) ou modelos ARIMA, que são projetados para capturar e modelar essas dependências de maneira eficaz.

1.2.4 Usos

Existem 3 usos complementares **principais** para séries temporais:

Descrever. Entender o que aconteceu na série: tendência, sazonalidade, choques, mudanças de regime. A pergunta é interpretativa — *o que o traço temporal revela?*

Diagnosticar. Avaliar se um modelo (clássico com covariáveis, baseline ingênuo, etc.) ainda deixou memória no tempo nos resíduos. Se os erros em t e em $t + h$ ainda se relacionam de forma sistemática, a estrutura temporal não foi absorvida. Ferramentas formais de identificação (por exemplo ACF e testes como Ljung-Box) entram mais adiante no curso; o ponto conceitual já agora é: diagnóstico temporal é parte do trabalho, não um acessório opcional.

Prever. Produzir expectativas para $t + 1, \dots, t + h$ com base no passado disponível até o momento. Previsão boa não é apenas “ajustar bem o histórico”; é generalizar para a frente, sob a mesma seta do tempo

Modelagem Clássica aplicada ao Tempo

2.1 Modelo linear padrão

É o modelo mais simples que podemos utilizar para modelar a dependência entre uma variável dependente y_t e variáveis explicativas x_{it} ao longo do tempo. Já vimos esse modelo n vezes nos semestres passados, então vou reescrever apenas os passos mais importantes

$$y_t = \beta_0 + \sum_{i=1}^P \beta_i x_{it} + \varepsilon_t \quad \varepsilon_t \sim N(0, \sigma^2) \quad (4)$$

ou, em forma matricial

$$y = X\beta + \varepsilon \quad \varepsilon \sim N(0, \sigma^2 I) \Rightarrow y \sim N(X\beta, \sigma^2 I) \quad (5)$$

onde $y \in \mathbb{R}^T$ é o vetor das observações da variável dependente, $X \in \mathbb{R}^{T \times P}$ é a matriz de observações das variáveis explicativas, $\beta \in \mathbb{R}^P$ é o vetor de pesos atribuindo a importância de cada parâmetro para explicar y e $\varepsilon \in \mathbb{R}^T$ é um ruído gaussiano. Com essa estrutura, podemos obter o estimador de máxima verossimilhança de β

$$\hat{\beta} = (X^T X)^{-1} X^T y \quad (6)$$

2.2 Balanço Viés-Variância

Vale lembrar que dentro do ramo da estatística (inclusive das séries temporais), sempre existirá o balanço **viés e variância**. O erro mais comum de se minimizar em contextos estatísticos é o erro quadrático médio

$$\mathbb{E}[(y_t - \hat{y}_t)^2] = \text{Bias}(\hat{y}_t)^2 + \mathbb{V}[\hat{y}_t]^2 + \sigma^2 \quad (7)$$

Obter modelos mais precisos na previsão de y_t (com menos viés) acaba resultando em modelos com variação alta (mudanças pequenas nos dados podem impactar muito os resultados) e vice-versa

2.3 Regularização Lasso e Ridge

Quando temos muito mais parâmetros do que amostras, o modelo pode se tornar muito instável, e isso pode ser recorrente na análise de séries temporais. Pode ocorrer de um paciente poder ser analisado por apenas 3 semanas, enquanto o modelo leva em conta 15 informações sobre o mesmo. Nesses cenários, podemos introduzir um parâmetro de regularização em nossos modelos

2.3.1 Lasso (Least Absolute Shrinkage and Selection Operator)

Em vez de minimizarmos simplesmente o erro quadrático, adicionamos um peso nos valores absolutos dos coeficientes, de forma que se eles crescem muito em módulo, a nossa função de perda não diminui como esperado

$$\sum_{t=1}^T (y_t - \hat{y}_t)^2 + \lambda \sum_{i=1}^P |\beta_i| \quad (8)$$

essa abordagem tende a zerar alguns coeficientes, indicando quais coeficientes realmente influenciam ou não

2.3.2 Ridge Regression

Em vez dos valores absolutos, usamos a soma dos quadrados

$$\sum_{t=1}^T (y_t - \hat{y}_t)^2 + \lambda \sum_{i=1}^P \beta_i^2 \quad (9)$$

essa abordagem não costuma zerar os coeficientes, mas os puxa para muito próximo de 0

2.4 Generalized Additive Models (GAM)

Extensão dos modelos lineares, permitindo que cada variável possua uma função não-linear associada com ela. A estrutura do GAM é dada por

$$y_t = f_1(x_{1t}) + \dots + f_p(x_{pt}) + \varepsilon_t \quad (10)$$

Aqui, $f_j(\cdot)$ são funções não-lineares suaves que modelam a relação entre y_t e x_{jt} . O exemplo mais conhecido de GAM são os modelos polinomiais

2.5 Deep Learning (DL)

Em deep learning, expressamos a relação entre y_t e suas covariáveis através de uma função complexa f

$$y_t = f(x_{1t}, \dots, x_{pt}) + \varepsilon_t \quad (11)$$

onde f é uma função altamente flexível modelada por uma rede neural, capaz de capturar padrões complexos e não-lineares dos dados

2.5.1 Janelas, Batches e Seta do Tempo

As redes neurais, durante seu treinamento, assumem uma hipótese que muitas vezes esquecemos, mas que são MUITO importantes no nosso contexto. Os dados **podem ser trocados**, eu posso embaralhar minhas amostras **sem perda de informação**. No entanto, o conceito de séries temporais não permite essa premissa, o que podemos fazer para mitigar isso? É aí que entram as **janelas**, onde empacotamos o passado e a dependência temporal entre elas. Por exemplo, imagine que temos a seguinte sequência:

$$\{10, 12, 9, 14, 11, 13, 8, 15\} \quad (12)$$

para podermos alimentar essas informações em uma rede neural, vamos criar uma janela de tamanho 3 e gerar nossos conjuntos de dados e alvo

$$\begin{aligned} \text{Janela 1} &\rightarrow \{10, 12, 9\} \rightarrow 14 \\ \text{Janela 2} &\rightarrow \{11, 13, 8\} \rightarrow 15 \end{aligned} \quad (13)$$

perceba que eu sempre pego um conjunto de 3 valores e digo que o valor resultante (alvo) deve ser o seguinte e assim por diante. Dessa forma, a ordem **entre janelas** passa a ser irrelevante pois a informação de passado e como ele influencia na resposta está incorporada na própria janela. No entanto, vale ressaltar que a ordem **dentro da janela** é **sagrada** e **nunca deve ser alterada**, do contrário a informação temporal entre amostras **se perde**

Como nem tudo são flores, existem alguns pontos de atenção que devemos tomar cuidado. O primeiro é quando formos separar nossos dados nos conjuntos de **treino** e **teste**. Não podemos, ao realizar a divisão, criar janelas com dados em conjuntos diferentes. Por exemplo, se temos a seguinte série, e fazemos a seguinte separação:

$$\left\{ \underbrace{10, 12, 9, 14, 11}_{\text{TREINO}}, \underbrace{13, 8, 15}_{\text{TESTE}} \dots \right\} \quad (14)$$

em hipótese alguma podemos, dentro das nossas janelas de treino, ter uma janela tipo $\{14, 11, 13\}$, pois estaríamos misturando pontos de treino e teste, de forma que nosso modelo estaria vendo o futuro fora do controlado

Além disso, devemos tomar cuidado com **janelas sobrepostas**. Como falei antes, criamos as janelas para que elas possam ser independentes, no entanto, é possível criar janelas que não são independentes (ainda podemos embaralhar elas como artimanha computacional). Por exemplo, dado a série:

$$\{10, 12, 9, 14, 11, 13, 8, 15, \dots\} \quad (15)$$

as janelas $\{10, 12, 9\}$ e $\{12, 9, 14\}$ se sobrepõem, de tal forma que elas **NÃO** são independentes pois contém a mesma parcela do passado e como ela influencia nos valores internos. O ponto é que, para um SGD, você **pode** embaralhar essas janelas, mas isso não lhe permite tratá-las como **independentes**

Diagnóstico Visual


3.1 Introdução

Antes de testes formais, ARIMA, ACF, PACF, etc., podemos fazer um diagnóstico visual da série temporal. O objetivo é identificar padrões, tendências, sazonalidades e possíveis anomalias nos dados. Essa análise inicial nos ajuda a formular hipóteses sobre o comportamento da série e a escolher modelos apropriados para previsão. Podemos primeiro pensar na série como

$$y_t = T_t + S_t + R_t \quad (16)$$

onde T_t representa a tendência (nível que a série se move no médio/longo prazo), S_t a sazonalidade (padrões que se repetem em intervalos fixos) e R_t os resíduos (por definição, o que sobra após fixar T_t e S_t)

Exemplo: Vamos analisar a seguinte figura



Visualmente conseguimos identificar cada um dos componentes da série temporal.

T: No médio/longo prazo, a tendência é um crescimento linear, com inclinação positiva. Mesmo que existam flutuações de subida e descida, é perceptível que a cada ano o valor de y_t tende a aumentar. **S:** A série mostra uma sazonalidade de subida no início de cada ano e descida no final, mostrando um padrão anual claro (mas de forma que a descida sempre se mantém acima do padrão anterior, gerando a tendência positiva citada anteriormente)

3.2 Covariáveis

Dentro dessa estrutura, podem existir também **covariáveis explicativas** que influenciam a série temporal. Por exemplo, em uma série de vendas de um produto, fatores como campanhas de marketing, feriados ou eventos especiais podem afetar os valores observados. Incorporar essas covariáveis nos modelos pode melhorar a precisão das previsões e fornecer insights sobre os fatores que impactam a série. Ainda dentro do nosso framework visual, podemos introduzir essas covariáveis como

$$y_t = \underbrace{T_t + S_t}_{\text{Estrutura Temporal}} + \underbrace{x_t^T \beta}_{\text{Covariáveis}} + R_t \quad (17)$$

Na prática, T_t e S_t são incorporados dentro de x_t e não são derivados explicitamente, mas é importante entender que eles existem e como eles caracterizam a série temporal. A análise visual pode nos ajudar a identificar quais covariáveis podem ser relevantes para o modelo e como elas se relacionam com os padrões observados na série.

3.3 Tendência

Tendência é o movimento lento do nível da série: crescimento, queda ou platô ao longo de muitos períodos. Em dados mensais, uma média móvel com janela da ordem de um ano (por exemplo 12) alisa oscilações curtas e ajuda a ver esse nível. A média móvel aqui é ajuda visual, não um modelo formal




Figura 2: Exemplo de tendência em uma série temporal

3.4 Sazonalidade

Sazonalidade é estrutura que se repete em fases do calendário (mês do ano, dia da semana, hora do dia, ...). Distinguir sazonalidade de “subiu uma vez e nunca mais” é parte da descrição. Três gráficos olham a mesma sazonalidade, mas respondem perguntas diferentes.

Overlay por ano. Eixo = mês; uma linha por ano. Serve para ver **o ciclo se repetindo**: o formato do ano (pico/vale em quais meses); se o padrão é estável ou muda de ano para ano (linhas parecidas vs. um ano “fora”); a amplitude. Anos mais “altos” no gráfico ainda carregam tendência — o formato relativo é o que importa




Figura 3: Exemplo de sazonalidade em uma série temporal (overlay por ano)

Série sem tendência. Plotar y_t menos a média móvel (12) no calendário real. Serve para ver a **onda anual na seta do tempo**, depois de tirar o nível lento T_t . Dá para ver se a oscilação volta

todo ano (liga a S_t) e se a amplitude muda ao longo dos anos. Ainda mistura sazonalidade + ruído — não é puro.




Figura 4: Exemplo de sazonalidade em uma série temporal (série sem tendência)

Boxplot por mês. Resume o nível típico de cada mês, agregando os anos. Serve para o ranking (quais meses são sistematicamente mais altos/baixos), a dispersão dentro do mês (caixa larga = aquele mês varia muito entre anos) e outliers. Não mostra a trajetória no tempo — cada mês aparece uma vez.




Figura 5: Exemplo de boxplot por mês

3.5 Resíduos

Por definição $R_t = y_t - (T_t + S_t)$, ou seja, o que sobra após extraírmos a tendência e a sazonalidade. Tomemos por exemplo o seguinte gráfico




Figura 6: Exemplo de resíduos em uma série temporal

Aqui, estratificamos T que é a média móvel, no entanto, o gráfico ainda contém a estrutura da **sazonalidade**. Podemos, nesse caso, interpretar a sazonalidade como a **média mensal** de $y_t - T_t$ (detalhes serão melhor compreendidos posteriormente). Removendo essa sazonalidade S_t , então obtemos um gráfico dos resíduos




Figura 7: Exemplo de resíduos em uma série temporal

Essa extração visual é temporária, serve no momento para termos um entendimento do que são resíduos e como eles se comportam. Posteriormente, vamos aprender a extrair T e S de forma formal, utilizando modelos estatísticos

3.6 Split Temporal

Comentamos anteriormente sobre, para fazer modelos preditivos das séries temporais, para separar eles em **treino** e **teste**. Sendo mais formal, isso é feito a partir de um **split temporal**, onde, ao invés de embaralhar os dados, pegamos uma parte inicial da série para treino e uma parte final para teste a partir de uma data-fronteira.




Figura 8: Exemplo de split temporal em uma série temporal

Estacionariedade e ACF

4.1 Introdução

Visualizamos anteriormente como utilizar de métodos **visuais** para identificar séries temporais, agora nosso foco vai ser formalizar esse conceito. Para tal, no entanto, precisamos definir alguns conceitos muito importantes, como média, covariância e a noção de **estacionariedade**


4.2 Exemplos de Série

Esses serão os exemplos que vamos utilizar de forma recorrente

Exemplo (Ruído Branco):

$$Y_t = \varepsilon_t \quad (18)$$

Não existe memória, cada instante contém um ruído que não conseguimos traçar a partir dos anteriores




Ruído branco

Exemplo (AR):

$$Y_t = \varphi Y_{t-1} + \varepsilon_t, \quad |\varphi| < 1 \quad (19)$$

Depende diretamente do valor anterior, mas não de valores mais antigos. A memória é curta, mas existe




AR(1)

Exemplo (Passeio Aleatório):

$$Y_t = Y_{t-1} + \varepsilon_t \quad (20)$$


Acumula os ruídos passados, de forma que a memória é longa e o valor atual depende de todos os valores anteriores



Exemplo (Tendência Linear):

$$Y_t = \beta_0 + \beta_1 t + \varepsilon_t \quad (21)$$

A tendência linear é um caso especial de passeio aleatório, onde o valor atual depende do tempo e de todos os valores anteriores



4.3 Conceitos

Definição 4.3.1 (Função Média): Seja $\{Y_t\}$ uma série temporal onde $\mathbb{E}[Y_t^2] < \infty$, então a média em cada instante, denotada como

$$\mu_Y(t) = \mathbb{E}[Y_t] \quad (22)$$

É a tendência central do processo ao longo de t . Em geral pode depender do tempo: nada obriga $\mathbb{E}[Y_i] = \mathbb{E}[Y_j]$ para $i \neq j$

Nos quatro exemplos que comentamos, temos que $\mathbb{E}[\varepsilon_t] = 0$, então temos que:

- **Ruído Branco:** $\mu_Y(t) = 0$
- **Tendência Linear:** $\mu_Y(t) = \beta_0 + \beta_1 t$
- **AR:** $\mu_Y(t) = \varphi \cdot \mu_Y(t-1)$

- **Passeio Aleatório:** $\mu_Y(t) = \mu_Y(t-1)$, se considerarmos $Y_0 = 0$, então $\mu_Y(t) = 0$, percebe-se que se mantém constante, isso mostra que uma realização não altera a **média**, mas sim a **covariância** do processo, que cresce com o tempo

Definição 4.3.2 (Covariância): Dados dois instantes r, s , definimos a covariância entre Y_r e Y_s como

$$\gamma_Y(r, s) = \mathbb{E}[(Y_r - \mu_Y(r))(Y_s - \mu_Y(s))] \quad (23)$$

Para vermos como a correlação nos exemplos vistos se comportam, tenha em mente que $\mathbb{V}[\varepsilon_t] = \sigma^2$ e $\gamma_\varepsilon(r, s) = 0$ para $r \neq s$

- **Ruído Branco:** $\gamma_Y(r, s) = 0$ para $r \neq s$, ou seja, não existe correlação entre os valores da série temporal e $\gamma_Y(r, s) = \sigma^2$ se $r = s$, ou seja, a variância é constante ao longo do tempo
- **Tendência Linear:**

$$\begin{aligned} \gamma_{Y(r,s)} &= \text{Cov}(Y_r, Y_s) \\ &= \text{Cov}(\beta_0 + \beta_1 r + \varepsilon_r, \beta_0 + \beta_1 s + \varepsilon_s) \\ &= \text{Cov}(\varepsilon_r, \varepsilon_s) \\ &= \begin{cases} \sigma^2 & r = s \\ 0 & r \neq s. \end{cases} \end{aligned} \quad (24)$$

- **AR:** Dado que $Y_t = \varphi Y_{t-1} + \varepsilon_t$, então temos:

$$\mathbb{V}[Y_t] = \mathbb{V}[\varphi Y_{t-1} + \varepsilon_t] = \varphi^2 \mathbb{V}[Y_{t-1}] + \sigma^2 \quad (25)$$

e se assumirmos que $Y_t = Y_{t-1}$:

$$\mathbb{V}[Y_t] = \varphi^2 \mathbb{V}[Y_t] + \sigma^2 \Rightarrow \mathbb{V}[Y_t] = \frac{\sigma^2}{1 - \varphi^2} \quad (26)$$

- **Passeio Aleatório:** Assumindo o caso onde $Y_t = \varepsilon_1 + \varepsilon_2 + \dots + \varepsilon_t$, temos que:

$$\mathbb{V}[Y_t] = \mathbb{V}[\varepsilon_1 + \varepsilon_2 + \dots + \varepsilon_t] = t\sigma^2 \quad (27)$$

Ou seja, a variância do passeio aleatório cresce linearmente com o tempo. Além disso, a covariância entre dois instantes r e s é dada por

$$\gamma_Y(r, s) = \mathbb{E}[Y_r Y_s] = \mathbb{E}[(\varepsilon_1 + \dots + \varepsilon_r)(\varepsilon_1 + \dots + \varepsilon_s)] = \min(r, s)\sigma^2 \quad (28)$$

Definição 4.3.3 (Estacionariedade Fraca): Dizemos que uma série temporal $\{Y_t\}$ é **estacionária fraca** se:

- Média $\mu_Y(t)$ é constante no tempo
- Covariância $\gamma_Y(r, s)$ depende apenas da diferença $|r - s|$ e não dos instantes absolutos r e s

Como vemos pelos exemplos, as únicas séries que são estacionárias fracas são o **ruído branco** e o **AR**. A tendência linear e o passeio aleatório não são estacionários fracos, pois a média e a covariância dependem do tempo

4.4 ACF e ACVF

Como falamos, a covariância de uma série temporal estacionária fraca depende apenas da diferença entre os instantes, então podemos definir a função de covariância como uma função do lag $h = |r - s|$, assim:

Definição 4.4.1 (ACVF): Dada a série temporal $\{Y_t\}$ estacionária fraca, definimos a função de autocovariância como

$$\gamma_Y(h) = \mathbb{E}[(Y_r - \mu_Y)(Y_{r+h} - \mu_Y)] \quad (29)$$

Definição 4.4.2 (ACF): Dada a série temporal $\{Y_t\}$ estacionária fraca, definimos a função de autocorrelação como

$$\rho_Y(h) = \frac{\gamma_Y(h)}{\gamma_Y(0)} \quad (30)$$

A ACF é uma função que mede a correlação entre os valores da série temporal em diferentes lags. Ela nos ajuda a identificar padrões de dependência temporal e a determinar a ordem de modelos AR e MA, é como se ela fosse a função que mede a **memória** da série temporal. Vale ressaltar que não é porque uma série tem estacionaridade fraca que ela não possui memória, como vimos no caso do AR, que é estacionário fraco, mas possui memória curta. O mesmo não ocorre com o passeio aleatório, que não é estacionário fraco e possui memória longa

4.5 IID v.s Ruído Branco

A distinção entre um processo **I.I.D.** (independente e identicamente distribuído) e um **Ruído Branco** (White Noise - WN) baseia-se na intensidade da independência estocástica exigida entre os instantes de tempo

Definição 4.5.1 (Ruído IID): $\{Y_t\} \sim \text{I.I.D}(0, \sigma^2)$ com $\sigma^2 < \infty$ se

$$\begin{aligned} \mathbb{E}[Y_t] &= 0 \\ \gamma_Y(h) &= \begin{cases} \sigma^2 & h = 0 \\ 0 & h \neq 0 \end{cases} \end{aligned} \quad (31)$$

Exige independência estocástica completa entre todas as variáveis aleatórias Y_t e Y_s ($t \neq s$). Não há qualquer dependência (linear ou não-linear) ou variação nas distribuições marginais

Definição 4.5.2 (Ruído Branco): $\{Y_t\} \sim \text{WN}(0, \sigma^2)$ com $\sigma^2 < \infty$ se

$$\begin{aligned} \mathbb{E}[Y_t] &= 0 \\ \gamma_Y(h) &= \begin{cases} \sigma^2 & h = 0 \\ 0 & h \neq 0 \end{cases} \end{aligned} \quad (32)$$

Exige apenas ausência de correlação linear ($\text{Cov}(Y_{t+h}, Y_t) = 0$ para $h \neq 0$) e estacionariedade de 2ª ordem

Teorema 4.5.1 (Relação entre IID e White Noise):

$$\text{I.I.D } (0, \sigma^2) \Rightarrow \text{WN}(0, \sigma^2) \quad (33)$$

4.6 Estimação Amostral

No dia a dia, não conseguimos dizer com precisão os parâmetros de uma série temporal, como a média e a covariância. Para contornar essa limitação, utilizamos estimadores amostrais, que são funções das observações da série temporal que nos permitem inferir sobre os parâmetros populacionais

Definição 4.6.1 (Estimador de média amostral de processo estocástico fracamente estacionário): Dada uma realização $\{y_1, y_2, \dots, y_T\}$ de um processo estocástico fracamente estacionário $\{Y_t\}$ com média populacional $\mathbb{E}[Y_t] = \mu$ e função de autocovariância $\gamma(h) = \text{Cov}(Y_t, Y_{t+h})$, o estimador da média amostral é definido por

$$\bar{Y}_t = \frac{1}{T} \sum_{t=1}^T Y_t \quad (34)$$

Teorema 4.6.1 (Não-viesamento e Variância da Média Amostral): Se $\{Y_t\}$ for um processo fracamente estacionário com $\mathbb{E}[Y_t] = \mu$ e autocovariância $\gamma(h)$ então

- $\bar{Y}_t$ é um estimador não-viesado de μ
- A variância de $\bar{Y}_t$ é dada por

$$\mathbb{V}[\bar{Y}_t] = \frac{1}{T} \sum_{h=-(T-1)}^{T-1} \left(1 - \frac{|h|}{T}\right) \gamma(h) \quad (35)$$

Demonstração: **Parte do não-viesamento:** Aplicamos a esperança no estimador

$$\mathbb{E}[\bar{Y}_t] = \mathbb{E}\left[\frac{1}{T} \sum_{t=1}^T Y_t\right] = \frac{1}{T} \sum_{t=1}^T \mathbb{E}[Y_t] = \frac{1}{T} \sum_{t=1}^T \mu = \mu \quad (36)$$

Parte da variância: Pela definição da variância da soma de variáveis aleatórias, temos

$$\mathbb{V}[\bar{Y}_t] = \mathbb{V}\left[\frac{1}{T} \sum_{t=1}^T Y_t\right] = \frac{1}{T^2} \mathbb{V}\left[\sum_{t=1}^T Y_t\right] = \frac{1}{T^2} \sum_{r=1}^T \sum_{s=1}^T \text{Cov}(Y_r, Y_s) \quad (37)$$

como o processo é fracamente estacionário, podemos reescrever a covariância como uma função do lag $h = |r - s|$, assim

$$\mathbb{V}[\bar{Y}_t] = \frac{1}{T^2} \sum_{r=1}^T \sum_{s=1}^T \gamma(|r - s|) \quad (38)$$

se agruparmos os pares (r, s) cuja a diferença $r - s$ seja igual a um determinado lag h ($\{-(T-1), \dots, T-1\}$), nota-se que existem exatamente $T - |h|$ pares com aquele lag h . Logo, podemos reescrever a soma como

$$\mathbb{V}[\bar{Y}_t] = \frac{1}{T^2} \sum_{h=-(T-1)}^{T-1} (T - |h|) \gamma(h) = \frac{1}{T} \sum_{h=-(T-1)}^{T-1} \left(1 - \frac{|h|}{T}\right) \gamma(h) \quad (39)$$

□

Definição 4.6.2 (Autocovariância Amostral): A autocovariância amostral usual para um lag $h \geq 0$ é definida com o divisor T

$$\hat{\gamma}(h) = \frac{1}{T} \sum_{t=1}^{T-h} (Y_t - \bar{Y}_t)(Y_{t+h} - \bar{Y}_t) \quad 0 \leq h < T \quad (40)$$

Teorema 4.6.2 (Propriedades do estimador de Autocovariância Amostral):

1. O estimador de autocovariância amostral é viesado em amostra finita, mas é **assintoticamente não-viesado** (isto é, $\lim_{T \rightarrow \infty} \mathbb{E}[\hat{\gamma}(h)] = \gamma(h)$)
2. O uso do divisor T em vez de $T - h$ garante que a matriz de autocovariância amostral seja **semi-definida positiva**, o que é importante para a consistência de estimadores de modelos de séries temporais e minimiza o MSE para lags elevados

Demonstração: Para simplificar a demonstração sem perder generalidade, considere inicialmente o estimador simplificado com μ conhecido

$$\tilde{\gamma}(h) = \frac{1}{T} \sum_{t=1}^{T-h} (Y_t - \mu)(Y_{t+h} - \mu) \quad (41)$$

tomando a esperança desse estimador

$$\begin{aligned} \mathbb{E}[\tilde{\gamma}(h)] &= \frac{1}{T} \sum_{t=1}^{T-h} \mathbb{E}[(Y_t - \mu)(Y_{t+h} - \mu)] \\ &= \frac{1}{T} \sum_{t=1}^{T-h} \gamma(h) \\ &= \frac{T-h}{T} \gamma(h) \end{aligned} \quad (42)$$

logo

$$\mathbb{E}[\tilde{\gamma}(h)] - \gamma(h) = -\frac{h}{T} \gamma(h) \quad (43)$$

Quando substituimos μ por $\bar{Y}_t$, o estimador se torna viesado, mas a diferença entre os dois estimadores é de ordem $O(\frac{1}{T})$, logo, o estimador com média amostral também é assintoticamente não-viesado

$$\lim_{T \rightarrow \infty} \mathbb{E}[\hat{\gamma}(h)] = \lim_{T \rightarrow \infty} \left(1 - \frac{h}{T}\right) \gamma(h) = \gamma(h) \quad (44)$$

Com relação à matriz semi-definida positiva, considere o vetor de observações centradas $Y = (Y_1 - \bar{Y}_T, \dots, Y_T - \bar{Y}_T)^T$. A matriz de autocovariância amostral de ordem $k \times k$ definida como

$$\hat{\Gamma}_k = [\hat{\gamma}(i-j)]_{i,j=1}^k \quad (45)$$

pode ser escrita da seguinte forma matricial

$$\hat{\Gamma}_k = \frac{1}{T} X^T X \quad (46)$$

onde $X_{rj} = Y_{r-j+1} - \bar{Y}_T$ para $r \in \{1, \dots, T+k-1\}$ e $j \in \{1, \dots, k\}$. Para qualquer vetor não-nulo $a = (a_1, \dots, a_k)^T \in \mathbb{R}^k$:

$$a^T \hat{\Gamma}_k a = a^T \left(\frac{1}{T} X^T X \right) a = \frac{1}{T} (Xa)^T (Xa) = \frac{1}{T} \|Xa\|^2 \geq 0 \quad (47)$$

Se dividíssemos por $T-h$ em vez de T , esse cancelamento matricial exato falharia, podendo gerar matrizes de autocovariância amostrais não-definidas positivas (com variâncias teóricas negativas para combinações lineares da série) e maior variabilidade estatística em h $\square$

Definição 4.6.3 (Autocorrelação Amostral): A autocorrelação amostral é a razão normalizada

$$\hat{\rho}(h) = \frac{\hat{\gamma}(h)}{\hat{\gamma}(0)} \quad (48)$$

Teorema 4.6.3 (Distribuição Limite sob Hipótese IID - Bartlett): Se $\{Y_t\} \sim \text{IID}(0, \sigma^2)$ com $\mathbb{E}[Y_t^4] < \infty$, então para qualquer $h > 0$ fixo, quando $T \rightarrow \infty$:

$$\sqrt{T} \hat{\rho}_h \xrightarrow{d} \mathcal{N}(0, 1) \quad (49)$$

e isso implica que $\hat{\rho}_h \approx \mathcal{N}(0, \frac{1}{T})$ para T grande

Demonstração: Sob a hipótese de ruído IID, temos que $\mu = 0$, $\gamma(0) = \sigma^2$ e $\gamma(k) = 0 \forall k \neq 0$.

Passo 1 - Comportamento do Numerador: Considere o estimador $\tilde{\gamma}(h) = \frac{1}{T} \sum_{t=1}^{T-h} Y_t Y_{t+h}$. Defina a sequência de variáveis $W_t = Y_t Y_{t+h}$. Como $\{Y_t\}$ é IID, de média 0

1. $\mathbb{E}[W_t] = \mathbb{E}[Y_t Y_{t+h}] = \mathbb{E}[Y_t] \mathbb{E}[Y_{t+h}] = 0$
2. Para $t \neq s$, as variáveis W_t e W_s são não-correlacionadas (Formam uma sequência de diferenças de martingale)
3. $\mathbb{V}[W_t] = \mathbb{E}[W_t^2] = \mathbb{E}[Y_t^2 Y_{t+h}^2] = \mathbb{E}[Y_t^2] \mathbb{E}[Y_{t+h}^2] = \sigma^4$

Pelo Teorema Central do Limite, para Sequências de Diferenças de Martingale, temos que

$$\sqrt{T} \tilde{\gamma}(h) = \frac{1}{\sqrt{T}} \sum_{t=1}^{T-h} W_t \xrightarrow{d} \mathcal{N}(0, \sigma^4) \quad (50)$$

Passo 2 - Comportamento do Denominador: O denominador $\hat{\gamma}(0)$, pela lei forte dos grandes números:

$$\hat{\gamma}(0) = \frac{1}{T} \sum_{t=1}^T (Y_t - \bar{Y}_T)^2 \xrightarrow{p} \mathbb{V}[Y_t] = \sigma^2 \quad (51)$$

Passo 3 - Aplicação do Teorema de Slutsky: A autocorrelação pode escrita como

$$\sqrt{T}\hat{\rho}(h) = \sqrt{T}\frac{\hat{\gamma}(h)}{\hat{\gamma}(0)} \quad (52)$$

Como a substituição de $\bar{Y}_T$ por $\mu = 0$ introduz apenas termos de ordem $o_p(1)$ (que somem assintoticamente), aplicamos o Teorema de Slutsky combinando a convergência em distribuição do numerador com a convergência em probabilidade do denominador:

$$\sqrt{T}\hat{\rho}(h) = \frac{\sqrt{T}\hat{\gamma}(h)}{\hat{\gamma}(0)} \xrightarrow{d} \frac{\mathcal{N}(0, \sigma^4)}{\sigma^2} = \mathcal{N}\left(0, \frac{\sigma^4}{(\sigma^2)^2}\right) = \mathcal{N}(0, 1) \quad (53)$$

□

Corolário 4.6.3.1 (*Construção formal do intervalo de confiança da ACF*): Do Teorema 4.6.3, decorre que quando temos um ruído IID e amostras grandes, podemos construir um intervalo de confiança para a autocorrelação amostral. Para um nível de confiança $1 - \alpha$:

$$\begin{aligned} \mathbb{P}\left(-z_{1-\alpha/2} \leq \sqrt{T}\hat{\rho}(h) \leq z_{1-\alpha/2}\right) &\approx 1 - \alpha \\ \mathbb{P}\left(-\frac{z_{1-\alpha/2}}{\sqrt{T}} \leq \hat{\rho}(h) \leq \frac{z_{1-\alpha/2}}{\sqrt{T}}\right) &\approx 1 - \alpha \end{aligned} \quad (54)$$

Com esse corolário, podemos interpretar o seguinte: Em um teste de nível de significância $\alpha = 0.05$ (confiança 95%), usamos o quantil $z_{0.975} \approx 1.96$, logo o intervalo de confiança é dado por

$$\left[-\frac{1.96}{\sqrt{T}}, \frac{1.96}{\sqrt{T}}\right] \quad (55)$$

se o valor amostral $\hat{\rho}(h)$ ultrapassar um desses limites, então rejeita-se a hipótese nula H_0 da **ausência de autocorrelação** no lag h , ou seja, existe evidência de que a série temporal possui memória linear. Caso contrário, não rejeitamos a hipótese nula, indicando que não há evidência suficiente para afirmar que existe autocorrelação nesse lag

Previsão e Baselines

No capítulo passado, nós definimos ACF, e como podemos utilizar ela para **diagnosticar** a presença de memória linear em uma série temporal. No entanto, não falamos sobre como utilizar essa informação para **prever** o futuro da série temporal

5.1 Previsão via Autocorrelação $\rho(h)$ e Esperança Condicional

Definição 5.1.1: Seja $\{Y_t\}$ um processo estocástico **gaussiano e fracamente estacionário**, com média constante $\mathbb{E}[Y_t] = \mu$, variância $\mathbb{V}[Y_t] = \gamma_Y(0) = \sigma^2$ e função de autocorrelação $\rho_Y(h) = \gamma_Y(h)/\sigma^2$. O vetor formado pela observação presente Y_n e pela observação futura Y_{n+h} segue uma distribuição normal bivariada

$$\begin{pmatrix} Y_n \\ Y_{n+h} \end{pmatrix} \sim \mathcal{N}\left(\begin{pmatrix} \mu \\ \mu \end{pmatrix}, \begin{pmatrix} \sigma^2 & \rho_Y(h)\sigma^2 \\ \rho_Y(h)\sigma^2 & \sigma^2 \end{pmatrix}\right) \quad (56)$$

Teorema 5.1.1 (Condicional Gaussiana): Sob a hipótese de gaussianidade no processo $\{Y_t\}$, a distribuição condicional de Y_{n+h} dado $Y_n = y_n$ é dada por

$$Y_{n+h} \mid Y_n = y_n \sim \mathcal{N}(\mu + \rho_Y(h)(y_n - \mu), \sigma^2(1 - \rho_Y(h)^2)) \quad (57)$$

Demonstração: Defina a variável transformada $Z = (Y_{n+h} - \mu) - \beta(Y_n - \mu)$ onde β é uma constante real **a ser determinada** para que Z e Y_n sejam **não-correlacionadas**. Pela definição de covariância, temos que

$$\begin{aligned} \text{Cov}(Z, Y_n) &= \text{Cov}((Y_{n+h} - \mu) - \beta(Y_n - \mu), Y_n) \\ &= \text{Cov}(Y_{n+h}, Y_n) - \beta\mathbb{V}[Y_n] \\ &= \gamma_Y(h) - \beta\sigma^2 \end{aligned} \quad (58)$$

para anular a covariância, escolhemos $\beta = \frac{\gamma_Y(h)}{\sigma^2} = \rho_Y(h)$, assim:

$$Z = (Y_{n+h} - \mu) - \rho_Y(h)(Y_n - \mu) \quad (59)$$

como (Z, Y_n) é um vetor normal, temos que o fato de $\text{Cov}(Z, Y_n) = 0$ implica que Z e Y_n são independentes. Utilizando desse fato, sabemos que

$$\begin{aligned} \mathbb{E}[Z \mid Y_n] &= \mathbb{E}[Z] = 0 \\ \mathbb{E}[Y_{n+h} - \mu - \rho_Y(h)(Y_n - \mu) \mid Y_n] &= 0 \\ \mathbb{E}[Y_{n+h} \mid Y_n] - \mu - \rho_Y(h)(Y_n - \mu) &= 0 \\ \mathbb{E}[Y_{n+h} \mid Y_n] &= \mu + \rho_Y(h)(Y_n - \mu) \end{aligned} \quad (60)$$

Já para a variância condicional, temos que

$$\mathbb{V}[Y_{n+h} \mid Y_n] = \mathbb{V}[Z + \rho_Y(h)(Y_n - \mu) \mid Y_n] \quad (61)$$

como é DADO Y_n , o termo $\rho_Y(h)(Y_n - \mu)$ é uma constante, logo

$$\begin{aligned}
\mathbb{V}[Y_{n+h} | Y_n] &= \mathbb{V}[Z | Y_n] = \mathbb{V}[Z] \\
&= \mathbb{V}[Y_{n+h} - \mu - \rho_Y(h)(Y_n - \mu)] \\
&= \mathbb{V}[Y_{n+h}] + \rho_Y(h)^2 \mathbb{V}[Y_n] - 2\rho_Y(h) \text{Cov}(Y_{n+h}, Y_n) \\
&= \sigma^2 + \rho_Y(h)^2 \sigma^2 - 2\rho_Y(h) \gamma_Y(h) \\
&= \sigma^2 + \rho_Y(h)^2 \sigma^2 - 2\rho_Y(h)^2 \sigma^2 \\
&= \sigma^2(1 - \rho_Y(h)^2)
\end{aligned} \tag{62}$$

□

Dado esse contexto, podemos agora mostrar que para **qualquer preditor** $g(Y_n)$, **o preditor que minimiza o erro quadrático médio** é a **média condicional** $\mathbb{E}[Y_{n+h} | Y_n]$.

Teorema 5.1.2 (Preditor que minimiza o MSE): Para qualquer preditor $g(Y_n)$ baseado na observação Y_n , o preditor que minimiza o erro quadrático médio ($\mathbb{E}[(Y_{n+h} - g(Y_n))^2]$) é dado por

$$g(Y_n) = \mathbb{E}[Y_{n+h} | Y_n] \tag{63}$$

Demonstração: Definindo o erro quadrático médio como f , temos:

$$f(y_n) = \mathbb{E}[(Y_{n+h} - g(Y_n))^2 | Y_n = y_n] \tag{64}$$

expandindo o termo quadrático, derivando e igualando a 0, vamos ter que

$$g(Y_n) = \mathbb{E}[Y_{n+h} | Y_n = y_n] \tag{65}$$

□

Sob a hipótese de gaussianidade, o preditor linear possui forma fechada de:

$$\mathbb{E}[Y_{n+h} | Y_n] = \mu + \rho_Y(h)(Y_n - \mu) \tag{66}$$

no entanto, sem essa premissa, o preditor linear pode não possuir forma fechada, mas ainda assim é o preditor que minimiza o erro quadrático médio. E como podemos perceber, a função $\rho_Y(h)$ determina diretamente a qualidade e o formato da predição

- $\rho_Y(h) \rightarrow 0$: A previsão tende a μ e o erro quadrático médio tende a σ^2 , ou seja, a informação presente Y_n não traz informação útil sobre o futuro Y_{n+h} . O melhor preditor reduz-se à média incondicional e a incerteza atinge a variância total da série
- $\rho_Y(h) \rightarrow 1$: A previsão tende a Y_n e o erro quadrático médio tende a 0, ou seja, a informação presente Y_n praticamente carrega toda a informação sobre o futuro Y_{n+h} . O melhor preditor aproxima-se do valor atual e a incerteza diminui significativamente

Mas como eu comentei antes, esse é o melhor preditor **sobre gaussianidade**, mas não necessariamente o melhor preditor **sobre a série temporal**. No entanto, é possível chegar que, definindo um preditor genérico $l(Y_n) = \alpha Y_n + \beta$, o melhor l é exatamente o preditor linear que obtivemos na prova anterior

Teorema 5.1.3 (Preditor Linear que minimiza o MSE): Para qualquer preditor linear $l(Y_n) = \alpha Y_n + \beta$ baseado na observação Y_n , o preditor que minimiza o erro quadrático médio ($\mathbb{E}[(Y_{n+h} - l(Y_n))^2]$) é dado por

$$l(Y_n) = \mu + \rho_Y(h)(Y_n - \mu) \quad (67)$$

e apresenta um erro quadrático médio de $\sigma^2(1 - \rho_Y(h)^2)$

Demonstração: Queremos determinar os escalares α e β que minimizam o erro quadrático médio

$$f(\alpha, \beta) = \mathbb{E}[(Y_{n+h} - (\alpha Y_n + \beta))^2] \quad (68)$$

expandindo o termo quadrático (e lembrando que $\mathbb{E}[Y_n] = \mathbb{E}[Y_{n+h}] = \mu$), temos que

$$f(\alpha, \beta) = \mathbb{E}[Y_{n+h}^2] - 2\alpha\mathbb{E}[Y_n Y_{n+h}] - 2\beta\mu + \alpha^2\mathbb{E}[Y_n^2] + 2\alpha\beta\mu + \beta^2 \quad (69)$$

e derivando com relação à α

$$\frac{\partial f}{\partial \alpha} = -2\mathbb{E}[Y_n Y_{n+h}] + 2\alpha\mathbb{E}[Y_n^2] + 2\beta\mu = 0 \quad (70)$$

igualando a 0 e isolando α , temos que

$$\alpha = \frac{\mathbb{E}[Y_n Y_{n+h}] - \beta\mu}{\mathbb{E}[Y_n^2]} \quad (71)$$

agora derivando com relação à β

$$\frac{\partial f}{\partial \beta} = -2\mu + 2\alpha\mu + 2\beta = 0 \quad (72)$$

igualando a 0 e isolando β , temos que

$$\beta = \mu(1 - \alpha) \quad (73)$$

substituindo β na equação de α , temos que

$$\begin{aligned} \alpha &= \frac{\mathbb{E}[Y_n Y_{n+h}] - \mu^2(1 - \alpha)}{\mathbb{E}[Y_n^2]} \\ \alpha\mathbb{E}[Y_n^2] &= \mathbb{E}[Y_n Y_{n+h}] - \mu^2 + \alpha\mu^2 \\ \alpha(\mathbb{E}[Y_n^2] - \mu^2) &= \mathbb{E}[Y_n Y_{n+h}] - \mu^2 \\ \alpha\mathbb{V}[Y_n] &= \text{Cov}(Y_n, Y_{n+h}) \\ \alpha &= \rho_Y(h) \end{aligned} \quad (74)$$

Voltando na equação de β , temos que

$$\beta = \mu(1 - \alpha) = \mu(1 - \rho_Y(h)) \quad (75)$$

agora substituindo na equação do preditor linear, temos que

$$\begin{aligned}
l(Y_n) &= \alpha Y_n + \beta \\
&= \rho_Y(h) Y_n + \mu(1 - \rho_Y(h)) \\
&= \mu + \rho_Y(h)(Y_n - \mu)
\end{aligned} \tag{76}$$

Substituindo isso tudo que encontramos na fórmula do erro quadrático médio, vamos acabar chegando que

$$f(\alpha, \beta) = \sigma^2(1 - \rho_Y(h)^2) \tag{77}$$


□

5.2 Métodos simples de previsão (baseline)

Um baseline estabelece o padrão mínimo. Se um modelo sofisticado perde para a média ou para o último valor (previsores que vimos anteriormente), o sofisticado ainda não justificou sua complexidade. O baseline estabelece um **limite inferior** para o desempenho de modelos mais complexos.

Definição 5.2.1: $\hat{Y}_{T+h|T}$ representa a previsão do valor futuro Y_{T+h} dado os dados observados até o instante T .

5.2.1 Método da média



Média em série sem memória; previsão plana

Figura 9: Ilustração do método da média

Prevemos todas as observações futuras pela média aritmética histórica da amostra:

$$\hat{Y}_{T+h|T} = \bar{Y}_T = \frac{1}{T} \sum_{t=1}^T Y_t \quad \forall h \geq 1 \tag{78}$$

o método da média assume que o processo é **fracamente estacionário**, sem tendência e sem sazonalidade

$$Y_t = \mu + \varepsilon_t, \quad \varepsilon_t \sim \text{WN}(0, \sigma^2) \tag{79}$$

Corresponde ao caso em que a autocorrelação $\rho(h) \approx 0$ para todo $h \geq 1$ (série sem memória linear)

Conseguimos notar também que esse estimador é **não-viesado** e **consistente**, ou seja, a previsão converge para o valor real da série temporal à medida que o tamanho da amostra aumenta (pois a média amostral converge para a média populacional).

Teorema 5.2.1.1 (Variância do Erro de Previsão):

$$\mathbb{V}[\varepsilon_{T+h}] = \sigma^2 \left(1 + \frac{1}{T}\right) \quad \forall h \geq 1 \quad (80)$$

Ou seja, a precisão converge para a variância do ruído branco à medida que o tamanho da amostra aumenta ($T \rightarrow \infty$)

Demonstração:

$$\begin{aligned} \mathbb{V}[Y_{T+h} - \bar{Y}_T] &= \mathbb{V}[\varepsilon_{T+h}] \\ &= \mathbb{V}[Y_{T+h}] + \mathbb{V}[\bar{Y}_T] - 2 \text{Cov}(Y_{T+h}, \bar{Y}_T) \\ &= \sigma^2 + \frac{\sigma^2}{T} \\ &= \sigma^2 \left(1 + \frac{1}{T}\right) \end{aligned} \quad (81)$$

Aqui a covariância entre Y_{T+h} e $\bar{Y}_T$ é nula, pois o ruído branco não possui memória linear, logo não há correlação entre o valor futuro e a média amostral (além de que o valor futuro está fora dos valores utilizados para a estimação da média amostral, pois $h \geq 1$) $\square$

5.2.2 Método ingênuo (Passeio aleatório sem tendência)



Ingênuo em passeio; previsão = último valor

Figura 10: Ilustração do método ingênuo

A previsão para qualquer horizonte futuro é o **último valor observado** da série

$$\hat{Y}_{T+h|T} = Y_T \quad \forall h \geq 1 \quad (82)$$

ele assume que o processo segue um **Passeio Aleatório** puro (não-estacionário na variância)

$$Y_t = Y_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim \text{IID}(0, \sigma^2) \quad (83)$$

É o caso limite em que a autocorrelação de curto prazo é extremamente alta ($\rho(h) \approx 1$ para h pequeno). O estado atual Y_T é a melhor estimativa para a posição futura

O erro de previsão acaba por ser a soma dos ruídos futuros acumulados

$$Y_{T+h} - \hat{Y}_{T+h|T} = Y_{T+h} - Y_T = \varepsilon_{T+1} + \dots + \varepsilon_{T+h} \quad (84)$$

É fácil ver que o estimador é não-viesado (basta tirar a esperança do erro de previsão). E podemos mostrar que a variância da previsão aumenta linearmente com o horizonte de previsão, pois a variância do erro de previsão é a soma das variâncias dos ruídos futuros

Teorema 5.2.2.1 (Variância do Erro de Previsão):

$$\mathbb{V}[Y_{T+h} - \hat{Y}_{T+h|T}] = h\sigma^2 \quad \forall h \geq 1 \quad (85)$$

Ou seja, a precisão da previsão diminui linearmente com o horizonte de previsão, pois a variância do erro de previsão aumenta linearmente com o horizonte de previsão

Demonstração:

$$\begin{aligned} \mathbb{V}[Y_{T+h} - \hat{Y}_{T+h|T}] &= \mathbb{V}[\varepsilon_{T+1} + \dots + \varepsilon_{T+h}] \\ &= \mathbb{V}[\varepsilon_{T+1}] + \dots + \mathbb{V}[\varepsilon_{T+h}] \\ &= h\sigma^2 \end{aligned} \quad (86)$$

□

5.2.3 Método ingênuo sazonal



Figura 11: Ilustração do método ingênuo sazonal

Para séries com sazonalidade de período m (ex: $m = 12$ para dados mensais, $m = 4$ para dados trimestrais), a previsão copia o valor observado na mesma fase do ciclo sazonal anterior

$$\hat{Y}_{T+h|T} = Y_{T+h-m(K+1)} \quad \forall h \geq 1 \quad K = \left\lfloor \frac{h-1}{m} \right\rfloor \quad (87)$$

Esse método assume um modelo de **Passeio Aleatório Sazonal** sem tendência:

$$Y_t = Y_{t-m} + \varepsilon_t, \quad \varepsilon_t \sim \text{IID}(0, \sigma^2) \quad (88)$$

Já aqui, conseguimos mostrar que a incerteza cresce não com h , mas a **cada ciclo sazonal completo**

$$\mathbb{V}[\varepsilon_{T+h}] = (K + 1)\sigma^2 \quad (89)$$

Teorema 5.2.3.1 (Variância do Erro de Previsão):

$$\mathbb{V}[Y_{T+h} - \hat{Y}_{T+h|T}] = (K + 1)\sigma^2 \quad \forall h \geq 1 \quad K = \left\lfloor \frac{h-1}{m} \right\rfloor \quad (90)$$

Ou seja, a precisão da previsão diminui a cada ciclo sazonal completo, pois a variância do erro de previsão aumenta a cada ciclo sazonal completo

Demonstração:

$$\begin{aligned} \mathbb{V}[Y_{T+h} - \hat{Y}_{T+h|T}] &= \mathbb{V}[\varepsilon_{T+h-m(K+1)} + \dots + \varepsilon_{T+h}] \\ &= \mathbb{V}[\varepsilon_{T+h-m(K+1)}] + \dots + \mathbb{V}[\varepsilon_{T+h}] \\ &= (K + 1)\sigma^2 \end{aligned} \quad (91)$$

□

5.2.4 Método do desvio (drift)




Figura 12: Ilustração do método do desvio

Extrapolamos uma tendência linear permitindo que a previsão mude ao longo do tempo a uma taxa constante C

$$\hat{Y}_{T+h|T} = Y_T + hC \quad \forall h \geq 1 \quad (92)$$

onde a taxa de variação (inclinação do desvio) é estimada pela variação média por período entre a primeira e a última observação da amostra

$$C = \frac{Y_T - Y_1}{T - 1} \quad (93)$$

na intuição geométrica, estamos traçando uma linha reta entre o primeiro e o último ponto da série temporal, e projetando essa linha para frente. Esse método assume um modelo de **Passeio Aleatório com Drift (Tendência)**:

$$Y_t = C + Y_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim \text{WN}(0, \sigma^2) \quad (94)$$

5.3 Valores Ajustados V.S Previsões

É importante notar que os métodos de previsão que vimos até agora são **modelos de previsão**, e não **modelos de ajuste**. Ou seja, eles não são modelos que descrevem a série temporal, mas sim modelos que descrevem como prever o futuro da série temporal.

Para um modelo de séries temporais ajustado sobre um conjunto de dados históricos $\mathcal{F}_T = \{Y_1, \dots, Y_T\}$ temos as seguintes definições

Definição 5.3.1 (Valores ajustados): O valor ajustado $\hat{Y}_{t|t-1}$ é a estimativa **dentro da amostra** de um passo à frente ($h = 1$) para instantes passados $t = 2, 3, \dots, T$. Representa o valor que o modelo teria previsto para o instante t conhecendo as observações anteriores $Y_1, Y_2, \dots, Y_{t-1}$ e com parâmetros globais **já calibrados na amostra completa**

Definição 5.3.2 (Previsão (Forecast)): A previsão $\hat{Y}_{T+h|T}$ são as projeções **fora da amostra** de h passos à frente ($h \geq 1$) para instantes futuros $t = T + 1, T + 2, \dots$. Utilizam estritamente a informação disponível até o instante de corte T , sem qualquer acesso visual ou numérico às realizações reais de Y_{T+h}

Diagnóstico de Resíduos

6.1 Introdução

No capítulo passado visualizamos formas de previsão utilizando da relação linear que as covariáveis possuem entre si ($\rho(h)$). Nesse capítulo, vamos entender que tipo de informações conseguimos retirar a partir dos **resíduos** das previsões

Definição 6.1.1 (Resíduo): Um resíduo e_t é a diferença entre o valor observado Y_t e o valor previsto $\hat{Y}_t$

$$e_t = Y_t - \hat{Y}_t \quad (95)$$

ele representa justamente aquilo que o modelo não absorveu, ou seja, a parte da série temporal que não foi explicada pelo modelo. Se o modelo for bom, os resíduos devem se comportar como **ruído branco**, ou seja, não devem apresentar autocorrelação significativa, ou seja, eles devem apresentar $\mathbb{E}[e_t] = 0$ e $\text{Cov}(e_t, e_{t+h}) = 0$, garantindo que não houve memória não explorada.

Algumas outras características, não obrigatórias, mas desejáveis, são variância constante $\mathbb{V}[e_t] = \sigma^2$ e distribuição **aproximadamente** normal, essencial para o ajuste de intervalos de confiança e testes de hipóteses.

Nós vamos ver alguns testes de hipótese que trabalham em cima dos resíduos e testam justamente as propriedades que citamos, mas, mesmo que nós já tenhamos visto isso em matérias anteriores, vale ressaltar que o teste **passar**, não significa que o modelo é bom, mas sim que **não há evidência suficiente** para rejeitar a hipótese nula de que os resíduos são ruído branco. Já se o teste **falha**, significa que o modelo é **inadequado** e que há memória não explorada na série temporal, ou seja, há espaço para sua melhoria.

6.2 Testes de Autocorrelação conjunta

Antes de iniciarmos, os dois testes apresentados serão os *testes portmanteau*, que têm o mesmo objetivo, avaliar a autocorrelação conjunta dos resíduos até um lag limite l

$$\begin{aligned} H_0 : \rho_e(1) = \rho_e(2) = \dots = \rho_e(l) = 0 \\ H_1 : \exists h \in \{1, \dots, l\} \text{ tal que } \rho_e(h) \neq 0 \end{aligned} \quad (96)$$

ou seja, atuam sobre a hipótese nula que **não existe** autocorrelação significativa nos resíduos até o lag l . Antes de partirmos para os testes, vale também ressaltar a definição:

$$r_k = \hat{\rho}_e(k) = \frac{\sum_{t=k+1}^T (e_t - \bar{e})(e_{t-k} - \bar{e})}{\sum_{t=1}^T (e_t - \bar{e})^2} \quad \forall k \in \{1, \dots, l\} \quad (97)$$

Os testes vão se basear no Teorema 4.6.3 que nos garante que, sob a hipótese nula de IID, temos que

$$\sqrt{T}r_k \xrightarrow{d} \mathcal{N}(0, 1) \quad \forall k \in \{1, \dots, l\} \quad (98)$$

6.2.1 Teste de Box-Pierce

Dado o Teorema 4.6.3, então podemos enunciar o seguinte teorema

Teorema 6.2.1.1 (Normalidade Conjunta): Se $\{Y_t\} \sim \text{IID}(0, \sigma^2)$ com $\mathbb{E}[Y_t^4] < \infty$, então para qualquer $h > 0$ fixo, quando $T \rightarrow \infty$ e para um l fixo:

$$\sqrt{T}(r_1 \dots r_l)^T \xrightarrow{d} \mathcal{N}(0, I_l) \quad (99)$$

Sabendo que cada um dos lags r_k converge para uma distribuição normal padrão, podemos construir a estatística de teste de Box-Pierce como

$$Q = T \sum_{k=1}^l r_k^2 \quad (100)$$

dessa forma, sob a hipótese nula, temos que

$$Q \xrightarrow{d} \chi_l^2 \quad (101)$$

No entanto esse teste possui uma limitação em amostras finitas, pois sob H_0 , é possível mostrar que a variância de r_k^2 para um lag k é

$$\mathbb{E}[Tr_k^2] \approx \frac{T-k}{T+2} < 1 \quad (102)$$

como a estatística de teste Q trata $\mathbb{E}[Tr_k^2] = 1$, então Q torna-se sistematicamente **superestimado** em amostras finitas, o que leva a rejeitar a hipótese nula de ruído branco mesmo quando ela é verdadeira (muito conservador). Para contornar esse problema, foi proposto o teste de Ljung-Box

6.2.2 Teste de Ljung-Box

Aplica um fator de reescalonamento que pondera cada lag pelo inverso de sua variância exata sob a hipótese nula, assim, a estatística de teste de Ljung-Box é definida como

$$Q^* = T(T+2) \sum_{k=1}^l \left(\frac{r_k^2}{T-k} \right) \quad (103)$$

assim, a distribuição empírica de Q^* aproxima-se com maior precisão da distribuição teórica Qui-Quadrado em amostras finitas, sendo o teste preferido na prática

6.2.3 Distribuição Assintótica e Regra de Decisão Formal

Sob a hipótese nula H_0 , ambas as estatísticas seguem assintoticamente uma distribuição Qui-Quadrado:

$$Q \xrightarrow{a} X^2(d) \quad Q^* \xrightarrow{a} X^2(d) \quad (104)$$

onde $d = l - K$ representa os graus de liberdade, l o número de lags testados. Há uma regra prática de fixar $l = 10$ para dados não-sazonais e $l = 2m$ para dados sazonais. A escolha de l deve ser fixada antes do cálculo do p -valor. K é o número de parâmetros estimados no modelo que gerou os resíduos⁵ (para as baselines simples sem calibração por otimização, $K = 0 \Rightarrow d = l$)

Fixando o nível de significância α , queremos rejeitar H_0 quando a estatística de teste Q ou Q^* forem maiores que um $c_{1-\alpha}$, ou seja

$$\mathbb{P}(Q > c_{1-\alpha}) = \alpha \quad (105)$$

dado que, sob a hipótese nula, Q e Q^* seguem uma distribuição Qui-Quadrado com d graus de liberdade, então o limite crítico $c_{1-\alpha}$ é dado pelo quantil $(1 - \alpha)$ da distribuição Qui-Quadrado, logo

$$c_{1-\alpha} = \chi_d^2(1 - \alpha) \quad (106)$$

e o p-valor

$$p = \mathbb{P}(X_d^2 > Q | H_0 \text{ verdade}) = 1 - F_{X_d^2}(Q) \quad (107)$$




Figura 13: Ilustração do teste de Box-Pierce

6.2.4 Intervalos de Precisão

Sob a premissa de que os erros seguem distribuição Normal $e_t \sim \mathcal{N}(0, \sigma^2)$ e são não-correlacionados, o intervalo de previsão com 95% de confiança para o horizonte h é

$$\hat{Y}_{T+h|T} \pm 1.96 \sqrt{\mathbb{V}[Y_{T+h} - \hat{Y}_{T+h|T}]} = \hat{Y}_{T+h|T} \pm 1.96 \sqrt{h\sigma^2} \quad (108)$$

onde o desvio padrão do erro de previsão é estimado como

$$\hat{\sigma} = \sqrt{\frac{1}{T - K - M} \sum_{t=1}^T \hat{e}_t^2} \quad (109)$$

A acumulação do desvio padrão futuro $\hat{\sigma}_h$ varia conforme a estrutura de cada baseline

- **Naive:** $\hat{\sigma}_h = \sqrt{h} \cdot \hat{\sigma}$




Figura 14: Ilustração do método ingênuo

- **Mean:** $\hat{\sigma}_h = \hat{\sigma} \sqrt{1 + \frac{1}{T}}$




Figura 15: Ilustração do método da média

- **Naive Sazonal:** $\hat{\sigma}_h = \sqrt{K+1} \cdot \hat{\sigma}$ com $K = \left\lfloor \frac{h-1}{m} \right\rfloor$




Figura 16: Ilustração do método ingênuo sazonal

- **Drift:** $\hat{\sigma}_h = \hat{\sigma} \cdot \sqrt{\frac{h(h+1)}{T-1}}$




Figura 17: Ilustração do método do desvio

6.3 Intervalo de Previsão por Bootstrap

Quando a distribuição dos resíduos apresenta assimetria ou caudas pesadas, a premissa de normalidade falha, gerando intervalos paramétricos mal calibrados

Algoritmo de Construção das Trajetórias Simuladas:

1. Extrair os resíduos observados de 1 passo $\{\hat{e}_1, \dots, \hat{e}_T\}$.
2. Para o horizonte $h = 1$, sortear com reposição um resíduo $e_{T+1}^* \in (\hat{e}_t)$ e calcular $Y_{T+1}^* = \hat{Y}_{T+1|T} + e_{T+1}^*$.
3. Para os passos subsequentes $h = 2, 3, \dots$, sortear com reposição um novo resíduo e_{T+h}^* e atualizar recursivamente $Y_{T+h}^* = \hat{Y}_{T+h|T+h-1} + e_{T+h}^*$.

4. Repetir esse processo B vezes (gerando B trajetórias futuras) e extrair os quantis empíricos de 2,5% e 97,5% para formar o intervalo a 95% de confiança.

O bootstrap não conserta um modelo com erros autocorrelacionados. Se a ACF dos resíduos indicar memória, a reamostragem i.i.d. mistura choques dependentes como se fossem independentes, destruindo a cobertura nominal do intervalo. O bootstrap relaxa a hipótese de normalidade, mas exige rigorosamente a ausência de autocorrelação.




Figura 18: Ilustração do método de bootstrap

Métricas de Avaliação

7.1 Erro de previsão V.S Resíduos

Antes de aprendermos sobre métricas de avaliação, é importante destacarmos a diferença entre **erro de previsão** e **resíduo**, a diferença é sutil e se encontra no fato da amostra **estar** ou **não estar** no conjunto de treino (ajuste do modelo)

- **Resíduo** $e_t = y_t - \hat{y}_{t|t-1} \quad \forall t \in \{1, \dots, T\}$: Mede a discrepância entre a observação real e o valor ajustado dentro da **amostra utilizada para calibrar o modelo**
- **Erro de previsão** $e_{T+h} = y_{T+h} - \hat{y}_{T+h|T} \quad \forall h \geq 1$: Mede a discrepância entre a observação real e o valor previsto **fora da amostra utilizada para calibrar o modelo**

7.2 Métricas de Avaliação Pontual

Para as próximas definições, defina H como o número de pontos **do conjunto de testes** que você reservou para a análise.

7.2.1 Métricas de Escala

Fornecem medidas de erro expressa na mesma escala dos dados (ex: R\$, litros, galões etc.), tornando a interpretação direta.

Definição 7.2.1.1 (Erro Absoluto Médio (MAE)):

$$\text{MAE} = \frac{1}{H} \sum_{h=1}^H |e_{T+h}| \quad (110)$$

O interessante dessa métrica é que o erro é tratado de forma proporcional, então errar 10 unidades machuca no bolso exatamente 10 vezes mais que errar 1 unidade. Utilizamos esse erro quando o custo operacional/financeiro cresce proporcionalmente ao erro cometido. Já vimos em teoremas de outras disciplinas que o MAE é minimizado pela **mediana** da distribuição de erros, ou seja, o preditor que minimiza o MAE é $\text{MED}(Y_{T+h|Y_T})$

Definição 7.2.1.2 (Root Mean Squared Error):

$$\text{RMSE} = \sqrt{\frac{1}{H} \sum_{h=1}^H e_{T+h}^2} \quad (111)$$

O erro RMSE penaliza erros grandes de forma mais severa, pois o erro é elevado ao quadrado. Utilizamos esse erro quando o custo operacional/financeiro de uma falha pequena é relevante, mas o custo de uma falha grande é inaceitável. Por exemplo, na previsão de demanda de energia elétrica, um erro de 10MW não é 10 vezes pior do que um de 1MW — ele pode derrubar a rede elétrica e causar um apagão. O quadrado captura essa “*gravidade exponencial*”. Também vimos em disciplinas passadas que o preditor que minimiza esse erro é $\mathbb{E}[Y_{T+h|T}]$

Por mais interessantes que essas métricas seja, existe um claro problema com elas, eles **não** podem ser usados para comparar erros de séries temporais com **escalas ou magnitudes diferentes**.

Exemplo (Escala iguais, magnitudes diferentes): Vamos pensar em um varejo com dois produtos A e B , onde o produto A vende aproximadamente 10 por dia, enquanto o B vende 10000 por dia. Se o modelo de previsão tem um MAE de 10 para ambos, enquanto no produto B isso é irrelevante, já que é uma quantidade de produtos errados muito baixa comparado

ao volume de vendas, para o produto A isso é um **completo desastre**, pois o modelo errou a previsão de vendas em 100%.

7.2.2 Erros Percentuais

Essas são as métricas que são **livres de escala**, permitindo comparação entre séries temporais com magnitudes diferentes e permitem fácil comunicação com stakeholders

Definição 7.2.2.1 (Mean Absolute Percentage Error):

$$P_j = 100 \cdot \frac{e_j}{y_j}$$

$$\text{MAPE} = \frac{1}{H} \sum_{j=1}^H |P_j| \quad (112)$$

Por mais útil que esse erro seja, ainda existem alguns pontos para se ficar atento. Se $y_j = 0$ o MAPE é indefinido, e se y_j é muito pequeno, o MAPE pode **explodir**. Além disso, o MAPE é **assimétrico**, ou seja, ele penaliza mais previsões que **subestimam** a demanda do que previsões que **superestimam** a demanda

Exemplo (Assimetria do MAPE): Suponha que $y = 1$ e $\hat{y} = 2$, então o erro percentual é $|P| = |100 \cdot \frac{1-2}{1}| = 100\%$, agora basta inverter e assumir $y = 2$ e $\hat{y} = 1$ e teremos $|P| = |100 \cdot \frac{2-1}{2}| = 50\%$

7.2.3 Erros Escalados

A ideia desse erro é calcular o MAE do seu modelo e dividir esse erro pelo erro de um modelo **ingênuo** (baseline)

Definição 7.2.3.1 (Mean Absolute Scaled Error): Em séries não-sazonais

$$q_j = \frac{e_j}{\frac{1}{T-1} \sum_{t=2}^T |y_t - y_{t-1}|} \quad (113)$$

em séries sazonais

$$q_j = \frac{e_j}{\frac{1}{T-m} \sum_{t=m+1}^T |y_t - y_{t-m}|} \quad (114)$$

e o MASE é dado por

$$\text{MASE} = \frac{1}{H} \sum_{j=1}^H |q_j| \quad (115)$$

Cada q_j indica a quantos “passos típicos de passeio aleatório” equivale o erro de teste.

- $\text{MASE} < 1$: Na janela de teste, o modelo foi superior ao Naive.
- $\text{MASE} = 1$: O modelo empatou com o Naive.
- $\text{MASE} > 1$: O modelo é pior que o Naive.

A escala é calculada no treino (ficando fixa antes do teste). Não sofre com zeros no teste, não é assimétrica e permite comparar métodos em coleções mistas de séries

7.3 Métricas de Avaliação Distribucional

MAE e RMSE avaliam **um** número $\hat{y}$. O intervalo $\hat{y} \pm 1.96\hat{\sigma}_h$ era um recorde de uma **distribuição preditiva** F de Y_{t+h} dado o passado. Agora nós gostaríamos de avaliar a **distribuição preditiva**.

7.3.1 Erro de Quantil

Avalia a precisão de um quantil $\hat{q}_{t+h|T}$ da distribuição preditiva F de Y_{t+h} dado o passado.

Definição 7.3.1.1 (Pinball Loss):

$$Q_{p,t}(\hat{q}_{p,t}, y_t) = \begin{cases} 2(1-p)(\hat{q}_{p,t} - y_t) & y_t < \hat{q}_{p,t} \\ 2p(y_t - \hat{q}_{p,t}) & y_t \geq \hat{q}_{p,t} \end{cases} \quad (116)$$

O valor de y que minimiza $\mathbb{E}[Q]$ é o **quantil verdadeiro** da distribuição

Teorema 7.3.1.1 (Minimizador teórico de Q): Seja Y uma variável aleatória contínua com função de distribuição acumulada (cdf) $F_Y(y) = \mathbb{P}(Y \leq y)$ estritamente crescente e função de densidade de probabilidade $f_Y(y) > 0$

Para um quantil fixado $p \in (0, 1)$, seja a função de perda de quantil $Q_p(q, Y)$ definida em Definição 7.3.1.1, a esperança do risco associado

$$\mathcal{L} = \mathbb{E}[Q_p(q, Y)] \quad (117)$$

atinge seu mínimo global estrito se e somente se o candidato q for o p -quantil verdadeiro da distribuição de Y

$$q^* = F_Y^{-1}(p) \quad (118)$$

Demonstração:

$$\mathcal{L}(q) = \int_{-\infty}^{\infty} Q_p(q, y) f_Y(y) dy \quad (119)$$

Dividindo a integral no ponto de corte q

$$\mathcal{L}(q) = \int_{-\infty}^q 2(1-p)(q-y)f_Y(y) dy + \int_q^{\infty} 2p(y-q)f_Y(y) dy \quad (120)$$

$$\mathcal{L}(q) = \underbrace{2(1-p) \int_{-\infty}^q (q-y)f_Y(y) dy}_f + \underbrace{2p \int_q^{\infty} (y-q)f_Y(y) dy}_g \quad (121)$$

Aplicando a regra de leibniz para derivadas de integrais, temos que

$$\frac{d}{dq} \mathcal{L}(q) = \frac{df}{dq} + \frac{dg}{dq} \quad (122)$$

$$\frac{df}{dq} = 2(1-p) \left[(q-q)f_Y(q) + \int_{-\infty}^q \frac{\partial}{\partial q} (q-y)f_Y(y) dy \right] = 2(1-p)F_Y(q) \quad (123)$$

$$\frac{dg}{dq} = 2p \left[-(q - q)f_Y(q) + \int_q^\infty \frac{\partial}{\partial q}(y - q)f_Y(y) dy \right] = -2p(1 - F_Y(q)) \quad (124)$$

Logo, para achar o ponto de mínimo:

$$\begin{aligned} 0 &= 2(1 - p)F_Y(q) - 2p(1 - F_Y(q)) \\ 0 &= (1 - p)F_Y(q) - p + pF_Y(q) \\ p &= (1 - p + p)F_Y(q) \\ F_Y(q) &= p \\ q^* &= F_Y^{-1}(p) \end{aligned} \quad (125)$$

A existência de $F_Y^{-1}(p)$ é garantida pois F_Y é estritamente crescente. Derivando novamente em relação a q

$$\frac{d^2\mathcal{L}}{dq^2} = \frac{d}{dq}[2(F_Y(q) - p)] = 2f_Y(q) \quad (126)$$

como $f_Y(q) > 0$ no suporte de Y , temos que a segunda derivada é estritamente positiva, garantindo que $q^* = F_Y^{-1}(p)$ seja o **único mínimo global estrito** $\square$




Figura 19: Gráfico de comparação entre a média do pinball error com relação ao valor candidato do quantil

7.3.2 Score de Winkler

Avalia a precisão de um intervalo de previsão $\hat{I} = [l_{\alpha,t}, u_{\alpha,t}]$ de nível de confiança $1 - \alpha$ para a distribuição preditiva F de Y

Definição 7.3.2.1 (Score de Winkler):

$$W_{\alpha}(l, u, y_t) = \begin{cases} (u - l) + \frac{2}{\alpha}(l - y_t) & y_t < l \\ u - l & l \leq y_t \leq u \\ (u - l) + \frac{2}{\alpha}(y_t - u) & y_t > u \end{cases} \quad (127)$$

onde l e u são os limites inferior e superior do intervalo de previsão, respectivamente, e y_t é o valor observado.

Existe uma conexão entre o score de Winkler e a Pinball Loss

Teorema 7.3.2.1 (Decomposição do Score de Winkler): O score de winkler se decompõe como a soma escalada das Pinball Losses nos quantis $p_1 = \frac{\alpha}{2}$ e $p_2 = 1 - \frac{\alpha}{2}$

$$W_{\alpha}(l, u, y_t) = \frac{1}{\alpha} [Q_{\frac{\alpha}{2}}(l, y) + Q_{1-\frac{\alpha}{2}}(u, y)] \quad (128)$$

Teorema 7.3.2.2 (Mínimo global do Score de Winkler): A esperança do Score de Winkler $\mathbb{E}[W_{\alpha}(l, u, y_t)]$ atinge seu mínimo global estrito se, e somente se, os limites l^* e u^* forem os quantis teóricos verdadeiros de y

$$\begin{aligned} l^* &= F_Y^{-1}\left(\frac{\alpha}{2}\right) \\ u^* &= F_Y^{-1}\left(1 - \frac{\alpha}{2}\right) \end{aligned} \quad (129)$$

Demonstração: Aplicando a linearidade da esperança e utilizando do Teorema 7.3.2.1, temos que

$$\mathbb{E}[W_{\alpha}(l, u, y_t)] = \frac{1}{\alpha} [\mathbb{E}[Q_{\frac{\alpha}{2}}(l, y)] + \mathbb{E}[Q_{1-\frac{\alpha}{2}}(u, y)]] \quad (130)$$

como o limite inferior l aparece apenas no primeiro termo e o limite superior u no segundo, então a minimização conjunta de $\mathbb{E}[W_{\alpha}(l, u, y_t)]$ se divide em duas otimizações diferentes

$$\min_l \mathbb{E}[Q_{\frac{\alpha}{2}}(l, y_t)] \quad \min_l \mathbb{E}[Q_{1-\frac{\alpha}{2}}(u, y_t)] \quad (131)$$

Pelo Teorema 7.3.1.1, sabemos que o mínimo global de cada termo é atingido quando l e u são os quantis verdadeiros da distribuição de y , ou seja

$$\begin{aligned} l^* &= F_Y^{-1}\left(\frac{\alpha}{2}\right) \\ u^* &= F_Y^{-1}\left(1 - \frac{\alpha}{2}\right) \end{aligned} \quad (132)$$

□

A lógica desse score é que, se o valor observado y_t estiver dentro do intervalo de previsão, o score é apenas o tamanho do intervalo, de forma que intervalos mais curtos são preferíveis. Se o

valor observado estiver fora do intervalo, o score penaliza a distância do valor observado para o limite mais próximo do intervalo, de forma que intervalos que **não cobrem** o valor observado são penalizados.




Figura 20: Dois intervalos. Se o curto cobre o valor observado, ele é preferível. Se o curto não cobre, ele pode ser penalizado e o maior ganhar

7.3.3 Continuous Ranked Probability Score

Avalia a CDF preditiva inteira $F(x)$ contra a função degrau empírica da realização real $\mathbb{I}(x \geq y_t)$

Definição 7.3.3.1 (Continuous Ranked Probability Score):

$$\text{CRPS}(F, y_t) = \int_{-\infty}^{\infty} (F(x) - \mathbb{I}(x \geq y_t))^2 dx \quad (133)$$

Ela mede a área entre a CDF prevista e o degrau unitário empírico em y_t (quanto menor a área, melhor). Existem dois teoremas interessantes que conectam o CRPS com a métrica de avaliação da pinball

Teorema 7.3.3.1 (Equivalência da CRPS): Seja Y uma variável contínua aleatória com CDF F_Y estritamente crescente, o CRPS de F_Y com relação a uma realização y é equivalente à integral da Pinball Loss sobre todos os quantis, ou seja:

$$\int_{-\infty}^{\infty} (F_Y(x) - \mathbb{I}(x \geq y))^2 dx = \int_0^1 Q_p(F_Y^{-1}(p), y) dp \quad (134)$$

Ou seja, enquanto o erro de quantil avalia apenas uma fatia p e o wrinkler avalia um intervalo fixo $(\frac{\alpha}{2}, 1 - \frac{\alpha}{2})$, o CRPS avalia a perda de todos os quantis do espaço amostral continuamente

Teorema 7.3.3.2 (Representação do CRPS por variáveis aleatórias latentes): Sejam X e X' duas variáveis aleatórias independentes com a mesma distribuição F , então, o CRPS pode ser representado como

$$\text{CRPS}(F, y) = \mathbb{E}_F |X - y| - \frac{1}{2} \mathbb{E}_F |X - X'| \quad (135)$$

Mas por que essa representação me é útil? Primeiro que ela é uma **decomposição**, onde $\mathbb{E}_F |X - y|$ é a acurácia/calibração, medindo o erro absoluto médio esperado entre as simulações do modelo e o valor real observado e $\mathbb{E}_F |X - X'|$ é a nitidez/dispersão, medindo a variabilidade/espalhamento interno da própria distribuição do modelo. Como entra com sinal negativo na perda, **recompensa distribuições mais concentradas (nítidas)** e pune incerteza desnecessária. Outro ponto positivo é que, em algoritmos de séries temporais que geram M trajetórias simuladas no futuro via **Bootstrap** $\{x^{(1)}, x^{(2)}, \dots, x^{(M)}\}$, não precisamos calcular nenhuma integral numérica da CDF $F(x)$. O CRPS empírico é calculado diretamente por somatório discreto:

$$\text{CRPS} = \frac{1}{M} \sum_{m=1}^M |x^{(m)} - y| - \frac{1}{2M^2} \sum_{m=1}^M \sum_{n=1}^M |x^{(m)} - x^{(n)}| \quad (136)$$




Figura 21: Ilustração do CRPS. F_1 com média deslocada e F_2 verdadeira

Transformações

Muitos modelos (e a ACF que já usamos) pedem algo próximo de **estacionariedade** fraca: média e variância estáveis no tempo, sem tendência óbvia. Só que isso obviamente pode não ocorrer na vida real e para cada **falha** lidamos de uma forma diferente

- **Variância muda com o nível:** Transformação de potência
- **Nível muda com o tempo:** Diferenciação

Primeiro estabiliza-se a variância (Box-Cox), depois aplica-se a diferenciação. Por quê? Diferenciar com o leque ainda aberto faz a série diferenciada misturar mudança de nível com mudança de escala ao mesmo tempo, destruindo o diagnóstico gráfico e da ACF

8.1 Box-Cox

Definição 8.1.1 (Transformação de Box-Cox): Para séries estritamente positivas $y_t > 0$, a transformação de Box-Cox é definida como

$$w_t = \begin{cases} \log(y_t) & \lambda = 0 \\ \frac{y_t^\lambda - 1}{\lambda} & \lambda \neq 0 \end{cases} \quad (137)$$

onde λ é um hiperparâmetro que controla a intensidade da transformação.




Figura 22: Ilustração da transformação de Box-Cox

Perceba que na imagem original, a variância cresce conforme o tempo vai passando, já as transformações estabilizam essa variância. Em software, o correto é estimar o λ ótimo via **Maximum Likelihood** e aplicar a transformação, mas para fins didáticos, testamos apenas alguns valores de λ e ver qual estabiliza melhor a variância. O gráfico serve também para ver se o λ faz sentido.

Depois que modelamos o w , precisamos que a previsão volte para a escala de y , afinal, se eu quero prever **litros de água**, não posso entregar **logaritmo de litros de água**.

Para intervalos de confiança, aplicamos a inversa da transformação nos extremos do intervalo

$$\mathbb{P}(w_1 \leq W \leq w_2) = 1 - \alpha \Rightarrow \mathbb{P}(g^{-1}(w_1) \leq Y \leq g^{-1}(w_2)) = 1 - \alpha \quad (138)$$

onde a inversa é definida como

$$g^{-1}(w) = \begin{cases} \exp(w) & \lambda = 0 \\ (\lambda w + 1)^{\frac{1}{\lambda}} & \lambda \neq 0 \end{cases} \quad (139)$$

Porém, temos que tomar cuidado. Por conta da **desigualdade de Jensen**, eu **não posso** estimar a média de W e aplicar g^{-1} nela para tentar estimar a média de Y .

8.2 Operador de Defasagem (Backshift)

Compacta a álgebra do atraso temporal

$$B^k y_t = y_{t-k} \quad k \in \mathbb{Z} \quad (140)$$

- Primeira diferença: $(1 - B)y_t = y_t - y_{t-1}$
- Diferença de ordem d : $(1 - B)^d y_t$
- Diferença sazonal de período m : $(1 - B^m)y_t = y_t - y_{t-m}$

8.3 Diferenciação

8.3.1 Diferenciação de Primeira Ordem

$$y'_t = (1 - B)y_t = y_t - y_{t-1} \quad (141)$$

Quando a média é aproximadamente linear, a diferenciação a estabiliza, removendo a tendência. Dois casos limites úteis:

- Se $y'_t = \varepsilon_t$ (ruído branco): y_t é um Passeio Aleatório Puro ($y_t = y_{t-1} + \varepsilon_t$).
- Se $y'_t = c + \varepsilon_t$: y_t é um Passeio Aleatório com Drift ($y_t = c + y_{t-1} + \varepsilon_t$, tendência estocástica com inclinação constante c)

8.3.2 Diferenciação de Segunda Ordem

$$y''_t = (1 - B)^2 y_t = (1 - B)y'_t = y'_t - y'_{t-1} = y_t - 2y_{t-1} + y_{t-2} \quad (142)$$

Empregada quando a primeira diferença ainda apresenta tendência (tendência quadrática). Porém, devemos tomar cuidado ao diferenciar demais ($d \geq 2$ injustificado) insere autocorrelação negativa artificial nos resíduos e destrói a informação do nível da série

Com tendência e sazonalidade juntas, a ordem usual é: sazonal primeiro, depois 1ª ordem se o nível ainda vagar:

$$(1 - B)(1 - B^m)y_t = y_t - y_{t-1} - y_{t-m} + y_{t-m-1} \quad (143)$$

Modelo AR e PACF

9.1 Modelos Autoregressivos (AR)

Um $AR(p)$ descreve a variável objetivo y_t como uma regressão linear nos próprios lags da série temporal

$$y_t = C + \varphi_1 y_{t-1} + \varphi_2 y_{t-2} + \dots + \varphi_p y_{t-p} + \varepsilon_t \quad \varepsilon_t \sim \text{WN}(0, \sigma^2) \quad (144)$$

Aqui, como os preditores são os próprios valores anteriores da série, a dependência temporal entra de forma explícita no modelo.

9.1.1 Caso especial $AR(1)$

$$y_t = C + \varphi_1 y_{t-1} + \varepsilon_t \quad \varepsilon_t \sim \text{WN}(0, \sigma^2) \quad (145)$$

Este é o modelo mais simples de um processo autoregressivo, onde a variável objetivo depende apenas do seu valor anterior.

- $\varphi_1 = 0, C = 0$: $y_t = \varepsilon_t$ (Ruído Branco).
- $\varphi_1 = 1, C = 0$: $y_t = y_{t-1} + \varepsilon_t$ (Passeio Aleatório — não-estacionário, variância cresce linearmente com t).
- $\varphi_1 = 1, C \neq 0$: $y_t = C + y_{t-1} + \varepsilon_t$ (Passeio Aleatório com Deriva/Drift).
- $\varphi_1 < 0$: A série oscila em torno da média trocando de sinal a cada passo (um valor alto em $y_{\{t-1\}}$ empurra y_t para baixo e vice-versa).
- Estacionariedade no $AR(1)$: Exige $|\varphi_1| < 1$. Se $|\varphi_1| > 1$, o processo é explosivo (os valores disparam sem limite).




Figura 23: Exemplo de modelo $AR(1)$ com $\varphi_1 < 0$ mostrando oscilações em torno da média.

Teorema 9.1.1.1 (ACF teórica do $AR(1)$ estacionário): Se $|\varphi_1| < 1$, a Função de Autocorrelação (ACF) teórica no lag $h \geq 0$ para o modelo $AR(1)$ é dada por:

$$\rho(h) = \varphi_1^h \quad (146)$$

Ou seja, a função decai exponencialmente para zero à medida que $h \rightarrow \infty$. Se $\varphi_1 > 0$, o decaimento é monótono positivo. Se $\varphi_1 < 0$, o decaimento oscila alternando sinais.

9.1.2 Estacionariedade do $AR(p)$

Usando o operador de defasagem (Backshift B), escrevemos o $AR(p)$ como:

$$(1 - \varphi_1 B - \varphi_2 B^2 - \dots - \varphi_p B^p) y_t = C + \varepsilon_t \Leftrightarrow \varphi(B) y_t = C + \varepsilon_t \quad (147)$$

onde $\varphi(z) = 1 - \varphi_1 z - \varphi_2 z^2 - \dots - \varphi_p z^p$ é o Polinômio Característico (ou de Defasagem) associado ao processo.

Definição 9.1.2.1 (Polinômio Característico): Dado um processo $AR(p)$, o polinômio característico $\varphi(z)$ é definido como

$$\varphi(z) = 1 - \varphi_1 z - \varphi_2 z^2 - \dots - \varphi_p z^p \quad (148)$$

Teorema 9.1.2.1 (Condição de Estacionariedade do $AR(p)$): O processo $AR(p)$ é (fracamente) estacionário se e somente se todas as p raízes do polinômio característico $\varphi(z) = 0$ estiverem **ESTRITAMENTE FORA** do círculo unitário no plano complexo:

$$\varphi(z_j) = 0 \Rightarrow |z_j| > 1 \quad \forall j \in \{1, \dots, p\} \quad (149)$$

Exemplo (Revisitando $AR(1)$): No caso de $p = 1$, temos que o polinômio característico será

$$\begin{aligned} \varphi(z) &= 1 - \varphi_1 z = 0 \\ \Rightarrow z &= \frac{1}{\varphi_1} \end{aligned} \quad (150)$$

logo, para ser estacionaria fraca, será

$$|z| > \frac{1}{\varphi_1} \Leftrightarrow |\varphi_1| < 1 \quad (151)$$

Exemplo (O triângulo de estacionariedade do $AR(2)$): No caso de $p = 2$, temos o polinômio

$$\varphi(z) = 1 - \varphi_1 z - \varphi_2 z^2 = 0 \quad (152)$$

exigir que as raízes estejam fora do círculo unitário reduz isso à um **triângulo de estacionariedade** no plano (φ_1, φ_2) , definido pelas seguintes condições:

$$\begin{cases} -1 < \varphi_2 < 1 \\ \varphi_1 + \varphi_2 < 1 \\ \varphi_2 - \varphi_1 < 1 \end{cases} \quad (153)$$




Figura 24: Triângulo de estacionariedade do modelo $AR(2)$

9.2 Função de Autocorrelação Parcial (PACF)

A ACF no lag h mede a correlação entre y_t e y_{t-h} , contudo, essa correlação pode ser contaminada por **caminhos indiretos** entre os lags intermediários. Se y_t correlaciona fortemente com y_{t-1} e y_{t-1} com y_{t-2} , a ACF mostrará uma correlação espúria em $h = 2$, mesmo que não exista nenhuma ligação direta entre y_t e y_{t-2} .

Definição 9.2.1 (Função de Autocorrelação Parcial): A Autocorrelação Parcial no lag k , denotada por α_k ou φ_{kk} , é a correlação entre y_t e y_{t-k} após remover o efeito linear de todos os lags intermediários $y_{t-1}, y_{t-2}, \dots, y_{t-k+1}$ (residualização). Matematicamente, φ_{kk} é o último coeficiente da regressão autorregressiva de ordem k :

$$y_t = \varphi_{k1}y_{t-1} + \varphi_{k2}y_{t-2} + \dots + \varphi_{kk}y_{t-k} + e_t \quad (154)$$




Figura 25: Ilustração da PACF

Nesse exemplo, a primeira imagem mostra a série temporal modelada com $AR(1)$ e $\varphi = 0.8$. A segunda imagem mostra a ACF, que vai decaindo aos poucos, mostrando que quanto mais distante, menos memória vai permanecendo. Já na PACF, a memória decai no instante $p = 1$, justamente por conta que o modelo depende exclusivamente do valor anterior.

Teorema 9.2.1 (Corte abrupto da PACF no modelo $AR(p)$): Se y_t segue um processo $AR(p)$ verdadeiro, então a PACF satisfaz

$$\varphi_{kk} = \begin{cases} C > 0 & k \leq p \\ 0 & k > p \end{cases} \quad (155)$$

Modelos MA e Invertibilidade

10.1 Modelo de Média Móvel (MA)

Ao contrário do $AR(p)$, que usa valores passados de y , o modelo $MA(q)$ escreve y_t como uma combinação linear dos erros passados ε_t

Definição 10.1.1 (Média Móvel): Ao modelarmos $y_t = MA(q)$, dizemos que:

$$y_t = C + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q} \quad \varepsilon_t \sim WN(0, \sigma^2) \quad (156)$$

a propriedade fundamental desse modelo é que ele possui **memória finita**, onde após q períodos, o erro ε_t não exerce mais influência

Teorema 10.1.1 (Memória do $MA(q)$): A Função de Autocorrelação (ACF) teórica de um modelo $MA(q)$ corta exatamente após o lag q :

$$\rho(h) = 0 \quad \forall h > q \quad (157)$$

10.2 $AR(1)$ como $MA(\infty)$

Todo processo $AR(p)$ estacionário pode ser reescrito como um processo $MA(\infty)$ de choques passados acumulados:

Teorema 10.2.1: Se $|\varphi_1| < 1$, o modelo $y_t = \varphi_1 y_{t-1} + \varepsilon_t$ admite a representação:

$$y_t = \sum_{j=0}^{\infty} \varphi_1^j \varepsilon_{t-j} \quad (158)$$

Demonstração: Substituindo a equação de y_{t-1} recursivamente em y_t :

$$y_t = \varphi_1(\varphi_1 y_{t-2} + \varepsilon_{t-1}) + \varepsilon_t = \varepsilon_t + \varphi_1 \varepsilon_{t-1} + \varphi_1^2 y_{t-2} \quad (159)$$

Após N substituições:

$$y_t = \sum_{j=0}^N \varphi_1^j \varepsilon_{t-j} + \varphi_1^{N+1} y_{t-N-1} \quad (160)$$

Tomando o limite $N \rightarrow \infty$, como $|\varphi_1| < 1$, o termo de memória inicial $\varphi_1^{N+1} y_{t-N-1} \rightarrow 0$, resultando em $y_t = \sum_{j=0}^{\infty} \varphi_1^j \varepsilon_{t-j}$ $\square$

10.3 Invertibilidade e Representação $AR(\infty)$ de um $MA(q)$

Podemos fazer o caminho inverso: expressar o erro ε_t em função dos valores observados passados de y .

Para o $MA(1)$: $y_t = (1 + \theta_1 B)\varepsilon_t \Rightarrow \varepsilon_t = (1 + \theta_1 B)^{-1} y_t$.

Aplicando a expansão em série de Neumann $(1 + x)^{-1} = \sum_{j=0}^{\infty} (-x)^j$:

$$\varepsilon_t = \sum_{j=0}^{\infty} (-\theta_1)^j B^j y_t = y_t - \theta_1 y_{t-1} + \theta_1^2 y_{t-2} - \theta_1^3 y_{t-3} + \dots \quad (161)$$

Isolando y_t para obter a representação $AR(\infty)$:

$$y_t = \sum_{j=1}^{\infty} -(-\theta_1)^j y_{t-j} + \varepsilon_t \quad (162)$$

Teorema 10.3.1 (Invertibilidade): Para que os pesos da recuperação do erro $(-\theta_1)^j$ decaiam para zero à medida que nos afastamos no passado (garantindo que observações recentes pesem mais do que o passado remoto), exige-se a condição de Invertibilidade:

$$\text{se } z_j \text{ tal que } \theta(z_j) = 0 \wedge \theta(z) = 1 + \theta_1 z + \dots + \theta_q z^q \Rightarrow |z_j| > 1 \quad (163)$$

10.4 Armadilha Matemática da Não-Identificabilidade do $MA(1)$ não invertível

Teorema 10.4.1: Os modelos $MA(1)$ com parâmetro $\theta_1 = \theta$ e com parâmetro $\theta_1 = \frac{1}{\theta}$ geram exatamente a mesma Função de Autocorrelação (ACF).

Demonstração: Seja $\rho_\theta(1)$ a ACF no lag 1 do modelo com parâmetro θ :

$$\rho_\theta(1) = \frac{\theta}{1 + \theta^2} \quad (164)$$

Substituindo θ por $\tilde{\theta} = \frac{1}{\theta}$:

$$\rho_{\tilde{\theta}}(1) = \frac{\frac{1}{\tilde{\theta}}}{1 + \left(\frac{1}{\tilde{\theta}}\right)^2} = \frac{\frac{1}{\tilde{\theta}}}{\frac{\tilde{\theta}^2 + 1}{\tilde{\theta}^2}} = \frac{1}{\tilde{\theta}} \cdot \frac{\tilde{\theta}^2}{\tilde{\theta}^2 + 1} = \frac{\tilde{\theta}}{1 + \tilde{\theta}^2} = \rho_\theta(1) \quad (165)$$

□

Mas por que isso seria um problema? A amostra de dados não consegue distinguir um $MA(1)$ com $\theta = 0.5$ de um com $\theta = 2$ pois ambos geram a mesma ACF. Se o modelo tivesse $\theta = 2$ (não-invertível), a recuperação do erro usaria pesos $(-2)^j$ que explodem no passado remoto. Para garantir identificabilidade única e uma expansão $AR(\infty)$ estável, todos os algoritmos de estimação impõem estritamente a restrição de invertibilidade $|\theta| < 1$

10.5 PACF e ACF do $MA(q)$

Teorema 10.5.1 (Corte abrupto da ACF do $MA(q)$): Seja Y_t um processo de Média Móvel de ordem q , $MA(q)$, definido por:

$$Y_t = C + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \dots + \theta_q \varepsilon_{t-q}, \quad \varepsilon_t \sim WN(0, \sigma^2) \quad (166)$$

onde $\theta_q \neq 0$. A Função de Autocorrelação (ACF) teórica $\rho(h)$ apresenta um corte abrupto exatamente após o lag q :

$$\rho(h) = \begin{cases} 1 & h = 0 \\ \frac{\sum_{j=0}^{q-|h|} \theta_j \theta_{j+|h|}}{\sum_{\{j=0\}}^q \theta_j^2} & 1 \leq |h| \leq q \text{ assumindo } \theta_0 = 1 \\ 0 & |h| > q \end{cases} \quad (167)$$

Aqui vemos a relação inversa com PACF e ACF que o $MA(q)$ possui em relação ao “AR(p)”. Enquanto o $AR(p)$ possui corte abrupto na PACF e decaimento exponencial na ACF, o $MA(q)$ possui corte abrupto na ACF e decaimento exponencial na PACF.

Modelo ARIMA

O modelo ARIMA(p, d, q) unifica tudo que vimos de modelagem de séries temporais até o momento

1. $I(d)$ (Integração/Diferenciação): Remove a **tendência estocástica** e ajusta o nível da série original y_t através de d diferenças para torná-la estacionária: $y_t^* = (1 - B)^d y_t$
2. $AR(p)$ (Autoregressivo): Modela a dependência temporal (**memória**) da série diferenciada y_t^* através de p lags passados: $y_t^* = \varphi_1 y_{t-1}^* + \dots + \varphi_p y_{t-p}^* + \varepsilon_t$
3. $MA(q)$ (Média Móvel): Modela a dependência temporal nos erros passados ε_t através de q lags passados: $y_t^* = \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}$

11.1 Formulação Geral

Aplicando d diferenças na série original y_t , temos a série diferenciada $y_t^* = (1 - B)^d y_t$, então y_t^* segue um modelo ARMA(p, q):

$$y_t^* = C + \varphi_1 y_{t-1}^* + \dots + \varphi_p y_{t-p}^* + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q} \quad \varepsilon_t \sim \text{WN}(0, \sigma^2) \quad (168)$$

Lembrando que $B^k y_t = y_{t-k}$, conseguimos simplificar a equação acima usando o operador de defasagem B :

$$y_t^* = C + (\varphi_1 B + \varphi_2 B^2 + \dots + \varphi_p B^p) y_t^* + (1 + \theta_1 B + \theta_2 B^2 + \dots + \theta_q B^q) \varepsilon_t \quad (169)$$

colocando os y_t^* em evidência e usando a definição $y_t^* = (1 - B)^d y_t$, conseguimos o modelo simplificado do ARIMA(p, d, q):

$$\underbrace{(1 - \varphi_1 B - \varphi_2 B^2 - \dots - \varphi_p B^p)}_{\text{AR}} \underbrace{(1 - B)^d}_{\text{I}} y_t = C + \underbrace{(1 + \theta_1 B + \theta_2 B^2 + \dots + \theta_q B^q)}_{\text{MA}} \varepsilon_t \quad (170)$$

11.2 C e d em Previsões de Longo Prazo

O C e d tem um papel conjunto muito importante na previsão de longo prazo da série

11.2.1 $C = 0$ e $d = 0$

Previsão de longo prazo converge para a média da série original y_t .

$$\lim_{h \rightarrow \infty} \hat{Y}_{T+h|T} = \mu = \frac{C}{1 - \sum_{i=1}^p \varphi_i} \quad (171)$$




Figura 26: Previsão de longo prazo converge para a média da série

11.2.2 $C = 0$ e $d = 1$

A previsão congela no último valor observado da série original y_t .

$$\lim_{h \rightarrow \infty} \hat{Y}_{T+h|T} = y_T \quad (172)$$




Figura 27: Previsão de longo prazo congela no último valor observado da série

11.2.3 $C \neq 0$ e $d = 1$

A constante C se torna-se a **inclinação** de uma **tendência linear determinística** no nível original de y

$$\hat{Y}_{T+h|T} \approx \hat{Y}_{T|T} + h \cdot \mu_{\Delta y}$$

$$\mu_{\Delta y} = \frac{C}{1 - \sum_{i=1}^p \varphi_i} \quad (173)$$




Figura 28: Previsão de longo prazo com $C \neq 0$ e $d = 1$ gera tendência linear determinística no nível original

11.2.4 $d = 2$

Gera uma previsão com curvatura quadrática




Figura 29: Previsão de longo prazo com $d = 2$ gera tendência quadrática determinística no nível original

11.3 Por que ARMA e não só AR ou MA?

Acontece que os modelos AR e MA modelam dois extremos diferentes, um cobre dependência temporal dentro das observações passadas (AR) e o outro cobre dependência temporal dentro dos erros passados (MA). A combinação de ambos permite capturar padrões mais complexos de memória temporal, tornando o modelo mais flexível e capaz de se ajustar melhor a uma variedade maior de séries temporais com menos parâmetros do que um modelo puramente AR ou MA.

Além disso, como vimos, teóricamente, todo modelo $AR(p)$ estacionário pode ser representado como um modelo $MA(\infty)$ e vice-versa, então para aproximar cada um, eu necessitaria de **muitos** parâmetros no outro, gerando risco de **overfitting** e perda de interpretabilidade.

Aqui utilizamos do princípio da parcimônia: **prefira o modelo mais simples que se ajuste bem aos dados**. Se um modelo $AR(p)$ com poucos parâmetros consegue capturar a memória temporal de uma série, não há necessidade de adicionar mais parâmetros de média móvel. O mesmo vale para o contrário.